

I HC QUC GIA THỊNH PH H CHỜ MINH
TRNG I HC BỒCH KHOA

LỔ PHỮC C

NGHIỂN CU VỊ PHÒT TRIN H THNG
T NG PHÒT HIN HIN TNG TRỮ DT VỊ
CP NHT MŨ HƠNH HC MÒY THỜCH
NG

Chuyển ngành: Khoa hc mỳ tồnh
Mã ngành: 8480101

LUN VN THC S

Thịnh ph H Chờ Minh, thòng 5 nm 2026

I HC QUC GIA THỊNH PH H CHỜ MINH
TRNG I HC BỒCH KHOA

LỔ PHỮC C

NGHIỂN CU VỊ PHÒT TRIN H THNG
T NG PHÒT HIN HIN TNG TRỮ DT VỊ
CP NHT MŨ HƠNH HC MÒY THỜCH
NG

Chuyển ngành: Khoa hc mỳ tồnh
Mã ngành: 8480101

LUN VN THC S

Thịnh ph H Chờ Minh, thòng 5 nm 2026

**CỦNG TRƯỞNG C HOÀN THỊNH TI
TRNG I HC BỒCH KHOA – HQG-HCM**

Còn b hng dn khoa hc 1: **PGS. TS. Thoi Nam**

Ch kỳ:

Còn b hng dn khoa hc 2: **TS. Nguyn Quang Hứng**

Ch kỳ:

Còn b chm nhn xốt 1: **TS. Hị Minh Tốn**

Ch kỳ:

Lun vn thc s c bo v ti Trng i hc Bồch Khoa – HQG-HCM ngiy 17 thòng 6 nm 2026.

Thịnh phn Hi ng ònh giò Lun vn thc s gm:

1. Ch tch hi ng: **TS. Nguyn Lổ Duy Lai**

2. Th kỳ: **TS. Dip Thanh ng**

3. Phn bin: **TS. Hị Minh Tốn**

Xóc nhn ca Ch tch Hi ng ònh giò Lun vn vị Trng khoa qun lý ngịnh sau khi lun vn ã c sa cha (nu cú).

CH TCH HI NG

TRNG KHOA

NHIM V LUN VN THC S

H vị tồn hc viõn: Lỗ Phũc c Mã s hc viõn: 2370116
Ngìy, thông, nm sinh: 29/09/2000 Ni sinh: Thỉnh ph H Chờ Minh
Chuyõn ngình: Khoa hc mỳi tồnh Mã ngình: 8480101

I. TỔN TỤ:

Tổn Tĩng Vit:

NGHIÕN CU VỊ PHÒT TRIN H THNG T NG PHÒT HIN HIN TNG TRỮI DT VỊ
CP NHT MỸ HỒNH HC MỖY THỒCH NG

Tổn Tĩng Anh:

Research and Development of an Adaptive Machine Learning System with
Automatic Concept Drift Detection and Model Updating

II. NHIM V VỊ NI DUNG:

Nhim v	Ni dung
Kho sòt vị phón tồch	Kho sòt hìn tng trữi dt khòì nìm, còc thng kổ kim nh, khong còch phón phi MMD vị phòt hìn drift khũng giòm sòt.
òngh giò hìu sut	Tìn hình ònh giò toịn đìn còc b phòt hìn drift trởn benchmark gm 14 tp d liu vì 30 ln chy c lp.
Phón loi trữi dt	Xóy dng h thng SE-CDT nhn dng loi drift đa trởn hình dng tòn hìu MMD khũng cn nhõn.
Thồch ng mữ hình	xut vị trin khai còc chín lc cp nht mữ hình thồch ng tng ng vì tng loi drift c phòt hìn.
Tồch hp thi gian thc	Thit k vị kim th nguyõn mu h thng x lý dùng thi gian thc trởn nn tng Apache Kafka.

III. NGÀY GIAO NHIM V: 25/08/2025

IV. NGÀY HOÀN THỊNH NHIM V: 11/05/2026

V. CÒN B HNG DN:

- **CBHD 1:** PGS. TS. Thoi Nam
- **CBHD 2:** TS. Nguyn Quang Húng

Tp. HCM, ngày .. tháng .. nm 20..

CÒN B HNG DN
(Ký vị ghi rủ h tổn)

TRNG KHOA
(Ký vị ghi rủ h tổn)

LI CM N

Li u tiển, hc viển xin c bñy t lũng bit n sỏu sc n Ban Giỏm hủu nhự trng, khoa Khoa hc vự K thut Mỏy tởnh ca i hc Bỏch Khoa - HQG-HCM trong quỏng thi gian hc viển c hc tp vự nghiỏn cu ti trng trong chng trỡnh Cao hc.

Hc viển c bit xin c gi li cm n sỏu sc n thỳ PGS.TS. Thoi Nam vự thỳ TS. Nguyñ Quang Hứng, nhng ngi thỳ hng dn vự giỏm sỏt trc tip quỏ trỡnh thc hin lun vn. Nh cú nhng gúp ý, ch bo tn tớnh cứng nhiu kin thc b ỏch, quỳ giỏ ca quỳ thỳ mự hc viển mi cú th hoỏn thỡnh tt c Lun vn tt nghip nựy.

Cui cứng, hc viển cng xin gi li cm n n gia ỏnh, ngi thỏn, bn bớ, nhng ngi ỏ quan tỏm, ng viển hc viển cú th hoỏn thỡnh tt lun vn tt nghip nựy.

Thỡnh ph H Chờ Minh, nm 2026

Hc viển thc hin

TÓM TẮT LUN VĂN THỰC S

Concept drift là một nguyên nhân quan trọng làm giảm hiệu quả của hệ thống học máy khi dữ liệu vận hành thay đổi theo thời gian. Luận văn đề xuất **SE-CDT (ShapeDD-Enhanced Concept Drift Type)** — một hệ thống phát hiện vị phân loại drift tổng hợp, không cần nhãn, kiểm soát khung thời gian mô hình theo loại drift cho luồng dữ liệu.

Module phát hiện của SE-CDT, dựa trên **ShapeDD-IDW**, cải tiến ShapeDD theo kiến trúc hai bước: tồn tại Standard MMD để phát hiện trôi dạt, sau đó lọc nhiễu bằng kim nhúng bằng IDW-MMD (Inverse Density-Weighted MMD) với tham số Gamma để hiệu chỉnh Bonferroni khi có nhiều nhiễu trôi dạt. Trên 14 tập dữ liệu với 30 lần chạy lặp, module phát hiện đạt $F_1 = 0.531$ với $\delta = 75$ mẫu và cooldown = 150 mẫu, tăng gấp đôi hiệu suất DAWIDD trong kim nhúng Nemenyi và vượt trội hơn ShapeDD gốc trong cùng benchmark, tăng gấp đôi hiệu suất ShapeDD gốc không $7\times$ thay thế permutation test bằng tham số Gamma.

Module phân loại của SE-CDT có hình thức tồn tại MMD phân biệt sudden, gradual, incremental, recurrent vị blip drift mà không cần nhãn. Module này được xây dựng để khởi đầu cho recurrent drift vị một loạt blip để nhận diện tồn tại có hai hoặc ba loại. Kết quả đạt 80.1% mức phân nhóm TCD/PCD, 55.3% mức tiêu loại theo trung bình vị mẫu và 54.4% theo trung bình tăng lặp. Sudden đạt 82.4%, Blip đạt 60.8% và Recurrent đạt 71.5%, trong khi Gradual (27.2%) và Incremental (30.3%) là hai trường hợp khó nhất do tồn tại chuyển tiếp chậm chóng lẫn vào phần sai của vị lọc chuỗi drift chậm lặp lại để bắt đầu khởi đầu gộp sang nhóm recurrent.

Trong môi trường thời gian, chiến lược cập nhật theo loại drift sẽ nâng cao hiệu suất phân loại của SE-CDT cải thiện rõ rệt trên Stepping vị Sudden so với không thời gian, đạt 73.96% và 73.34% prequential accuracy. Trên Mixed, chiến lược này đạt 86.36%, gần với Periodic Retrain nhưng tốn kém chi phí bảo trì hơn. Nguyên nhân hệ thống cũng có kim nhúng trên kiến trúc tăng thời gian Kafka/Redpanda xác nhận quy trình phát hiện-phân loại bằng SE-CDT cần cập nhật vị nạp lại mô hình.

ABSTRACT

Concept drift is a major cause of performance degradation in machine learning systems when operating data changes over time. This thesis proposes **SE-CDT (ShapeDD-Enhanced Concept Drift Type)**, a unified detector-classifier system for unsupervised drift handling on streaming data, paired with a type-specific adaptation framework.

The **detection module** of SE-CDT, named **ShapeDD-IDW**, extends ShapeDD with a two-stage design. A Standard MMD signal first locates drift candidates; candidate peaks are then validated by IDW-MMD (Inverse Density-Weighted MMD) using a Gamma-approximated null distribution, with Bonferroni correction when several peaks are tested in the same trace. On a 14-dataset benchmark with 30 independent runs, $\delta = 75$ tolerance, and cooldown = 150, the detection module reaches $F_1 = 0.531$, statistically tied with DAWIDD under the Nemenyi rank test and above the original ShapeDD in the same benchmark, while running approximately $7\times$ faster than ShapeDD because the Gamma null replaces the costly permutation test.

The **classification module** of SE-CDT identifies sudden, gradual, incremental, recurrent, and blip drift from the shape of the MMD signal without labels. It uses concept memory for recurrent drift and a relaxed blip rule that accepts two- or three-peak transient signals. The classifier reaches 80.1% TCD/PCD category accuracy, 55.3% micro-averaged subtype accuracy, and 54.4% macro-averaged subtype accuracy. Sudden, blip, and recurrent drift are identified more reliably than the two slow-transition types; gradual and incremental drift are the hardest cases, as their signals overlap in windowed variance and repeated slow drifts are absorbed into the recurrent branch by concept memory.

For adaptation, type-specific model updates driven by SE-CDT’s classification output improve prequential accuracy on Stepping and Sudden scenarios compared with no adaptation, reaching 73.96% and 73.34%, respectively. On the Mixed scenario, the method reaches 86.36%, close to Periodic Retrain but with fewer redundant alarms. A Kafka/Redpanda-compatible prototype is also tested to validate the end-to-end flow from SE-CDT detection to model update and reload.

LI CAM OAN

Học viên xin cam oan rằng luận văn này là cũng trình nghiên cứu cá riểng học viên, c thc hìn di s hng dn khoa học ca PGS.TS. Thoi Nam vị TS. Nguyn Quang Hứng. Còc ni dung nghiên cứu vị kt qu c trình bày trong luận văn li trung thc vị do chồnh học viên thc hìn trong sut quồ trình theo học chng trình Cao học ti Trng i học Bòch Khoa – HQG-HCM. Mi tị liu vị ngun tham kho c s dng u ò c trồch dn vị ghi nhn y .

Học viên xin hoịn toịn chu trồch nhim v ni dung nghiên cứu cá mớnh.

Thịnh ph H Chờ Minh,

Học viên thc hìn

MC LC

LI CM N	i
TÚM TT LUN VN THC S	ii
ABSTRACT	iii
LI CAM OAN	iv
MC LC	v
DANH SÒCH BNG BIU	x
DANH SÒCH HÓNH V	xii
DANH SÒCH GII THUT	xiv
DANH MC T VIT TT	xv
DANH MC KỲ HIU TOÀN HC	xvii
CHNG 1. Gii thiu tị	1
1.1 Thc trng chung	1
1.2 Tng quan v bii toàn	1
1.3 Mc tiu tị	2
1.4 Phm vi tị v i tng nghiõn cu	2
1.4.1 Phm vi tị	2
1.4.2 i tng nghiõn cu	3
1.5 Cu trũc lun vn	4
CHNG 2. C s lý thuyt	5
2.1 Khòì nim v concept drift v i phón loi	5
2.1.1 Khòì nim v Concept Drift	5
2.1.2 Phón loi còc dng Concept Drift	5
Phón loi theo s thay i phón phi	6

Phón loi theo tc vị mũ hnh thay i	6
2.1.3 nh hng ca concept drift	8
2.2 ShapeDD - Phng phòp phòt hin trũi dt đa trổn hnh dng vị kh nhiu tòn hiu	9
2.2.1 Gii thiu	9
2.2.2 Quy c kỳ hiu	9
2.2.3 C s lý thuyt	9
i lng ln trũi dt (σ)	9
Hnh dng c trng ca drift t ng	10
Tng quòt hoò cho nhiu s kin drift	11
2.2.4 ng dng vò lc nhiu vị phòt hin drift	11
2.2.5 Maximum Mean Discrepancy (MMD)	11
2.2.6 Còch thc hot ng ca ShapeDD	13
Giai on 1: Thu thp d liu (Data Collection)	13
Giai on 2: Xóy dng feature (Feature Construction)	14
Giai on 3: Tòngh toòn s khòc bit (Difference Computation)	14
Giai on 4: Xòc thc thng kỏ (Statistical Validation)	15
u im ni bt ca ShapeDD	17
Hn ch vị iu kin òp dng hiu qu	17
CHNG 3. Cũng trnh liỏn quan	19
3.1 Còc phng phòp phòt hin trũi dt	19
3.1.1 Còc phng phòp thng kỏ	19
3.1.2 Còc phng phòp đa trổn hiu nng mũ hnh	20
3.1.3 Còc phng phòp hc mỳy truy n thng	23
3.1.4 Còc phng phòp hc sỏu	23
3.2 Phng phòp phón loi drift CDT-MSW	26
3.3 Còc chin lc cp nht mũ hnh thờch ng	27
3.3.1 Tng quan	27
3.3.2 Phón loi chin lc cp nht	27
3.4 Lý do la chn ShapeDD lịm nn tng	29
CHNG 4. H thng SE-CDT: Phòt hin, Phón loi vị Thờch ng Concept Drift	31
4.1 ng lc vị tng quan còch tip cn	31
4.1.1 Tng quan kin trũc ba module	32
4.2 xut ci tin phng phòp phòt hin drift: IDW-MMD vị xp x Gamma	33

4.2.1 Inverse Density-Weighted MMD (IDW-MMD): Tỉ lệ hóa hiệu suất vị chớnh xóc	33
Vn ca c lng MMD truyn thng	33
Ỗ tng ci tin bng còch dứng trng s thay i theo v trồ	33
Gii phỏp xut: Trng s nghch bin mt (Inverse Density Weighting)	34
nh hng n tồn hiu phỏt hin	35
Phỏn tồch phc tp tồnh toỏn	36
Hn ch vị khi nỏo nỏn dứng	37
Kin trức kt hp ca Detection Module	37
4.3 Phng phỏp phỏn loi drift SE-CDT	38
4.3.1 C s lý thuyt	38
4.3.2 c trng phỏn loi t tồn hiu $\sigma(t)$	39
4.3.3 Thut toỏn phỏn loi	43
4.3.4 u im vị phc tp	45
4.3.5 Gii thờch la chn ngng	46
4.3.6 T hiu chnh ngng phỏn loi (Online Self-Calibration)	47
4.3.7 B nh khỏi nim cho Recurrent Drift (Concept Memory)	47
4.4 Khung chin lc thờch ng mủ hỏnh	48
4.4.1 Ma trn quyỏt nh chin lc	48
4.4.2 nh hng ca bỏo ng sai vị b sút drift	49
4.4.3 Trin khai còc chin lc	50
Chin lc cho Sudden Drift (Trng tóm nghiỏn cu)	50
Model Caching theo Concept Memory	50
4.5 Kin trức xut cho h thng phỏt hin trủi dt vị cp nhỏt mủ hỏnh thờch ng	50
4.5.1 Tng quan kin trức	51
4.5.2 Thit k chỉ tit còc thnh phn	52
Producer vị Data Ingestion	52
Consumer vị C ch Windowing	52
Qun lý Topic vị Giao tip	52
4.6 C ch chu li vị m bo tin cy	52
4.6.1 X lý li mc ng dng	53
4.6.2 X lý li mc h tng (Kafka)	53
4.7 Kt lun chng	53
CHNG 5. Thc nghi m vị ònh giò	54
5.1 Tng quan thc nghi m	54

5.1.1	Mc tiểu vị cụ trực chng	54
5.1.2	Mũi trng vị cụ hnh	54
5.1.3	Tp d liu thc nghim	54
5.1.4	Chin lc ònh giò	58
5.2	ònh giò kh nng phòt hìn ca SE-CDT	59
5.2.1	Thit lp thc nghim phòt hìn drift (Detection Setup)	59
5.2.2	Kt qu so sòn hiu sut phòt hìn	59
5.2.3	Phón tồch ý ngha thng kổ	60
5.2.4	ònh giò chỉ tit trổn tng loi d liu	61
5.2.5	Kim tra t l bào ng sai trổn d liu khũng cú drift	66
5.2.6	ònh giò hiu sut tồnh toòn	67
5.3	ònh giò module phón loi ca SE-CDT	68
5.3.1	Thit lp thc nghim phón loi drift	68
5.3.2	Kt qu phón loi tng hp ca SE-CDT	70
5.3.3	Phón tồch chỉ tit theo loi drift	72
5.3.4	So sòn vi CDT-MSW	74
5.4	ònh giò kh nng thồch ng mũ hnh	74
5.4.1	Thit lp thc nghim thồch ng mũ hnh	74
5.4.2	Phm vi phòt hìn trong thồch ng	75
5.4.3	Kt qu phc hi (Recovery)	76
5.5	Kim th nguyổn mu trổn kin trức tng thồch Kafka	79
5.5.1	Kch bn trin khai	79
5.5.2	Kt qu thc t	80
5.6	Kt lun chng	81
CHNG 6.	Kt lun vị Hng phòt trin	82
6.1	Tng kt còc úng gúp chờnh	82
6.2	Hn ch vị Phm vi nghiổn cu	83
6.2.1	Trade-off gia Recall vị False Positives	83
6.2.2	Subcategory Accuracy cùn hn ch	83
6.2.3	Ngng phón loi vn cùn yu t heuristic	83
6.2.4	Gi nh joint drift trong phón loi	84
6.2.5	D liu tng hp (Synthetic Data)	85
6.2.6	Phm vi ònh giò thồch ng	85
6.2.7	Nguyổn mu Kafka cha phi benchmark production	85
6.3	Hng nghiổn cu tng lai	85

6.3.1	M rng sang còc loi Drift khòc nhau	85
6.3.2	Ci tin phón loi SE-CDT	86
6.3.3	Hng dñi hn	86
6.4	Kt lun	86
DANH MC CŨNG B KHOA HC		88
TỊ LIU THAM KHO		89
PH LC		95
PHN LỖ LCH TRÒCH NGANG		98

DANH SÁCH BNG BIU

2.1 Liễn h gia loi thay i d liu vị chin lc thờch ng mũ hnh	7
2.2 Bng kỳ hui thng nht	9
3.1 Còc phng phòp DDM-family	22
3.2 Tóm tt mt s mc chnh trong phòt trin phng phòp phòt hin concept drift	25
3.3 Phón loi vị c tnh k thut ca còc b dù Concept Drift tiếu biu	25
3.4 Tng hp hui nng phòt hin drift t còc nghiêng cu gc	26
3.5 Mi quan h gia loi trũ dt vị chin lc cp nht mũ hnh thờch ng	29
4.1 phc tp tnh toàn ca IDW-MMD vị còc phng phòp liễn quan	36
4.2 Tng hp còc c trng phón loi ca SE-CDT	43
4.3 Siếu tham s ca SE-CDT vị giò tr mc nh	43
4.4 Chin lc thờch ng theo loi Drift	49
4.5 Danh sòch Kafka Topics vị Chc nng	52
5.1 Quy c thit lp còc mc ònh giò. Cứng mt detector nhng c o di nhng cu hnh ca s vị dung sai khòc nhau tũy còu hi mị mc ú tr li; còc giò tr W , δ vị cooldown dũng trong chng c tng hp ti óy.	58
5.2 So sònh tng hp hui sut còc phng phòp phòt hin drift	59
5.3 Th hng trung bnh theo F1-score trong kim nh Friedman/Nemenyi	61
5.4 F1-Score theo dataset (Phn 1: D liu c bn vị Mild/Moderate Drift)	62
5.5 F1-Score theo dataset (Phn 2: Drift mnh vị thay i mt phng)	62
5.6 F1-Score theo dataset (Phn 3: RBF Blips, GCS vị GRS)	62
5.7 F1-Score theo dataset (Phn 4: Standard SEA vị trung bnh)	62
5.8 T l Type-I error trổn d liu tnh	66
5.9 So sònh hui sut tnh toàn ca còc phng phòp	67
5.10 Sòu kch bn benchmark module phón loi ca SE-CDT	68
5.11 Kt qu phón loi drift type ca SE-CDT (tng hp 1800 s kin, 6 kch bn $\times$ 30 seeds)	70
5.12 chnh xòc phón loi theo tng loi drift (oracle mode, SE-CDT Std)	72

5.13	So sánh phón loi CDT-MSW vs SE-CDT	74
5.14	Kt qu Prequential Accuracy theo loi drift ($N = 30$ runs, $T = 5000$ mu). Ct FP: s ln bào ng sai trung bình mi run, theo th t chín lc (Type-Specific / Simple Retrain / Periodic Retrain / No Adaptation).	76
6.1	Túm tt s liu chờnh ca lun vn theo ba trc ứng gúp. Chi tit vị phón tồch thng kố trong Chng 5.	82

DANH SÁCH HÌNH V

2.1	Phón loi drift theo thay i phón phi	7
2.2	Phón loi drift theo tc thay i	8
3.1	Tng quan ba giai on ca CDT-MSW: phòt hin v trở trũ dt, c lng dũi, theo dũi vị phón loi tiu loi bng TFR/MTFR.	27
4.1	Kin trũc tng quan: H thng SE-CDT (gm Detection Module chy ShapeDD- IDW vị Classification Module phón tồch hnh dng $\sigma(t)$) nhn lung $\{X_t\}$ vị sn xut nhõn loi drift; Adaptation Module dũng nhõn nịy chn chin lc cp nht mũ hnh phũ hp.	32
4.2	C ch Trng s Nghch mt IDW-MMD	34
4.3	C ch Ca s trt to tồn hũu MMD	37
4.4	Phón tồch tồn hũu SE-CDT	40
4.5	Hnh dng tồn hũu MMD ca còc loi Drift	40
4.6	C ch hot ng ca Variance Ratio	42
4.7	Lu phón loi drift ca SE-CDT	45
4.8	S kin trũc h thng phòt hin vị thờch ng Drift	51
5.1	Biu Critical Difference (CD)	61
5.2	Mĩnh ha tồn hũu phòt hin trở d liũ Sudden Drift	64
5.3	Mĩnh ha tồn hũu trở d liũ Gradual Drift	65
5.4	Phón tồch s lng bõo ng gĩ trở tp d liũ tnh	65
5.5	Thi gian chy trung bõnh ca còc phng phòp trở ònh giò phòt hin (10,000 mu, 30 ln chy).	67
5.6	Hnh dng tồn hũu SE-CDT — Sudden Drift	69
5.7	Hnh dng tồn hũu SE-CDT — Incremental Drift	70
5.8	Confusion Matrix — 5 lp drift	72
5.9	Confusion Matrix — Category Level	73
5.10	Prequential Accuracy — Stepping Drift	77
5.11	Prequential Accuracy — Sudden Drift	78

5.12Prequential Accuracy — Mixed Drift	79
5.13Kt qu kim th nguồn mu Kafka	80

DANH SÁCH GIỚI THIỆU

1	Shape-based Drift Detector (ShapeDD)	17
2	Inverse Density-Weighted MMD (IDW-MMD)	35
3	SE-CDT — Unsupervised Drift Type Classification	44

DANH MỤC T VIẾT TẮT

Viết tắt	Giải nghĩa
<i>Phương pháp vị thuật toán</i>	
MMD	Maximum Mean Discrepancy — Không còch phón phi đa trở h t nhón
IDW-MMD	Inverse Density-Weighted MMD — MMD cú trng s nghch bin mt
ShapeDD	Shape-based Drift Detection — Phòt hìn drift đa trở hnh đng tồn h iu
ShapeDD-IDW	ShapeDD kt hp IDW-MMD vì xp x Gamma
SE-CDT	ShapeDD-Enhanced Concept Drift Type — H thng tòch hp phòt hìn vị phón loi drift khùng giòm sòt
CDT-MSW	Concept Drift Type identification based on Multi-Sliding Windows
ADWIN	Adaptive Windowing — C ch ca s thờch nghi
CUSUM	Cumulative Sum — Tng tòch ly cho kim soòt cht lng
DDM	Drift Detection Method
EDDM	Early Drift Detection Method
HDDM	Hoeffding's Drift Detection Method
FHDDM	Fast HDDM — Phiổn bn nhanh ca HDDM
RDDM	Reactive Drift Detection Method
MDDM	McDiarmid Drift Detection Method
KSWIN	Kolmogorov-Smirnov Windowing
SEA	Streaming Ensemble Algorithm — B to d liu drift chun
NSE	Non-Stationary Environment (Learn++.NSE)
DAWIDD	Dynamic Adapting Window Independence Drift Detection
D3	Discriminative Drift Detector
KS	Kolmogorov-Smirnov (test)
<i>Phón loi drift</i>	
TCD	Transient Concept Drift — Drift tm thi (sudden, blip, recurrent)
PCD	Progressive Concept Drift — Drift tin trin (gradual, incremental)
<i>c trng vị ch s</i>	
FWHM	Full Width at Half Maximum — rng nh tỉ na chiu cao
WR	Width Ratio — T s rng nh ($FWHM/2l_1$)
SNR	Signal-to-Noise Ratio — T s tồn h iu trở nh iu
CV	Coefficient of Variation — H s bin thiổn

Vit tt	Gii ngha
PPR	Peak Proximity Ratio — T s khong còch gia hai nh
DPAR	Dual-Peak Amplitude Ratio — T s biổn hai nh
LTS	Linear Trend Strength — mnh xu hng tuyn tồnh (R^2)
SDS	Step Detection Score — im phòt hin bc nhy
MS	Monotonicity Score — im n iu
VR	Variance Ratio — T s phng sai trổn d liu thũ (Mc 4.3)
EDR	Event Detection Rate — T l phòt hin s kin
MDR	Miss Detection Rate — T l b sút ($1 - \text{EDR}$)
FP	False Positive — Bòo ng gi
CAT	Category Accuracy — chồnh xòc phón nhúm (TCD/PCD)
SUB	Subcategory Accuracy — chồnh xòc phón tiu loi
<i>Toàn hc vị thng kổ</i>	
RKHS	Reproducing Kernel Hilbert Space — Khũng gian Hilbert ht nhón tòi to
RBF	Radial Basis Function — Hịm c s hng tóm (Gaussian kernel)
HSIC	Hilbert-Schmidt Independence Criterion — Tiổu chồ c lp Hilbert-Schmidt
i.i.d.	Independent and identically distributed — c lp cúng phón phi
<i>H thng vị h tng</i>	
IoT	Internet of Things — Mng li vn vt kt ni

DANH MỤC KÝ HIỆU TOÀN HC

$P(X, Y)$	Phón phi xóc sut ng thi ca c trng vị nhõn
$P(X)$	Phón phi xóc sut l ca c trng u vị
$P(Y X)$	Phón phi xóc sut cú iu kin ca nhõn
$\sigma(t)$	Tõn hiu ln trũi dt (drift magnitude signal)
$h_l(t)$	Hịm hõnh dng tam giõc c trng ca ShapeDD
l_1	Kõch thc ca s tham chiu
l_2	Kõch thc ca s kim tra
s	Bc trt ca ca s
δ	tr chp nhn khi i sõnh vị ground truth
α	Mc ý ngha thng kỏ
γ	Tham s bng thũng ca kernel
ϵ	Hng s n nh s hc
σ_g	lch chun ca b lc Gauss lịm mt tõn hiu
N_{perm}	S vùng hoàn v trong permutation test
VR	Variance Ratio — t s phng sai trõn d liu thũ
$\tau_{\text{VR}}^+, \tau_{\text{VR}}^-$	Ngng trõn/di ca Variance Ratio
τ_{WR}	Ngng Peak Width Ratio (WR)
τ_{SNR}	Ngng Signal-to-Noise Ratio (SNR)
τ_{CV}	Ngng Periodicity CV
τ_{match}	Ngng so khp ca Concept Memory
M, n_s	S snapshot vị kỡch thc mi snapshot trong Concept Memory

CHNG 1

GII THIU T

1.1 Thc trng chung

Mt mũ hnh hc mỳ t chõnh xõc cao khi va trin khai vn cú th suy gim dn sau mt thi gian vn hnh, dũ thut toõn vỹ quy trõnh hun luyõn khũng cú gõ sai. Hnh tng nỹ õ c ghi nhõn trong nhiu min ng dng cũng nghiõp: cõc mũ hnh cht lng vỹ bo trõ d oõn mt dn tin cy khi thit b lõo hoõ, quy trõnh c iu chnh hoc iu kin mũ trng thay i theo mĩa [1–3]. óy khũng phi li ca thut toõn hay ca k s xõy dng mũ hnh, mĩ lĩ hnh tng *trũi dt khõì nim* (concept drift): phõn phi d liu thc t thay i theo thi gian trong khi mũ hnh vn “ng yõn” [4].

V mt toõn hc, concept drift xy ra khi $P_{train}(X, Y) \neq P_{online,t}(X, Y)$, trong ú P_{train} vỹ $P_{online,t}$ ln lt lĩ phõn phi ng thi ca d liu u vỹ vỹ nhõn trong giai õn hun luyõn vỹ vn hnh ti thi im t [4]. Concept drift cú th xut hnh dĩ nhiu dng: *sudden drift*, *gradual drift*, *incremental drift*, vỹ *recurrent drift* [5].

Cõc mũ hnh hc mỳ c hun luyõn vỹ gi nh d liu trong tng lai s tuõn theo cũng phõn phi vỹ d liu hun luyõn (gi nh IID). Tuy nhiõn, mũ trng sn xut cũng nghiõp him khi tnh: thit b lõo hĩa, quy trõnh thay i, cm bin xung cp, hnh vỹ ngĩ dũng bin i [4]. Kt qu lĩ hĩu sut mũ hnh suy gim dn theo thi gian, õi khi t ngĩ, lĩm gim tin cy h thng vỹ tng chi phõ vn hnh. x lý, cn cú c ch (1) phõt hnh drift cĩng sm cĩng tt, vỹ (2) thờch ng mũ hnh theo cõc iu kin mĩ.

1.2 Tng quan v bĩi toõn

Concept drift cú th xut hnh hai thĩnh phõ ca phõn phi liõn hp $P(X, y) = P(X) \times P(y|X)$. Lun vn tp trung vỹ hng khũng giõm sõt, tc lĩ theo dĩĩ s thay i ca $P(X)$ khi nhõn cha cú sn. Phm vỹ nỹ phũ hp vỹ nhiu h thng cũng nghiõp, ni nhõn thng n mun hoc tn chi phõ kim chng.

Một vấn đề xuyên suốt là **giò m sò t cht lng sn xut** (Manufacturing Quality Control / Process Monitoring), nì drift thng liỏn quan n thay i ca quy trỏnh, mủi trng hoc cm bin [4, 6]. Cm bin trỏn dóy chuyỏn liỏn tc sinh lung c trng X_t nh nhit , ỏp sut, rung ng, m, dừng in hoc c trng nh. Mủ hỏnh sn xut chỏnh d oỏn li, cht lng sn phỏm hoc nhu cu bo trỏ t lung nỳ; SE-CDT khủng thay th mủ hỏnh ú. SE-CDT ng nh mt tng giò m sò t trc b thờch ng: nú theo dủi $P(X)$, phỏt hỏn vị phỏn loi drift, sau ú phỏt s kin cho Adaptation Manager quyỏt nh cú cp nht mủ hỏnh sn xut hay khủng.

Trong cỏc ng dng hc mỳy trỏn d liu lung, h thng giò m sò t khủng ch cn phỏt hỏn thi im drift. Nu bit thỏm dng drift, h thng cú th chn cỏch cp nht mủ hỏnh phứ hp hn: hun luyỏn li nhanh khi thay i t ngỏt, cp nht mm khi thay i đn, dứng li mủ hỏnh c khi khỏi nim lp li, hoc b qua cỏc nhieu ngỏn hn.

tỳi xỏy dng h thng SE-CDT (ShapeDD-Enhanced Concept Drift Type) — mt h thng tỏch hp phỏt hỏn, phỏn loi vị thờch ng vị concept drift trỏn nn tng ShapeDD [7]. Module phỏt hỏn ca SE-CDT (ShapeDD-IDW) dứng IDW-MMD vị xp x Gamma kim nh ng viỏn drift, ci thỏn tc so vị permutation test gc; module phỏn loi c hỏnh dng tỏn hieu MMD xỏc nh loi drift mỳi khủng cn nhỏn.

1.3 Mỏc tiỏu tỳi

Lun vn hng ti bn mỏc tiỏu chỏnh. Trc ht, tỳi kho sò t cỏc nhúm phng phỏp phỏt hỏn drift hỏn cú, t kim nh thng kỏ, theo dủi hieu nng mủ hỏnh n cỏc phng phỏp c tp trung nh MMD vị ShapeDD. T ú, lun vn xut ci tin ShapeDD bng IDW-MMD nhm gim chi phỏr kim nh vị kim sỏt bỏo ng gỳ tt hn trong mủi trng ca s trt.

Mỏc tiỏu tip theo lỳi xỏy dng SE-CDT, mt b phỏt hỏn vị phỏn loi loi drift khủng cn nhỏn, lỳ cm hng t CDT-MSW [8] nhng thay vớ da trỏn tỏn hieu t l chỏnh xỏc (accuracy ratio) bng c trng hỏnh hc ca tỏn hieu MMD. Kt qu phỏn loi nỳ t ú c dứng cho phn tip theo, nì chin lc cp nht mủ hỏnh c chn theo loi drift ỏ nhn đin. Cui cứng, lun vn ỏnh giò thut toỏn trỏn cỏc tp d liu cú ground truth vị kim th nguyỏn mu h thng trỏn Kafka. Vic trin khai trong mủi trng sn xut vị ỏnh giò chu ti quy mủ ln nm ngoỳi phm vị hỏn ti.

1.4 Phm vị tỳi vị i tng nghiỏn cu

1.4.1 Phm vị tỳi

Trong mủi trng sn xut cũng nghip, nhỏn tht (y) thng khủng cú sn trong thi gian thc do chi phỏr vị thi gian kim nh cht lng cao [4]. Vớ vy nghiỏn cu tp trung vớo phỏt hỏn concept drift theo hng **khủng giò m sò t** (unsupervised), c th lỳ phỏt hỏn s thay i trong

phân phối dữ liệu vào $P(X)$ (cùng với covariate shift hoặc data drift), đã trở nên joint drift. Phê phán sự thay đổi trong $P(X)$ đóng vai trò tồn tại cân bằng, hệ thống kích hoạt các cơ chế kiểm tra học tập mới mô hình khi cần. Luận văn tập trung phân tích một hệ thống kết hợp các thành phần sau:

- Nghiên cứu vị trí phân phối ShapeDD phân tích concept drift không giám sát, so sánh với các phương pháp truyền thống.
- Đồng bộ hóa năng suất của các tập dữ liệu tổng hợp vị trí các kịch bản drift khác nhau.
- Xây dựng các chiến lược thích ứng mô hình tổng hợp vị trí lỗi drift có phân tích.
- Tự động tham số các phương pháp mô hình hóa dựa trên vị trí các kiểu dữ liệu vị trí phân tích khác nhau.
- Thiết kế vị trí khai thác trực tuyến dữ liệu luồng thời gian thực trên Apache Kafka theo mô hình event-driven, cấu hình năng suất.

Hệ thống thiết kế vị trí đồng bộ hóa nhiều loại drift (sudden, gradual, incremental, recurrent, blip). Các đồng bộ hóa hệ thống như sau:

1. **Đồng bộ hóa kịch bản:** Thực nghiệm trên nhiều kịch bản drift khác nhau, mỗi kịch bản chỉ có lặp nhiều lần cấu trúc phân tích.
2. **Phân tích tổng hợp:** Đồng bộ hóa các kịch bản phân tích lần lượt phân tích, bao gồm phân tích theo nhóm chờ đợi vị trí theo tổng hợp các thành phần.
3. **Chỉ số vị trí phân phối CDT-MSW:** Đánh giá sự khác biệt của CDT-MSW có giám sát mô hình dung lượng không có gia hạn hai cách tiếp cận. Đây không phải so sánh trực tiếp trên cùng một benchmark; sẽ khác biệt về dữ liệu vị trí mà giám sát có thể luận chỉ tiêu Mục 5.3.4.

1.4.2 Các thí nghiệm

Các thí nghiệm của luận văn gồm:

- **Phương pháp phân tích drift:** Phương pháp ShapeDD vị trí phân tích của phân tích ShapeDD-IDW, vị trí các phương pháp so sánh gồm MMD, KS-Test, D3, DAWIDD.
- **Hệ thống phân tích vị trí phân tích drift:** SE-CDT, hệ thống tích hợp trong đó module phân tích (ShapeDD-IDW) xác định vị trí drift vị trí module phân tích xác định lỗi drift tích hợp dung lượng tồn tại MMD, lý do tổng hợp CDT-MSW.
- **Năng suất xử lý streaming:** Apache Kafka cho vị trí khai thác hệ thống giám sát *real-time*.

1.5 Cu trúc lun vn

Lun vn c t chc thịnh nm chng chờnh:

- **Chng 2 — C s lý thuyt:** Trờnh bỳ nn tng toàn hc v concept drift, Maximum Mean Discrepancy (MMD), vị phng phòp ShapeDD.
- **Chng 3 — Tng quan nghiỏn cu liỏn quan:** Kho sỏt còc phng phòp phòt hin drift hin cú, t thng kỏ c in n hc sỏu, cừng vị phng phòp phỏn loi drift CDT-MSW.
- **Chng 4 — Mũ hỏnh xut:** Trờnh bỳ chi tit h thng SE-CDT: module phòt hin ShapeDD-IDW (IDW-MMD + xp x Gamma), module phỏn loi drift khỏng giỏm sỏt, khung thờch ng mũ hỏnh, vị kin trức trỏn Apache Kafka.
- **Chng 5 — Thc nghiỏm vị ònh giỏ:** ònh giỏ cú h thng ba module (phòt hin, phỏn loi, thờch ng) trỏn 14 tp d liu vị 30 ln chy c lp.
- **Chng 6 — Kt lun vị hng phòt trin:** Tng kt úng gúp, phỏn tỏch hn ch, vị xut còc hng nghiỏn cu tip theo.

CHNG 2

C S LÝ THUYT

Tóm tt: Chng nỳ trnh bày nn tng lý thuyết phc v cho phng phòp xut. Chng bt u vì nh ngha vị phón loi concept drift, tip theo lý thuyết Maximum Mean Discrepancy (MMD), vị kt thức bng c ch hot ng ca ShapeDD – phng phòp c chn lỳm c s phòt trin cho lun vn.

2.1 Khòì nìm v concept drift vị phón loi

2.1.1 Khòì nìm v Concept Drift

Concept drift (trũi dt khòì nìm) cp n nhng s thay i khũng th d oòn trc trong phón phi thng kỏ ca d liu theo thi gian [9]. Hìn tng nỳ c bit ph bin trong còc mũi trng vn hình liỏn tc vị nng ng nh h thng IoT [10] hay còc quy trnh cũng nghip, nì mũi trng thu thp d liu luũn bin ng.

V mt toòn hc, concept drift c nh ngha lỳ s thay i ca phón phi xỏc sut liỏn hp (joint probability distribution) gia d liu u vộo X vị nhỏn mc tiỏu y ti hai thi im khỏc nhau t vị $t + 1$. Ngha lỳ:

$$P_t(X, y) \neq P_{t+1}(X, y) \quad (2.1)$$

Trong mũi trng thc t, s thay i nỳ lỳm cho còc mũi hỏnh hc mỳy c hun lỳn trỏn d liu lch s tr nỏn lỳ thi, dn n s suy gim nghiỏm trng v hieu sut d oòn so vì khi c ònh giò trỏn tp th nghim tn.

2.1.2 Phón loi còc dng Concept Drift

Theo quy tc nhón xỏc sut, xỏc sut liỏn hp cú th c phón rỏ thnh $P(X, y) = P(X) \times P(y|X)$. Da vộo s thay i ca còc thnh phn nỳ, concept drift c chia thnh còc nhúm chỏnh nh sau [11]:

Phón loi theo s thay i phón phi

- **S trũi dt o (Virtual Drift / Covariate Shift):** cp n tnh hung phón phi ca còc c trng u vjo $P(X)$ thay i, nhng xòc sut hu nghim ca lp mc tiõu $P(y|X)$ (tc lị ranh gii quy t nh) vn khũng i [12]. Dũ d liu u vjo bin i, mũ hnh cú th khũng b gim hieu sut nghiõm trng nu ranh gii quy t nh vn bao quò c.
- **S trũi dt thc (Real Concept Drift):** Lị s thay i trc tip trong xòc sut hu nghim $P(y|X)$. S thay i nịy lịm sai lch ranh gii quy t nh ban u vj bt buc phi cp nht lị mũ hnh hc mỳy. Vở d in hnh lị s thay i trong s thờch ca ngi dũng i vj còc ch tin tc: cũng mt c trng ngi dũng X , nhng hnh vj click y õ thay i [13].

Hai thnh phn $P(X)$ vj $P(y|X)$ trở lị thuyt cú th thay i c lp, nhng trong nhieu ng dng thc t chũng thng thay i ng thi (gi lị gi nh **joint drift**) [14]. Lun vn dũng gi nh nịy nh c s phòt hìn drift theo hng khũng giõm sòt: khi quan sòt $P(X)$ thay i òng k, h thng coi ú lị tồn hieu cnh bõo cú kh nng $P(y|X)$ cng ang lch. Trng hp ngoi l (ch $P(y|X)$ thay i mị $P(X)$ gi nguỷn) nm ngoi phm vj quan sòt ca phng phòp vj c xòc nhn trở còc tp i chng Mc 5.2.

Phón loi theo tc vj mũ hnh thay i


- **S trũi dt t ng t (Abrupt / Sudden Drift):** Phón phi d liu c thay th bng mt phón phi hoịn toịn mị gn nh ngay lp tc tị mt thi im t . Loi nịy d phòt hìn nhng ùi hi c ch thờch ng cc nhanh (vở d: cm bin hng hoc i dch COVID-19 bũng phòt) [15].
- **S trũi dt tim tin (Gradual Drift):** Quò trnh chuyn i ãin ra qua mt giai on xen k. Trong giai on nịy, d liu t c khòì nim c vj khòì nim mị cũng xut hìn, nhng xòc sut xut hìn ca khòì nim mị tng ãn lỏn cho n khi thay th hoịn toịn khòì nim c [13].
- **S trũi dt tng ãn (Incremental Drift):** Khòì nim c tin húa thnh khòì nim mị thũng qua mt chui còc khòì nim trung gian (intermediate concepts). S thay i ãin ra lỏn tc, n iu vj biỏn nh, vở d nh hieu sut ca cm bin gim ãn theo thi gian do hao mỳn vt lị [11].
- **S trũi dt lp lị (Recurrent Drift):** Xy ra khi mt khòì nim c õ tng bin mt nay xut hìn tr lị sau mt khong thi gian khũng xòc nh (vở d: thúi quen mua sm thay i theo mứa hoc chu k kinh t) [11].


Mi dng thay i gị y mt còch thờch ng khòc nhau cho mũ hnh sn xut. Bng 2.1 khũng phi lị lut cng, mị lị ònh x vn hnh thng dũng khi kt hp phòt hìn drift vj cp nht mũ hnh [13, 14, 16].

Bng 2.1 Liển h gia loi thay i d liu vị chin lc thờch ng mĩ hnh

Loi thay i	Tồn hiu thng gp	Chin lc phứ hp
Sudden	Mt bc nhy rủ, phón phi mi thay th nhanh phón phi c	Reset hoc retrain nhanh trởc ca s mi
Gradual	Giai on chuyt tip cú d liu c vị mi cũg xut hin	Cp nht theo trng s thi gian, u tiổ mu gn óy
Incremental	Trung bnh/ranh gii dch chuyt liổn tc qua nhiu bc nh	Warm-start hoc online update trờnh hc li t u
Recurrent	Phón phi tng gp quay li theo chu k hoc bi cnh	Concept/model cache, chn li mĩ hnh ỏ lu
Blip	Xung ngn hn ri quay v phón phi c	B qua hoc cp nht ti thiũ trờnh quổn nhm

La chn chin lc cùn ph thuc vị chi phờ vn hnh: nu false alarm rt t (vờ d retrain mĩ hnh ln hoc dng dóy chuyt), ngng phòt hin nỏn cht hn vị cn c ch xỏc nhn. Nu b sút drift góy ri ro cht lng hoc an toỏn cao, h thng nỏn u tiổ recall, chp nhn nhiu cnh bởo hn vị cú human approval trc khi thay th mĩ hnh trong min ri ro cao. tr nhỏn cũg quan trng: khi nhỏn n mun, tng giỏm sỏt $P(X)$ nh SE-CDT ch nỏn c xem li tồn hiu sm, cũn quyt nh cp nht cui cũg cú th kt hp thỏm nhỏn khi nhỏn xut hin.

**Hnh 2.1** Phón loi da trởc s thay i phón phi: Virtual Drift (ch $P(X)$ i) vị Real Drift ($P(Y|X)$ i).



Hình 2.2 Phấn loi đa trở t: thay i: Sudden (t ng), Gradual (dn dn), Incremental (tng dn) và Recurrent (lp li). Trc ngang biu din thi gian, trc dc biu din phn phi d liu.

2.1.3 nh hng ca concept drift

Concept drift cú th nh hng ln n hieu sut ca mĩ hnh d oàn, c bit li khi mĩ hnh hc t d liu ò lóu trong quò kh. Mt lot còc dch v/ng dng trong bi cnh h thng v i mng trun thng cú th b cn tr bi concept drift nh [10]:

- **H thng phòt hin xóm nhp (IDS):** Còc mu tn cũng mng lión t: thay i, ùi hi IDS phi thờch ng vì còc mi e da mi
- **H thng phn loi v i d oàn lu lng:** Mu lu lng mng thay i theo thi gian, nh hng n chònh xòc d oàn
- **Industrial IoT (IIoT):** c bit trong còc k thut bo trò da trở tnh trng (Condition-Based Maintenance - CBM) c s dng d oàn còc iu kin bt thng v i thi gian bo trò thng qua phn tồch d liu IIoT [2]
- **Thịnh ph thng minh:** D liu c thu thp cho nhieu mc òch nh m bo an ninh mng, d oàn ùi nhim khũng khò, d oàn giao thng ng b v i d bòa ti in

Phn phi d liu cú th thay i theo thi gian do mòi míc lỏo hóa, do quy trnh bo trò, hoc do còc yu t mĩi trng thay i. Mt k thut CBM khũng cú kh nng x lý concept drift s hot ng kổm trong còc iu kin n i [2], kổ theo tin cy v i chònh xòc ca vic phn tồch d liu cng b nh hng [3].

Vò v y, mĩ hnh d oàn cn cú c ch phòt hin v i t thờch ng vì concept drift g i hieu sut n nh. Vic thờch ng cú th li cp nht trở d liu mi, iu chnh tham s v i cu trũc, hoc thay th ho ien to ien mĩ hnh c tũy theo loi drift xy ra [13, 14].

2.2 ShapeDD - Phng phòp phòt hin trũi dt đa trỏn hnh đng vị kh nhiu tòn hũu

2.2.1 Gũi thiũ

Trong hc mỳy c in, d liũ thng c gi nh lĩ c lp vị phỏn phi ng nht (IID, Independent and identically distributed) theo mt phỏn phi tnh P_X . Trong còc ng đng thc t nh lung d liũ t mng xũ hi, thit b IoT hay cm bin, phỏn phi d liũ thng thay i theo thi gian.

Còc phng phòp **khũng giòm sỏt (unsupervised)** cho bũi toỏn phòt hin drift thng đa trỏn vic o *khỏc bit* gia hai phỏn phi d liũ trong hai ca s thi gian liỏn tip. Do s lng mu trong mĩ ca s thng nh, còc phỏp o nũy d b **nhiũ**, khĩn vic phỏn bit gia thay i tht vị dao ng ngu nhiỏn tr nỏn khũ khĩn.

ShapeDD (Shape-Based Drift Detection) c xũt x lý vn nũy, bng còch khai thỏc c trng hnh hc ca tòn hũu trũi dt. Phng phòp c bit hũu qu vị **drift t ngũt (abrupt drift)**.

2.2.2 Quy c kỳ hũu

Trc khi i vớo chỉ tit, phn nũy thng nht còc kỳ hũu c s đng trong chng:

Bng 2.2 Bng kỳ hũu thng nht

Kỹ hũu	Ý nghĩa	Giỏ tr mc nh
l, l_1, l_2	Kỏch thc ca s	$l_1 = 50, l_2 = 150$
P, Q	Hai phỏn phi xỏc sut	–
D_t	Phỏn phi ti thi im t	–
$\sigma(t)$	Drift magnitude signal	–
$h_l(t)$	Hnh đng tam giỏc c trng	–
γ	Kernel bandwidth (RBF), $k(x, y) = e^{-\gamma\ x-y\ ^2}$	median heuristic
$k(x, y)$	Kernel function	Gaussian RBF

Quy c kỳ hũu: Lun vn đũng $\sigma(t)$ (hoc $\sigma_{d,l}$) cho drift magnitude signal, vị γ cho kernel bandwidth ca RBF kernel. Trong còc phn lý thuyt trỏch t bũi bỏo gc, σ_k hoc σ vị subscript vn c gi nguỹỏn vị cú th hũu lĩ γ .

2.2.3 C s lý thuyt

i lng ln trũi dt (σ)

Xỏt lung d liũ mĩ phỏn phi sinh d liũ ti thi im t c kỳ hũu lĩ D_t . Khi xy ra trũi dt, $D_t \neq D_s$ vị mt s $s < t$. ShapeDD nh nghĩa i lng **ln trũi dt** σ nh lĩ o s khỏc bit gia hai phỏn phi quan sỏt c trong hai ca s thi gian lỏn cn.

Vì hai case $W_l(t) = [t - \frac{l}{2}, t + \frac{l}{2}]$ và $W_l(s) = [s - \frac{l}{2}, s + \frac{l}{2}]$, nên nghĩa:

$$\sigma_{d,l}(s, t) = d(P_{W_l(s)}, P_{W_l(t)}), \quad (2.2)$$

trong đó $P_{W_l(t)}$ là phân phối trung bình trơn của $W_l(t)$ và $d(\cdot, \cdot)$ là khoảng cách (ví dụ: MMD, Wasserstein, KL, v.v.).

Hình dạng trung của drift tổng

Kết quả lý thuyết trung tâm của ShapeDD có thể biểu diễn như sau: Cho luồng dữ liệu với phân phối p_t thay đổi theo thời gian từ $t = 0$ từ phân phối P sang phân phối Q . Giả sử dạng của sự trôi dạt có kích thước l và khoảng cách $\|\cdot\|$ thỏa mãn các điều kiện metric tiêu chuẩn. Khi đó, tồn tại hàm trơn để phân tích thành:

$$\sigma_{\|\cdot\|, l, p'}(t) = \underbrace{\|P - Q\|}_{\text{mức drift}} \cdot \underbrace{h_l(t)}_{\text{hình dạng drift}}, \quad (2.3)$$

trong đó hàm hình dạng $h_l(t)$ có nghĩa là:

$$h_l(t) = \max\left(0, 1 - \frac{|t|}{l}\right). \quad (2.4)$$

Hàm $h_l(t)$ có dạng tam giác có đỉnh không $[-l, l]$, tức là $h_l(0) = 1$ thì xảy ra drift ($t = 0$), và suy giảm tuyến tính về hai phía cho đến khi đạt giá trị nhỏ nhất $t = \pm l$. Các trường hợp này không phụ thuộc vào dạng phân phối hay khoảng cách sử dụng, miễn chỉ cần thỏa mãn $\|P - Q\|$. Ý nghĩa của ShapeDD có thể áp dụng cho nhiều mô hình dữ liệu khác nhau mà không cần thay đổi kernel hay metric.

Tuy nhiên, Triangle Shape Property (2.2.3) chỉ ứng trực tiếp cho sudden drift do tính chất tam giác của nó. Các loại drift khác (gradual, incremental, recurrent) không tạo ra hình dạng tam giác trung tâm, ý nghĩa thiết kế của ShapeDD tập trung vào mô hình abrupt drift, tuy nhiên có thể mở rộng nhận biết các loại drift khác bằng cách phân tích hình dạng tồn tại dữ liệu:

- Gradual drift to peak rộng vì slope thoải hơn.
- Incremental drift có thể tạo chuỗi nhiều peak nhỏ liên tiếp.
- Recurrent drift tạo chuỗi peak lặp lại theo chu kỳ.

Do đó, phương pháp SE-CDT (Chương 4) bổ sung các trường hợp hình học vị thế khác nhau tồn tại MMD phân loại các loại drift này, thay vì chỉ dựa vào hình dạng tam giác.

Tng quòat hoò cho nhieu s kin drift

Khi tn ti nhieu im trũi dt t ng t i còc thi im $t_1 < t_2 < \dots < t_n$, vị đị ca s l nh còc tam giòc khũng chng lỏn nhau, tng tồn hũ trũi dt c biu din nh:

$$\sigma_{\|\cdot\|,l,p}(t) = \sum_{i=1}^n \|P_{i-1} - P_i\| h_l(t - t_i). \quad (2.5)$$

Nh v y, tồn hũ tng th $\sigma(t)$ cú th xem lĩ tng chp (linear superposition) ca nhieu “hnh tam giòc” trũi dt c lp.

2.2.4 ng dng vộ lc nhieu vị phòt hìn drift

Nhn bit c dng hnh hc ca tồn hũ trũi dt cho phỗp thc hìn c lng tham s (parametric estimation) cho σ . Thay vớ dũng trc tip giò tr c lng nhieu $\hat{\sigma}$, ShapeDD khp mt hịm tham s $\tilde{\sigma}$ cú dng:

$$\tilde{\sigma}(t) = \sum_i a_i h_l(t - t_i), \quad (2.6)$$

trong ú a_i biu din biổn (mnh drift) vị t_i lĩ v trở thi gian ca s kin drift. Do hịm $h_l(t)$ cú cu trũc hnh hc c nh vị ch ph thuc vộ l , vic khp mũ hnh $\tilde{\sigma}$ giữp lc nhieu ngu nhiổn trong $\hat{\sigma}$, xỏc nh chỏnh xỏc hn thi im trũi dt t_i , vị gĩm t l bỏo ng gĩ. Trong thc nghim, quỏ trỏnh khp hịm nũy c thc hìn bng Fast Sequential Function Fitting, òp dng trởn còc tồn hũ thu c t nhieu o (nh MMD) vị còc đị ca s khỏc nhau, nhm to ra c lng cui cũng cú chỏnh xỏc cao.

ShapeDD tip cn bị toỏn phòt hìn concept drift t gúc nhỏn x lý tồn hũ: khi drift t ng t xy ra, ln thay i ca phỏn phi to ra mt tồn hũ cú hnh tam giòc c trng. Nh ú, phng phỏp cú th lc nhieu, c lng thi im drift vị tng tin cy trong còc kch bn abrupt/sudden drift.

2.2.5 Maximum Mean Discrepancy (MMD)

Nh õ nhc n trởn, ShapeDD da trởn Maximum Mean Discrepancy (MMD) [17], mt thc o thng kổ c s dng so sỏnh hai phỏn phi xỏc sut P vị Q . Y tng ct lũi lĩ ònh x d liu t khũng gian gc vộ khũng gian feature nhieu chiu, ni vic so sỏnh tr nỏn nhy cm hn vị s khỏc bit phỏn phi.

MMD o lng khong còch gia hai phỏn phi bng còch tỏm hịm f cú th phỏn bit tt nht gia chũng. Nu hai phỏn phi gĩng nhau, giò tr k vng ca bt k hịm nộ òp dng lỏn chũng s gĩng nhau. Ngc li, nu khỏc nhau, s tn ti mt hịm cho phỗp phỏn bit rũ rịng.

MMD c nh nghĩa chõnh thc nh:

$$\text{MMD}(P, Q) = \sup_{f \in \mathcal{F}} |\mathbb{E}_{X \sim P}[f(X)] - \mathbb{E}_{Y \sim Q}[f(Y)]| \quad (2.7)$$

trong ú:

- P v Q l hai phõn phi c n c so sõnh
- $X \sim P$ i din cho bin ngu nhiõn c ly mu t phõn phi P
- $Y \sim Q$ i din cho bin ngu nhiõn c ly mu t phõn phi Q
- $\mathcal{F}$ l mt lp hõm f sao cho $\|f\|_{\mathcal{H}} \leq 1$ trong Reproducing Kernel Hilbert Space (RKHS) [18]
- sup biu th giò tr ln nht cú th (supremum)

Trong khõng gian ban u, hai phõn phi cú th khú phõn bit. Bng cõch ònh x v i RKHS thõng qua hõm kernel [18], cõc cu trũc phc tp ca phõn phi tr nõn rũ rìng hn. MMD o lng khõng cõch gia “trung bõnh” (mean embedding) ca hai phõn phi trong khõng gian n i y.

Vic tõm giò tr ln nht trõn $\mathcal{F}$ l khõng kh thi v mt tõnh toõn, do ú MMD thng c trin khai trong RKHS [18] s dng kernel trick v hõm kernel $k(x, y)$:

$$k(x, y) = \langle \phi(x), \phi(y) \rangle_{\mathcal{H}} \quad (2.8)$$

Trong ú $\phi(x)$ ònh x im x v i RKHS $\mathcal{H}$ v $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ l phõp nhõn vũ hng (inner product) trong $\mathcal{H}$. Gaussian RBF kernel c s dng rng rõi do tõnh cht universal (cú th xp x bt k hõm liõn tc n i o):

$$k(x, y) = \exp(-\gamma \|x - y\|^2), \quad \gamma = \frac{1}{2\sigma_k^2} \quad (2.9)$$

Tham s γ (bandwidth, kỳ h iu thng nht v Bng 2.2) iu kh i nh y: giò tr ln tp trung v i khõc bit cc b, giò tr nh nm bt cu trũc to i n cc. cõc phn sau, $\sigma(t)$ luõn ch tõn h iu drift magnitude theo thi gian, khõng phi bandwidth ca kernel. Khi ú, MMD bõnh phng trong RKHS tr th i nh:

$$\text{MMD}^2(P, Q) = \mathbb{E}_{X, X' \sim P}[k(X, X')] + \mathbb{E}_{Y, Y' \sim Q}[k(Y, Y')] - 2\mathbb{E}_{X \sim P, Y \sim Q}[k(X, Y)] \quad (2.10)$$

Trong ú:

- $\mathbb{E}_{X, X' \sim P}[k(X, X')]$ - tng ng trung bõnh gia cõc im trong phõn phi P

- $\mathbb{E}_{Y, Y' \sim Q}[k(Y, Y')]$ - tng ng trung bình gia còc im trong phón phi Q
- $-2\mathbb{E}_{X \sim P, Y \sim Q}[k(X, Y)]$ - tng ng chổo gia hai phón phi (cú du óm)

Nu $P = Q$, ba thnh phn nìy cón bng nhau vị $\text{MMD}^2 = 0$. Nu $P \neq Q$, s khòc bit trong cu trũc nì b vị tng tòc chổo dn n $\text{MMD}^2 > 0$.

2.2.6 Còch thc hot ng ca ShapeDD

Còc phng phòp phòt hin drift c bn s c trnh bìy chỉ tit Chng 3. cú ng cnh cho ShapeDD, phn nìy túm tt ngn gn còc c im chònh ca còc phng phòp ph bin:

Còc phng phòp đa trổn hìu sut mũ hnh nh DDM, EDDM, MDDM, FHDDMS theo dũi thng kổ li ca mũ hnh vị phòt hin drift khi hìu sut gim òng k. Còc phng phòp nìy ph thuc vò nhõn ground truth vị cú th b tr vớ cn thu thp li.

ADWIN i din cho nhúm ca s thòch ng: thut toòn iu chnh ng kòch thc ca s đa trổn s thay i c quan sòt, t cón bng gia nhỹ vị n nh vì m bo lý thuyt $O(\log W)$ v b nh [19].

DAWIDD phòt hin drift bng còch o s ph thuc gia c trng vị thi gian, cho phỗp phòt hin sm mị khũng cn nhõn.

So vì còc phng phòp nìy, ShapeDD mang li gúc nhơn khòc bit bng còch s dng Maximum Mean Discrepancy (MMD) so sònh trc tip phón phi d liu trong khũng gian kernel, kt hp vì k thut phòt hin hnh dng (shape detection) gim nhiu vị tng chònh xòc nh v drift. ShapeDD hot ng theo bn giai on chònh nh sau [7]:

Giai on 1: Thu thp d liu (Data Collection)

Giai on u tiổn bao gm thu thp d liu s dng k thut ca s trt. ShapeDD s dng chin lc ca s ùi (double window) vì kòch thc $2l_1$ so sònh hai on d liu liổn tip:

- **Ca s tham chiu:** l_1 im d liu u tiổn $[t - 2l_1 + 1, t - l_1]$
- **Ca s hìn ti:** l_1 im d liu tip theo $[t - l_1 + 1, t]$

i vì lung d liu $\mathcal{S} = \{x_1, x_2, \dots, x_n\}$, ca s trt W_t cú kòch thc tng cng $2l_1$ c duy trớ ti thi im t :

$$W_t = \{x_{t-2l_1+1}, x_{t-2l_1+2}, \dots, x_t\} \quad (2.11)$$

Kòch thc ca s l_1 lị tham s quan trng nht ca ShapeDD. Ca s nh nhỹ vì drift nhanh nhng d b nhiu; ca s ln n nh hn nhng phòt hin tr. Khi cn iu chnh t ng, cú th t l_1 t l vì dị lung.

Lu ý v cu hnh ca s i xng vị khũng i xng. Còch trnh bìy trổn dũng ca s ùi i xng (l_1 mu cho mị na, tng $2l_1$) vớ óy lị dng n gin nht suy ra tòngh cht hnh tam giòc: khi hai

na cú cứng kờch thc, tòn hiu MMD tng vị gim cón i quanh im drift. Tuy nhiên, phn trin khai vị toin b thc nghim ca lun vn đứng cu hnh *khũng i xng* vì ca s tham chiu $l_1 = 50$ vị ca s kim tra $l_2 = 150$ (Chng 5 vị Ph lc A.1). Ca s kim tra đị hn cho c lng phón phi mi n nh hn, i li hnh tam gióc b lch (sn lỏn dc hn sn xung) thay vớ cón i. Tờnh cht nh v nh vn c gi, nõn còc suy lun v hnh dng còc mc sau vn òp dng c; ch cn hiu l trong còc cũg thc lý thuyt lị kờch thc na ca s tham chiu l_1 .

Giai on 2: Xóy dng feature (Feature Construction)

Trong giai on nỳ, ma trn tng ng (similarity matrix) c xóy dng s dng hịm kernel nm bt mi quan h gia còc im d liu. Gaussian RBF kernel thng c s dng vì cũg quy c γ nh Bng 2.2:

$$k(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (2.12)$$

Iu nỳ to ra ma trn kernel i xng $K \in \mathbb{R}^{2l_1 \times 2l_1}$ trong ú $K_{ij} = k(x_i, x_j)$ biu th s tng ng gia còc im d liu x_i vị x_j .

Bandwidth γ cú th c chn t ng bng median heuristic:

$$\gamma = \frac{1}{2 \text{median}(\{\|x_i - x_j\| : i, j \in W_t, i \neq j\})^2} \quad (2.13)$$

Phng phòp nỳ m bo kernel thờch nghi vị scale ca d liu.

Ma trn kernel cú th c cp nht tng dn khi ca s trt:

- Tờnh toàn y : $O(l_1^2)$ cho mi ca s
- Cp nht tng dn: Ch cn tờnh $O(l_1)$ phn t mi khi thỏm im d liu

Giai on 3: Tờnh toàn s khòc bit (Difference Computation)

Ct lủi ca ShapeDD bao gm tờnh toàn s khòc bit thng kổ gia hai na ca ca s trt s dng MMD cú trng s. Hịm trng s $w(t)$ c nh ngha to ra trng s tng phn (+1 vị -1) cho hai na ca ca s:

$$w(t) = \begin{cases} +\frac{1}{l_1} & \text{nu } t \in [1, l_1] \quad (\text{ca s tham chiu}) \\ -\frac{1}{l_1} & \text{nu } t \in [l_1 + 1, 2l_1] \quad (\text{ca s hìn ti}) \end{cases} \quad (2.14)$$

Thng kố MMD cú trng s sau ú c tồnh nh:

$$\text{MMD}_t^2 = \sum_{i,j=1}^{2l_1} w_i w_j K_{ij} \quad (2.15)$$

Khai trin cũng thc trỏn:

$$\begin{aligned} \text{MMD}_t^2 &= \frac{1}{l_1^2} \sum_{i,j=1}^{l_1} K_{ij} \quad (\text{tng ng trong ca s tham chiu}) \\ &+ \frac{1}{l_1^2} \sum_{i,j=l_1+1}^{2l_1} K_{ij} \quad (\text{tng ng trong ca s hin ti}) \\ &- \frac{2}{l_1^2} \sum_{i=1}^{l_1} \sum_{j=l_1+1}^{2l_1} K_{ij} \quad (\text{tng ng chỏo}) \end{aligned} \quad (2.16)$$

óy chỏnh lị cũng thc MMD gia hai phón phi c nh ngha bi hai na ca s. Tồnh toỏn nỳ c thc hin trỏn toỏn b lung d liu s dng phng phỏp ca s trt, to ra chui thi gian cỏc giỏ tr MMD: $\{\text{MMD}_1^2, \text{MMD}_2^2, \dots, \text{MMD}_T^2\}$.

Khi drift xy ra ti thi im t_d , chui MMD cú din bin nh sau:

- Trc drift ($t < t_d - l_1$): C hai na ca s u t phón phi c $\Rightarrow \text{MMD}_t^2 \approx 0$
- Ti drift ($t_d - l_1 \leq t \leq t_d$): Ca s tham chiu t phón phi c, ca s hin ti t phón phi mi $\Rightarrow \text{MMD}_t^2$ tng mnh
- Sau drift ($t > t_d + l_1$): C hai na u t phón phi mi $\Rightarrow \text{MMD}_t^2 \approx 0$

Iu nỳ to ra hỏnh dng tam giỏc (triangular shape) c trng trong chui MMD ti v trỏ drift.

Giai on 4: Xỏc thc thng kố (Statistical Validation)

Giai on cui cúg bao gm hai bc: phỏt hin hỏnh dng (shape detection) v i xỏc thc thng kố.

phỏt hin hỏnh dng tam giỏc, ShapeDD s dng b lc convolution h'_l c thit k nh y v i biỏn tng-gim:

$$h'_l(t) = \begin{cases} +1 & \text{nu } t \in [0, l] \\ -1 & \text{nu } t \in (l, 2l] \end{cases} \quad (2.17)$$

Tồn hieu shape c tòngh bng convolution:

$$\text{shape}_t = (h'_l * \text{MMD}^2)(t) = \sum_{i=0}^{2l} h'_l(i) \cdot \text{MMD}_{t-i}^2 \quad (2.18)$$

Drift candidate c xòc nh khi tồn hieu shape i du (t dng sang óm hoc ngc li):

$$\text{Candidate}(t) = \text{sign}(\text{shape}_t) \neq \text{sign}(\text{shape}_{t-1}) \quad (2.19)$$

Sau bc shape detection, mi drift candidate c xòc thc bng permutation test [20] loi b false positive:

1. Tòngh $\text{MMD}_{\text{obs}}^2$ t d liu gc ti v trờ candidate

2. Lp N_{perm} ln (thng 1000-5000):

(a) Hoàn v ngu nhiên nhõn ca hai na ca s

(b) Tòngh $\text{MMD}_{\text{perm}}^2$ vi d liu hoàn v

3. Tòngh p-value:

$$p\text{-value} = \frac{|\{\text{MMD}_{\text{perm}}^2 \geq \text{MMD}_{\text{obs}}^2\}|}{N_{\text{perm}}} \quad (2.20)$$

4. Nu $p\text{-value} < \alpha$ (thng $\alpha = 0.05$), chp nhn drift

Nu khũng cú drift thc s, vic hoàn v nhõn khũng nỏn thay i nhiu MMD^2 . Nu cú drift, $\text{MMD}_{\text{obs}}^2$ s ln hn òng k so vi còc giò tr permutation.

Permutation test lị bc tn thi gian nht: $O(N_{\text{perm}} \cdot l_1^2)$. Tuy nhiên, vớ ch òp dng cho còc candidate (khũng phi mi thi im), chỉ phờ trung bõnh vn chp nhn c.

Hn ch lị s ln resampling N_{perm} thng phi ly vựi nghơn p-value cú phón gii tt, vị mi ln phi tòngh li kernel matrix. Chỉ phờ kim nh vớ vy ln hn nhiu ln so vi chỉ phờ tòngh MMD thũ. chõnh xòc thng kỏ ca ngng phòt hin cng ch m bo nu phón phi đi gi thuyt khũng trũĩ dt c c lng phứ hp.

Hn ch nịy lị ng lc cho IDW-MMD Chng 4: thay permutation test (Gii thut 1) bng p-value da trỏn xp x Gamma, ng thi dũng trng s nghch bin mt nhn mnh vũng biỏn phón phi. Phng phòp ly cm hng t “Optimally-Weighted MMD” ca Bharti et al. [21], nhng dũng heuristic n gin hn phứ hp vi d liu lung.

Gii thut 1 Shape-based Drift Detector (ShapeDD)**Require:** Stream S , window size l_1 , bandwidth γ , significance level α **Ensure:** Set of detected drift points D

```

1:  $D \leftarrow \emptyset$ 
2: Initialize sliding window  $W$  of size  $2l_1$ 
3: for each new sample  $x_t$  in  $S$  do
4:   Update  $W$  with  $x_t$ 
5:   if  $|W| = 2l_1$  then
6:      $\gamma \leftarrow \text{MedianHeuristic}(W)$  ▷ estimate kernel bandwidth
7:      $K_{ij} \leftarrow \exp(-\gamma \|x_i - x_j\|^2)$  for all  $i, j$  ▷ compute kernel matrix
8:     Define contrast weights  $w(t)$  and compute  $\text{MMD}_t^2 \leftarrow \sum_{i,j} w_i w_j K_{ij}$ 
9:      $\text{shape}_t \leftarrow (h' * \text{MMD}^2)(t)$  ▷ convolve with derivative of smoothing kernel
10:    if  $\text{sign}(\text{shape}_t) \neq \text{sign}(\text{shape}_{t-1})$  then ▷ sign change  $\Rightarrow$  drift candidate
11:       $t_c \leftarrow t$ 
12:      Compute p-value via  $N_{\text{perm}}$  permutations of the kernel matrix
13:      if p-value  $< \alpha$  then
14:         $D \leftarrow D \cup \{t_c\}$  ▷ drift confirmed at  $t_c$ 
15:      end if
16:    end if
17:  end if
18: end for return  $D$ 

```

u im ni bt ca ShapeDD

So vi còc phng phòp phòt hin drift trun thng, im mnh chònh ca ShapeDD lị khai thòc hnh dng tồn hiu thay vớ phn ng trc tip vi mi dao ng ca MMD. C ch lc shape giúp gim nhiu thng kổ vị gim bòn ng gi, vớ ch nhng bin ng cú dng phứ hp vi drift tht mi c gi li. Nh khp dng tam giòc, ShapeDD cng nh v c im thay i gn vi v trở drift thc, trong khi nhiu phng phòp ca s ùi ch bòn rng drift ò xy ra trong mt khong thi gian.

Trong iu kin phứ hp, c bit lị sudden drift vi $P(X)$ thay i rử, ShapeDD t hiu nng phòt hin cao theo bòn còc gc [7]. Phng phòp cng cú th kt hp nhiu ãi ca s vị nhiu o tng bao ph. V tòn thòn, phn convolution/shape detection cú chi phò $O(l)$, cùn kernel matrix cú chi phò $O(l^2)$ cho mi ca s; chi phò ln nht trong bn gc nm bc permutation test.

Hn ch vị iu kin òp dng hiu qu

Bổn cnh u im, ShapeDD phứ hp nht vi còc thay i ri rc vị rử. Lý thuyt hnh dng gi nh mi khong thi gian ch cú ti a mt s kin drift ni bt; nu còc drift xy ra lión tc hoc quò gn nhau, còc tam giòc cú th chng ln vị b lc shape khũng cùn nhn dng ỹng. Vị vớ thit k tp trung vớ abrupt drift, hiu sut cú th gim khi i mt vị gradual hoc incremental drift, ni tồn hiu trũi dt khũng to ra hnh tam giòc rử rịng.

Hiu qu ca ShapeDD cng ph thuc mnh vớ ãi ca s l . Ca s quò nh lịm c lng $\hat{\sigma}(t)$ nhiu, cùn ca s quò ln lịm m hiu ng drift vị tng tr. Vic kt hp nhiu l giúp gim ri ro b

sút nhng tng chi phờ vị phc tp trin khai. Ngoi ra, còc ngng kim nh vị biổn vn cn hiu chnh; t quò cht s gim recall, t quò lng s tng bôo ng gi.

Trong d liu nhieu chiu phc tp, nu drift ch nh hng mt nhúm thuc tồnh nh, khong còch MMD toịn cc cú th yu. Khi ú, ShapeDD cú th cn kt hp vi la chn c trng hoc kim nh theo tng chiu. Nhng hn ch nịy lị lý do Chng 4 ci tin bc kim nh bng IDW-MMD vị tồch tồnh hiu phòt hin khi tồnh hiu phón loi.

CHNG 3

CŨNG TRŒNH LIÖN QUAN

Tóm tắt: Chng này trnh bày tng quan còc phng phòp phòt hìn hìn tng trũĩ dt ò vị ang c nghiõn cu, ng thì gũ thiũ còch phón loi trũĩ dt da trõn ca s trt. Còc phng phòp c trnh bày theo nhiũ gúc nhõn khòc nhau so sònh, ònh giò vị lịm tin cho vic phòt trin mũ hõnh phòt hìn trũĩ dt ca lun vn.

3.1 Còc phng phòp phòt hìn trũĩ dt

Trĩ qua nhiũ thp k, bị toàn phòt hìn hìn tng trũĩ dt ò c nghiõn cu vì nhiũ còch tip cñ khòc nhau. T nhng nm 1990, còc h thng hc mòy u tiõn cú kh nng thờch ng vì concept drift ch yu da trõn chín lc ca s trt hoc b qua mu c ãn thờch nghi vì d liũ mi. Giai on này cha cú phng phòp “phòt hìn” drift tòch ri, mĩ còc mũ hõnh thng t iũ chnh da trõn li hoc trng s mu theo thì gian.

S thay i ãn ra vĩa gia nhng nm 2000 khi còc thut toàn chuyõn bit phòt hìn im thay i bt u ra i. Còc phng phòp phòt hìn trũĩ dt cú th chia thịnh bn nhũm chõnh theo k thut ct lũĩ: (1) nhũm phng phòp thng kỏ (phón tòch thay i phón phi d liũ), (2) nhũm phng phòp theo ãũ hũn nng mũ hõnh (da trõn sai s hoc chõnh xòc), (3) nhũm phng phòp hc mòy truyn thng (vò d ãũng ensemble hoc mũ hõnh ph ãnh bit drift), vĩa (4) nhũm phng phòp hc sỏu (deep learning).

3.1.1 Còc phng phòp thng kỏ

Nhũm phng phòp thng kỏ tĩp trung vĩa vic phòt hìn thay i phón phi d liũ mĩ còch trc tip, thng thũng qua còc phỏp kim nh thng kỏ hoc quan sòt ca s trt trõn ãũng d liũ. Mĩ trong nhng k thut kinh in lĩ s ãũng còc biũ kim sỏt thng kỏ liõn tc nh *CUSUM* [22] hay kim nh *Page-Hinkley* (*PH*).

Chng hñ, kim nh *PH* [22, 23] c òp ãũng trong bi cñh concept drift giòm sòt trung

bệnh ca m t chui s liu vị phòt hin khi nịo trung bñnh thay i òng k. PH thc cht trin khai biu CUSUM nhy vi nhng thay i nh trong giò tr trung bñnh vị cú th phòt hin c xu hng tng ln gim. Tng t, còc kim nh thng kỏ hai mu (nh KolmogorovSmirnov, Student t-test) cng c tn dng so sònh phón phi ca hai ca s d liu (mì vị c) nhm tòm ra s khòc bit cú ý ngha.

Mt du mc quan trng trong nhúm nịy lị phng phòp **ADWIN** (Adaptive Windowing) do Bifet vị Gavalđi xut nm 2007 [19]. ADWIN s dng ca s trt cú kòch thc thay i mt còch thờch ng: nú duy trở mt ca s d liu vị ãi bin thiỏn sao cho gi thit “khũng cú s thay i” c m bo bốn trong ca s ú.

Ti mì thi im, ADWIN tòch ca s hin ti thnh hai phn W_0 vị W_1 liỏn tip ri so sònh s khòc bit v giò tr trung bñnh gia W_0 vị W_1 . Nu chỏnh lch trung bñnh vt quò mt ngng thng kỏ (xòc nh ãa trởn khong tin cy vì mc ý ngha δ ò chn), thut toỏn kt lun rng phón phi d liu ò thay i vị kòch hot bòn ng drift.

ADWIN cú gii hn lý thuyt trởn t l bòn ng gi vị t ng iu chnh kòch thc ca s thay vớ yỏu cu ngi ãng c nh trc, nh ú phòt hin c c drift t ngt ln ãn ãn vị lị nn tng cho nhieu k thut nóng cao sau nịy. Hai nhc im chỏnh lị chỉ phò thờnh toỏn cao ão phi kim tra nhieu kòch thc ca s, vị nhy vì nhieu trong d liu [6].

Mt phng phòp khòc lị **KSWIN** (KolmogorovSmirnov WIndowing [24]), kt hp kim nh KolmogorovSmirnov vì ca s trt nhm phòt hin thay i phón phi mì khũng cn gi nh trc v dng phón phi. Còc phng phòp thng kỏ thun tữ nịy cú u im lị khũng ph thuc v iỏ mũ hnh hc mỳy c th, ão ú cú th òp dng trong mũ trng phi giòm sòt (khũng cn nhỏn). Mt khòc, chũng thng ùi hi gi nh mnh v c lp vị phón phi d liu, vị cú th b sút nhng thay i nh nu kòch thc mu khũng ln.

Dứ vỵ, nhúm phng phòp thng kỏ ò t nn múng quan trng cho lnh vc phòt hin drift, c bit cho còc bị toỏn quan tòm trc tip n s thay i ca d liu hn lị hiu nng mũ hnh.

3.1.2 Còc phng phòp ãa trởn hiu nng mũ hnh

óy lị nhúm phng phòp ph bin trong giai on gia nhng nm 2000, khi còc nhị nghiỏn cu tp trung v iỏ vic giòm sòt cht lng ão òn ca mũ hnh hc mỳy theo thi gian phòt hin drift. Ý tng chỏnh lị nu chỏnh xòc ca mũ hnh hc mỳy t nhiỏn tr nỏn kỏm i (t l lị tng lỏn òng k khi so sònh vì nhỏn tht) thờ cú kh nng d liu ò cú thay i.

Phng phòp DDM (Drift Detection Method) ra i nm 2004 [25], nhanh chũng tr thnh nn tng quan trng vị t nn múng cho còc phng phòp sau nịy.

DDM (Drift Detection Method) theo ãi t l lị p_i vị lch chun s_i ca mũ hnh trởn ãùng d liu. Ý tng lị trong quò trởnh hot ng, nu phón phi d liu n nh, t l ão òn sai s gim ãn vị ão ng xung quanh mt giò tr thp. Khi concept drift xy ra, t l lị ca mũ hnh t ngt

tăng cao, vượt ra khi không tin cậy. DDM ghi nhận giờ trả lời thiếu cả $p_i + s_i$ trong quá trình học, vị trí hai ngưỡng cân bằng:

- **Warning level:** Khi $p_i + s_i \geq p_{min} + 2 \cdot s_{min}$ (ngưỡng 2-sigma), hệ thống bắt đầu lưu dữ liệu mới chuẩn bị huấn luyện lại
- **Drift level:** Khi $p_i + s_i \geq p_{min} + 3 \cdot s_{min}$ (ngưỡng 3-sigma), drift có xác nhận, mẫu học cũ bị loại bỏ và huấn luyện lại từ đầu lưu trữ

DDM nhận ra, hiệu quả cho sudden drift, nhưng phần nhạy cảm vì gradual drift do chỉ dựa vào sự gia tăng trung bình của nó [25].

EDDM (Early Drift Detection Method) cải thiện khả năng phát hiện gradual drift bằng cách thay đổi metric theo dõi. Thay vì theo dõi trực tiếp lỗi, EDDM tập trung vào giờ trả lời không có chênh lệch lớn dòn sai lệch tiếp [26]. Ý tưởng là khi không có drift, chênh lệch phản biến ngẫu nhiên vì không có chênh lệch, khi drift bắt đầu xuất hiện, chênh lệch xuất hiện tăng dần. EDDM không trung bình vị trí chuẩn của không có chênh lệch, phát hiện drift khi không có chênh lệch giảm mạnh so với giờ trả lời đã ghi nhận. Như vậy, EDDM nhạy hơn vì thay đổi lỗi, bù đắp hiệu suất hơn DDM trong nhiều trường hợp [26]. Sau DDM và EDDM, hàng loạt thuật toán đã được đề xuất theo dõi hiệu suất ra đi, cho thấy sự phát triển ngày càng phong phú sau này.

HDDM (Hoeffding's Drift Detection Method) [27] là một hướng cải tiến quan trọng, áp dụng các công thức thống kê chặt chẽ hơn để giảm thiểu sai lệch. Thay vì giả định rằng lỗi tuân theo phân phối chuẩn (như DDM giả định phân phối chuẩn thực), HDDM sử dụng bất đẳng thức Hoeffding để ước lượng giới hạn phát hiện drift mà không cần giả định về dạng phân phối. HDDM có hai biến thể chính: **HDDM_A** sử dụng trung bình trượt lỗi vì Hoeffding bound, và **HDDM_W** dùng lỗi trượt để giảm thiểu sai lệch cao hơn cho dữ liệu ngắn.

Bất đẳng thức Hoeffding cho phép HDDM tăng cường phát hiện drift mà không cần giả định về phân phối của dữ liệu, làm cho phương pháp phù hợp hơn trong các tình huống thực tế.

FHDDM (Fast HDDM) [28] cải thiện hiệu suất tính toán của HDDM, cải thiện hiệu suất trong việc phát hiện drift. FHDDM vẫn dựa trên bất đẳng thức Hoeffding nhưng tối ưu thuật toán để giảm thiểu chi phí tính toán vì dùng dữ liệu tốc độ cao (high-speed data streams). Các cải tiến về mặt kỹ thuật giúp FHDDM phần mềm nhanh hơn vì có drift tăng dần drift dần dần, nên chỉ giảm thiểu phần trăm tổng số vì HDDM gốc. **FHDDMS (Fast HDDM with Multiple Sliding Windows)** mở rộng FHDDM bằng cách duy trì hai cửa sổ trượt khác nhau: cửa sổ ngắn nhạy với thay đổi bất ngờ của sudden drift nhanh, còn cửa sổ dài có nhiều dữ liệu hơn để giảm thiểu sai lệch false negative cho gradual drift.

FHDDMS liên tục so sánh giờ trả lời trung bình hiện tại với giờ trả lời trung bình đã quan sát trong quá khứ. Drift có hiệu suất như sự khác biệt của bất kỳ cửa sổ nào vượt quá ngưỡng Hoeffding tăng dần. Thiết kế dual-window này cho phép FHDDMS tận dụng ưu điểm của hai cách thức

ca s, cón bng gia nhy (sensitivity) vı tin cy (reliability).

MDDM (McDiarmid’s Drift Detection Method) [29] lı phng phòp òp dng bt ng thc McDiarmid – mt cũng c thng kỏ dng concentration inequality – phòt hin nhng thay i òng k trong phón phi d liu. im c bit ca MDDM lı vic òp dng còc lc trng s (weighting schemes) cho còc phn t trong ca s trt:

- **MDDM-A (Arithmetic):** Trng s tuyn tòngh $w_i = i$
- **MDDM-G (Geometric):** Trng s hính hc $w_i = r^{i-1}$ vı $r > 1$
- **MDDM-E (Euler):** Trng s theo hịm m $w_i = e^{(i-1)/c}$

Còc lc trng s nıy gòn trng s cao hn cho còc mu gn óy, giúp MDDM phn ng nhanh hn vi thay i mi nht trong dùng d liu.

RDDM (Reactive DDM) [30] tp trung vıo vic ti u thi gian phn ng bng còch rứt ngn giai on cnh bào (warning phase) ca DDM gc. RDDM iu chnh còc ngng phòt hin nhanh hn còc thay i t ngt, ng thi vn duy tró kh nng x lý drift lp li (recurrent drift). Ci tin nıy c bit hu òch trong còc ng dng yỏu cu phn ng thi gian thc.

Nhng nm gn óy cùn xut hin còc bin th hng n còc tòngh hung c thứ (xem Bng 3.1 so sòngh tng hp):

- **ACDDM** [31] (Accurate DDM, 2020): Ci thin chòngh xỏc cho drift lp li bng còch lu tr vı tòi s dng còc concept c.
- **DMDDM** [32] (Diversity-Measure DDM, 2020): Tn dng tòngh a dng (diversity) ca ensemble classifier tng nhy phòt hin drift.
- **DDM-FPW** [33] (2020): Kim soỏt t l dng tòngh gi trong lung d liu IoT a nhõn.

Mc tiỏu chung ca còc ci tin nıy lı tng nhy vi nhıu loi drift, ng thi gim bào ng gi vı phón bit c drift thc s vi nhıu.

Bng 3.1 Còc phng phòp DDM-family

Phng phòp	Nm	Ci tin chòngh	im mngh
DDM [25]	2004	Theo dủi error rate	n gin, phòt hin sudden drift tt
EDDM [26]	2006	Khong còch gia li	Phòt hin gradual drift sm hn
HDDM [27]	2015	Hoeffding bound	Khũng gi nh dng phón phi c th
FHDDM [28]	2016	Ti u tc	Nhanh cho high-speed stream
FHDDMS [28]	2016	Dual windows	Cón bng sudden/gradual detection
MDDM [29]	2018	McDiarmid + weights	Nhn mngh d liu gn óy
RDDM [30]	2017	Rứt ngn warning	Phn ng nhanh vi sudden drift

Nhúm phng phòp da trỏn hıu nng mủ hính bt u t DDM [25] vı ỏ c m rng thính nhıu bin th cón bng hn gia tc , chòngh xỏc vı tin cy.

3.1.3 Cờ phng phòp hc mỳ trun thng

Bổn cnh vic đứg trc tip thng kỏ hoc sai s mũ hnh, cò nhự nghiỏn cu cùn phòt trin nhng k thut phòt hin drift da trỏn mũ hnh hc mỳ hoc t hp nhiu mũ hnh. Nhng phng phòp nỳ thng cú tờnh “ch ng” hn: thay vớ ch hiu nng gim, chũng tởm du hiu thay i trong cu trũc d liu hoc trong phn ng ca nhiu mũ hnh khỏc nhau.

Paired Learners [34] lỳ mt vờ d tiỏu biu, s dng hai mũ hnh hc song song trỏn dùng d liu: mt mũ hnh “n nh” (stable learner) c hun luyỏn trỏn toỏn b d liu tỏch ly (dị hn), vỳ mt mũ hnh “nhỏnh” (reactive learner) liỏn tc hun luyỏn trỏn ca s ngn hn gỏn óy. Khi cú concept drift, mũ hnh nhỏnh s thờch nghi sm vỳ phỏn phi d oỏn ca nú s khỏc bit rủ so vỳ mũ hnh n nh. Paired Learners theo dũi mc bt ng (disagreement) gia hai mũ hnh nỳ: nu sai khỏc vt ngng, ta kt lun ỏ cú drift. Cỏch tip cn nỳ cho phỏp phòt hin c drift t ngỏt (mũ hnh nhỏnh thay i tc thi) ln drift đn đn (mũ hnh nhỏnh đn đn thay i so vỳ mũ hnh c).

Mt hng khỏc lỳ tn dng **ensemble learning**, đứg nhiu mũ hnh phỏn loi chy song song nhn bit concept drift thũng qua s a dng (diversity) ca ensemble. Phng phòp **ACE** (Adaptive Classifiers-Ensemble System [35], 2007) duy trỏ mt tp phỏn loi vỳ liỏn tc ờnh giỏ mi mũ hnh trỏn lung d liu; mũ hnh suy gim s b thay th bi mũ hnh mi hun luyỏn trỏn d liu gỏn óy, vỳ chờnh vic thay th nỳ lỳ tỏn hiu drift.

Learn++.NSE [36] m rng theo hng tng t: gỏn trng s thi gian cho tng classifier theo tui, classifier mi hc concept mi cùn classifier c đn m nht. C hai phng phòp phòt hin drift gỏn tip qua thay i cu trũc hoc thnh phn ensemble.

Ngoi ra, mt s phng phòp s dng **Classifier-based Drift Detection**: hun luyỏn mt mũ hnh phỏn loi nhm phỏn bit “d liu c” vỳ “d liu mi”; nu mũ hnh nỳ t chờnh xỏc cao ngha lỳ hai phỏn phi khỏc nhau rủ (drift ln). Trong mũ trng unsupervised, cò phng phòp **one-class** nh OCDD (One-Class Drift Detector) [37] đứg mt b phỏn lp one-class hun luyỏn trỏn ca s d liu c; khi t l mu mi b b phỏn lp nỳ xem lỳ ngoi lai tng vt ngng, ú lỳ du hiu drift.

Nhúm phng phòp nỳ phòt trin mnh khong 20082015, khi kh nng tỏnh toỏn cho phỏp trin khai nhiu mũ hnh song song. Chũng tn dng sc mnh ca ensemble vỳ mũ hnh meta phòt hin cỏc thay i tinh vỳ, to bc chuyỏn t cỏc k thut thun thng kỏ sang cỏc h thng linh hot, kt hp cht ch quỏ trỏnh phòt hin drift vỳ quỏ trỏnh hc liỏn tc.

3.1.4 Cờ phng phòp hc sỏu

Vỳ s bứg n ca deep learning, bị toỏn concept drift c nghiỏn cu trong bi cnh cò mũ hnh mng neural phc tp. Thỏch thc t ra lỳ cò mũ hnh deep learning thng cú hng

triu tham s vị quò trính hc phc tp, lịm sao tồch hp hoc thit k b phòt hin drift hieu qu? Còc hng tip cn chờnh bao gm: (I) tồch hp còc detector truyñ thng giòm sòt u ra hoc c trng trung gian ca mng deep; (II) thit k kin trũc mng cú kh nng t nhn bit drift vị iu chnh cu trũc; (III) s dng chờnh còc mũ hnh deep trc tip phón tồch s thay i phón phi trong d liu.

Hng (I): External detectors. Còch tip cn ph bin lị gn còc b phòt hin drift c in vọ pipeline ca mũ hnh deep learning. Vở d, trong giòm sòt mũ hnh CNN phón loi nh, cú th theo dũi bt nh (entropy) ca phón phi d oòn, khi entropy tng t bin (mũ hnh tr nỏn kỏm chc chn), mt b phòt hin nh ADWIN c kỏch hot dù tỏm thay i trong chui entropy theo thi gian. Jourdan vị cng s [4] ò ỏp dng thnh cũng còch nịy phòt hin drift trong h thng giòm sòt sn xut cũng nghip: s dng ADWIN theo dũi lch xỏc sut d oòn ca mng CNN, khi ADWIN bỏo drift thỏ h thng kỏch hot hun luyñ li mũ hnh trỏn d liu mi.

Tng t, trong mũ hnh phòt hin bt thng dũng LSTM, còc nghiỏn cu trc óy cng nhũng còc detector nh DDM hoc Page-Hinkley liỏn tc canh chng li d oòn theo thi gian. Vic tồch hp nịy khai thỏc tỏnh cht “model-agnostic” ca còc thut toòn drift detection truyñ thng, bin chũng thnh cm bin giòm sòt bốn ngoịi cho còc mũ hnh deep phc tp.

Hng (II): Self-adaptive architectures. Còc mng neural t iu chnh cu trũc khi drift xy ra ang tr thnh mt hng nghiỏn cu c quan tỏm. **NADINE** [38] lị mt mng MLP nhieu lp cú kh nng tin húa cu trũc: NADINE tồch hp c ch phòt hin drift ch ng da trỏn ca s trt thờch ng kt hp bt ng thc Hoeffding (tng t ý tng ca FHDDM) liỏn tc kim tra d liu mi. Mi khi detector phòt hin tỏn hieu drift, NADINE s “tin húa” bng còch thỏm hoc bt còc nũt n vị tng n tng ng thờch nghi vị concept mi. C ch nịy giúp mng t iu chnh phc tp: tng nu concept mi phc tp hn, hoc gim nu cn trỏnh overfitting.

Hng (III): Intrinsic detection. Khai thỏc trc tip nng lc biu din ca mũ hnh deep nhn bit drift. Vở d, mt autoencoder cú th hc nỏn d liu u vọ; nu phón phi d liu thay i, li tòi to (reconstruction error) ca autoencoder s tng cao. Jaworski vị cng s [39] giòm sòt phón phi li tòi to ca autoencoder, khi phón phi nịy dch chuyn nhieu thỏ phòt tỏn hieu drift. Trong lnh vc chui thi gian, mt hng tng t lị hc mũ hnh chui bng LSTM ri dũng sai s d bỏo lịm tỏn hieu phòt hin thay i [5]; k thut t ngng ng phi tham s (*nonparametric dynamic thresholding*) cho loi tỏn hieu sai s nịy c Hundman vị cng s [40] gii thiu trong bịi toòn phòt hin bt thng trỏn d liu vin trc, vị v sau c vn dng li cho bịi toòn phòt hin drift. Còc phng phỏp nịy tn dng c thũng tin trong d liu nh c trng hc c ca network, nhng khú tồch bch gia “drift” vị “nhieu” bốn trong mũ hnh.

Bng 3.2 Tóm tắt các phương pháp phát hiện concept drift

Nm	Phương pháp	Đặc điểm
1996	FLORA [41]	Các thuật toán dựa trên lý thuyết drift dựa trên các nguyên nhân.
2004	DDM [25]	Giảm số lượng mẫu huấn luyện, tăng cường bảo vệ drift theo luật SPC; phát hiện drift theo ngưỡng.
2006	EDDM [26]	Mở rộng DDM, cải thiện phát hiện drift dựa trên các khoảng cách giữa các điểm.
2007	ADWIN [19]	Các thuật toán dựa trên lý thuyết, so sánh thống kê hai các con phát hiện thay đổi phân phối.
2015	HDDM [27]	Sử dụng bất đẳng thức Hoeffding (không giả định phân phối) phát hiện drift trong dữ liệu; giảm giả định về DDM.
2016	FHDDM [28]	Phiên bản nhanh của HDDM, tăng tốc độ khi drift (theo ngưỡng dựa trên dữ liệu).
2017	RDDM [30]	Phát hiện nhanh về drift theo ngưỡng, rút ngắn giai đoạn bảo vệ của DDM; phù hợp cho drift lặp lại.
2020	DAWIDD [42]	Phương pháp phi tham số dựa trên kiểm định độc lập (independence test) thay vì mô hình dự đoán; linh hoạt vì nhiều dạng drift khác nhau.
2019–22	Học sâu theo hướng	Xử lý các mô hình deep learning tích hợp phát hiện drift (NADINE [38], ADL [43], DEV DAN [44]); mở rộng các học máy để phát hiện drift.

Các phương pháp cũng có thể được thử nghiệm trên các tập dữ liệu khác nhau và các tham số khác nhau. Bng 3.4 tổng hợp các kết quả của các nghiên cứu. Lưu ý: các số liệu có thể thay đổi theo thời gian và các phương pháp khác nhau (mô hình các, cách chia dữ liệu, số lần chạy), do đó không nên so sánh trực tiếp giữa các hệ thống mà chỉ nên xem xét các kết quả tổng thể. Bng 3.3 phân loại các bài báo theo nhóm chính và các chủ đề.

Bng 3.3 Phân loại các bài báo về phát hiện Concept Drift theo chủ đề

Thuật toán	Nhóm chính	Chủ đề	Đặc điểm	Ưu điểm
DDM	Statistical Process Control	Binomial Distribution	Ổn định, nhanh [25]	Hiệu suất giảm khi các số liệu [6]
EDDM	Statistical Process Control	Distance between errors	Nhạy với gradual drift [26]	Dễ dàng áp dụng cho các mô hình [11]
ADWIN	Sliding Window	Adaptive Windowing	Các giới hạn lý thuyết (theoretical bounds) và tính linh hoạt [19]	Tính linh hoạt của DDM/EDDM [6]
HDDM	Sliding Window	Hoeffding's Bound	Phù hợp cho abrupt/gradual drift [27]	Các dữ liệu không đồng nhất [11]
FHDDM	Sliding Window	Hoeffding + Sliding Win.	Chỉ cần một bước tính toán, đơn giản [28]	Các kết quả thực nghiệm của các phương pháp [6]
D3	Virtual Classifier	Unsupervised Separation	Tính nhanh, không cần mẫu huấn luyện [45]	Hiệu quả thực nghiệm với các mô hình phân loại [6]
ShapeDD	Meta-Statistic	Shape-based Filtering	Nhạy với drift không xác định [7]	Thực nghiệm thực nghiệm của các số liệu [7]
DAWIDD	Block-Based	Independence Test (HSIC — Hilbert-Schmidt Independence Criterion)	Ổn định, nhạy với drift, không cần mẫu huấn luyện [6, 42]	Các dữ liệu không đồng nhất, các phương pháp phân loại (Bng 5.9) [6]

Số lượng cũng tăng lên với các phương pháp deep learning về phát hiện concept drift cũng tăng nhanh trong những năm gần đây. Ban đầu, các mô hình deep learning đã vượt qua các “cơn bão” drift bốn mươi

(nh ADWIN, DDM) quyết nh khi nộ cn tòi hun luyn. Sau ú, còc kin trúc deep thòch ng (NADINE [38], DEN [46], ADL [43], DEVDAN [44]) ra i vì kh nng t iu chnh cu trúc khi drift xy ra. Còc phng phòp nìy vn ang phòt trin, nhng ha hn giúp mĩ hnh hc sòu vn hnh n nh trong mĩi trng d liu bin ng.

Bng 3.4 Tng hp hieu nng phòt hin drift t còc nghiõn cu gc

Thut toà	Accuracy (%)				Delay		β -score	
	Elec2	Cov.	Hyp.	SEA	Elec2	Hyp.	Elec2	Hyp.
D3	86.69	87.17	85.29	88.08	–	–	–	–
ADWIN	81.33	80.48	87.28	77.59	–	–	–	–
DDM	79.30	83.36	84.01	85.32	–	–	–	–
EDDM	78.25	82.76	80.27	75.73	–	–	–	–
HDDM-A	85.71	87.24	86.91	–	–	–	–	–
FHDDM	73.62 [†]	67.76 [†]	85.08	–	–	–	–	–
DAWIDD	–	–	–	–	21.00	37.18	–	–
ShapeDD	–	–	–	–	–	–	87.73	96.00

Ghi chú: Còc ch s c tng hp t còc nghiõn cu gc.

[†] Tònh toà t t l i (Error-rate) ca mĩ hnh Hoeffding Tree.

Accuracy: chònh xòc tòch ly (Prequential) ca mĩ hnh kt hp vi b phòt hin drift.

Delay: S mu trung bnh t khi drift xy ra n khi c phòt hin (thp = tt).

β -score: Ch s ònh giò cht lng phòt hin, cón bng Precision vị Recall (cao = tt).

Nh bng 3.2 tóm tt, lnh vc phòt hin concept drift ò i t còc ì tng ca s trt vị giòm sòt sai s mĩ hnh sang còc kim nh thng kỏ, ensemble, meta-learning vị gn óy lị hc sòu [11]. Xu hng chung lị gim ph thuc vộ gi nh cng, x lý c nhieu dng drift hn, vị chun b cho còc h thng va phòt hin va thòch ng vị d liu bin i.


3.2 Phng phòp phón loi drift CDT-MSW

CDT-MSW [8] lị phng phòp *cú giòm sòt* phón loi loi drift da trỏn hnh vị ca chònh xòc mĩ hnh trỏn nhieu ca s trt (Hnh 3.1). óy lị ngun cm hng trc tip cho SE-CDT (Chng 4); lun vn k tha hai ì chònh sau vị thay th phn lủi tòn hieu, chỉ tit k thut ca ba giai on xem trong bậi bòa gc.

Phón nhúm TCD vs PCD theo ãị trủi dt: CDT-MSW ãng phng sai chònh xòc trỏn ca s ph W_R c lng ãị m ca s trủi dt. Th tc c lng ãị nìy c bậi bòa gc gi lị **Growth process** (Algorithm 2 trong [8]): sau khi phòt hin c v trỏ drift, ca s ph c m rng ãn cho ti khi phng sai chònh xòc tr lị mc n nh, vị s bc m rng chònh lị m . Lun vn gi nguyễn thut ng nìy khi nhc lị c ch ca CDT-MSW Chng 4 vị Chng 6. Khi ãị $m = 1$ (phón phi n nh ngay lp tc), drift thuc nhúm **Transient Concept Drift (TCD)** bao gm Sudden, Blip vị Recurrent. Khi $m > 1$ (chuyñ tip ãn), drift thuc nhúm **Progressive Concept Drift (PCD)** bao gm Incremental vị Gradual. Hai nhúm nìy c phón bit tip giai on theo ãủi bng hnh ãòng ca ng cong Tracking Flow Ratio (TFR) vị Micro TFR

(MTFR).

Hai mc ònh giò phón loi CAT vị SUB: Phón loi c ònh giò hai mc: nhóm chờnh TCD/PCD (gi tt lị CAT) vị tiu loi Sudden/Blip/Recurrent/Incremental/Gradual (gi tt lị SUB). Hai thut ng CAT/SUB tòi s dng trong còc thờ ngihm phón loi ca lun vn (Mc 5.3).



Hình 3.1 Tng quan ba giai on ca CDT-MSW: phòt hìn v trở trũ dt, c lng dị, theo dũ vị phón loi tiu loi bng TFR/MTFR.

Tuy nhiên, vic dũng chờnh xòc mũ hnh lịm tồn hũ khĩn CDT-MSW ph thuc vịo nhõn y , khũng kh dng cho mũ trng khũng giòm sòt ca lun vn. SE-CDT thay tồn hũ t l chờnh xòc (accuracy ratio) bng tồn hũ MMD o trở ca s trt nhng gi lị còch phón nhũm CAT/SUB trở (Chng 4).

3.3 Còc chín lc cp nht mũ hnh thờch ng

3.3.1 Tng quan

Trong còc h thng hc trc tũn (online learning systems), vic phòt hìn trở trũ dt ch lị bc u tiũn. iu quan trng hn lị còch **mũ hnh thờch ng** (model adaptation) c cp nht sau khi trở trũ dt xy ra. Còc chín lc cp nht mũ hnh nhm duy trở chờnh xòc, n nh vị trờnh hìn tng quũn ngn hn (catastrophic forgetting) trong quò trờnh hc liũn tc.

Theo Guo *et al.* [8], thũng tin v loi trở trũ dt (drift type) do CDT-MSW cung cp gi vai trũ quan trng trong vic la chn c ch cp nht phũ hp. Còc nghiũn cu gũn óy [4] ò m rng khũng thờch ng nịy sang h thng hc sũu, trong ú chín lc cp nht ph thuc ng thi vịo loi trở trũ dt, cu trũc mũ hnh, mc sn cú ca nhõn vị chỉ phờ tũnh toũn.

3.3.2 Phón loi chín lc cp nht

Tng hp t còc tị liu trở về còc kho sòt v hc di concept drift [13, 14, 16], cú th chia còc chín lc cp nht mũ hnh thĩnh bn nhũm chờnh:

- (a) Cp nht cc b (Local Reset / Fine-tuning) phú hp vi *sudden drift*, khi phón phi d liu thay i mnh trong thi gian ngn. Mũ hnh c tòi hun luyn mt phn hoc toịn b trón ca s d liu mi. Phng phòp nỳ phú hp vi còc b phòt hin trũ dt da trón ca s nh ADWIN hoc CDT-MSW, khi $L_d < \lambda$ (dũ trũ dt ngn).

Võ d, trong h thng giòm sòt quò trónh sn xut (process monitoring), Jourdan *et al.* [4] thc hin *partial reinitialization* ca còc tng cui trong mng n-ron khi bt nh (uncertainty) vt ngng.

- (b) Cp nht dn (Gradual / Incremental Update) c dũng khi mũ hnh gp *gradual* hoc *incremental drift*. Võ s thay i din ra t t, mũ hnh thng cn cp nht mm vi h s hc η_t nh hn. Mt còch mũ t tng quòt lĩ cp nht tham s theo gradient trón d liu mi vi h s hc hoc trng s quón ph thuc vĩa tc drift:

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \mathcal{L}(x_t, y_t), \quad \text{vi } \eta_t = f(L_d, r_t),$$

Trong ú L_d lĩ dũ trũ dt, r_t lĩ tc thay i. Khi r_t tng u, η_t c tng dn theo kp xu hng d liu mi. Còc k thut nh *online fine-tuning*, *stochastic gradient with forgetting factor* hoc *momentum adaptation* thng c s dng trong nhúm nỳ.

- (c) Cp nht theo ng cnh (Recurrent / Memory-based Adaptation) x lĩ *recurrent drift*, khi khòì nim c tòi xut hin theo chu k. Mũ hnh nỏn duy trở mt *b nh khòì nim* (concept repository), lu còc snapshot $\{M_i\}$ tng ng vi tng khòì nim vĩa chn mũ hnh phú hp nht khi phón phi d liu hin ti $P_t(x)$ tng t vi mt snapshot trc ú:

$$M^* = \arg \min_{M_i} \text{Dist}(P_t(x), P_{M_i}(x)).$$

Phng phòp nỳ c òp dng trong còc framework hc sỏu cú b nh ng nh Deep Ensemble Replay hoc Continual Learning with Experience Buffer.

- (d) Cp nht cu trũc (Structural or Hybrid Adaptation) thay i c tham s ln *cu trũc mng hc sỏu* khi cú drift. Võ d, thỏm tng mi hoc nhònh mi hc khòì nim mi mĩ khũng lĩm mt kin thc c, biu din bi:

$$\mathcal{M}_{t+1} = \mathcal{M}_t \cup \Delta \mathcal{M},$$

Trong ú $\Delta \mathcal{M}$ lĩ tp còc node hoc layer mi c thỏm. Phng phòp nỳ hu òch vi còc trũ dt dũ hn (progressive drift) hoc trũ dt phc hp (hybrid drift).

Bng 3.5 Mối quan hệ gia loi trôi dạt vị chỉnh lý cập nhật mô hình thích ứng

Loi trôi dạt	Chỉnh lý cập nhật xuất
Sudden drift	Tôi huấn luyện nhanh (local reset), bỏ dữ liệu cũ; tăng η_t ; phù hợp vì incremental retraining, ADWIN, CDT-MSW.
Gradual drift	Cập nhật mềm (soft update), giảm η_t ; áp dụng momentum học học sliding window dài.
Incremental drift	Cập nhật liên tục (continuous adaptation), sử dụng gradient online vị drift-aware scheduler.
Recurrent drift	Duy trì bộ nhớ khởi đầu; lựa chọn mô hình tăng t (ensemble selection / memory replay).
Progressive drift	Thay đổi cấu trúc mô hình (dynamic architecture), học học chuyển giao (transfer learning) giữa các giai đoạn.

Cờ kết quả trở lại cho thấy thông tin về loi trôi dạt có thể giúp chọn chỉnh lý thích ứng phù hợp hơn, thay vì huấn luyện lại toàn bộ trong môi trường hợp. Cờ hệ thống hình ảnh hệ thống kết hợp tồn tại từ bỏ phớt lờ vị cũ trong ngữ cảnh mô hình điều chỉnh learning rate, chuyển mô hình học thay đổi cấu trúc khi cần. Ý nghĩa tin cậy cho khung thích ứng theo loi drift có xấp xỉ dạng Công 4.

3.4 Lý do lựa chọn ShapeDD làm nền tảng

Tìm kiếm cờ phân trở lại, có thể rút ra nhận xét chung rằng hệ thống cho phân xuất cao hơn.

Cờ phân phù hợp theo dữ liệu nung mô hình như DDM và EDDM hoạt động tốt nhưng cần nhận dữ liệu (y) rõ ràng. Yếu tố này khiến khó khăn trong môi trường sản xuất cũng như môi trường vận hành. Cờ phân phù hợp thống kê không cần nhận như ADWIN hoặc KS-Test phù hợp hơn về mặt giảm sót lỗi, nhưng chưa trực tiếp cung cấp *trở ngại* xác định im drift theo cờ ShapeDD khai thác hình dạng tồn tại. Cờ phân phù hợp kernel-based như MMD và DAWIDD gần hơn vì yếu tố, nhưng chỉ phù hợp toàn diện vị không có sẵn các phép toán loi drift.

ShapeDD phù hợp vì mục tiêu cao hơn với hoạt động không giảm sót, như vị cũ im drift như cờ trong hình học tam giác (Triangle Shape Property), vị có nền tảng lý thuyết rõ ràng tin cậy chắc chắn. Lựa chọn này không chỉ hiệu quả như ShapeDD lựa phân phù hợp tốt nhất. Thay vào đó, ShapeDD có thể với núm cung cấp ứng tồn tại môi trường vận hành: phớt lờ không cần nhận, có localization theo thời gian, có trace hình dạng mở rộng sang phép toán loi drift, vị có thể so sánh thực nghiệm vị cờ detector hiện tại như DAWIDD, MMD, D3 và KS-Test. ShapeDD gần với phép thử permutation test kiểm tra vị chưa có các phép toán loi drift. Hai nhận xét này lý giải xuất phát cho cờ ứng dụng có tránh bị trong Công 4.

Lưu ý với việc xuất hiện ShapeDD theo hai hướng bổ sung cho nhau: dùng IDW-MMD và xấp xỉ Gamma cho bộ kiểm tra nhiễu trôi dạt, vị xấp xỉ dạng hệ thống SE-CDT thích hợp phớt

hình vị phân loại drift — trong đó module phân loại đã trộn hình dạng tồn tại MMD
mặt không cân nhắc. Các tính chất trình bày Chương 4; lý thuyết nền của ShapeDD đã được giải
thích Chương 2.

CHNG 4

H THNG SE-CDT: PHÒT HIN, PHÓN LOI VỊ THỒCH NG CONCEPT DRIFT

Tóm tt: Trổn c s lý thuyt ShapeDD Chng 2 vị kho sòt còc phng phòp phòt hin – phón loi drift Chng 3, chng nịy trng bìy h thng SE-CDT (ShapeDD-Enhanced Concept Drift Type) — mt h thng phòt hin vị phón loi drift tòch hp khũng giòm sòt. Bc phòt hin dúng ShapeDD-IDW (ShapeDD cì tin bng IDW-MMD vì xp x Gamma); bc phón loi phón tòch hnh dng tòn hìu MMD xòc nh loi drift mị khũng cn nhõn. SE-CDT úng vai trò tng giòm sòt cho mữ hnh sn xut, khũng thay th mữ hnh d oòn chõnh. Lun vn cng trng bìy khng thờch ng mữ hnh theo loi drift vị kin trũc x lý lung d liu.

4.1 ng lc vị tng quan còch tip cn

ShapeDD gc cú nhiu u im v chõnh xòc nh v v trờ xy ra drift vị kh nng kh nhiu, nhng khi trin khai trong còc h thng thì gian thc quy mữ ln gp ba hn ch: chỉ phờ permutation test cao, nhy vì kernel bandwidth vị kòch thc ca s, vị cn c ch thờch ng sau khi phòt hin drift [5] nh mt h thng hoịn chnh.


Lun vn xóy dng h thng SE-CDT x lý ba hn ch nịy. V thut toòn, ShapeDD-IDW kt hp tòn hìu Standard MMD vì bc kim nh IDW-MMD (Inverse Density-Weighted MMD) da trổn xp x Gamma [47] thay cho permutation test tn kỏm. Bng thũng kernel c x lý bng còch c lng γ mt ln bng median heuristic vị dúng chung cho toịn b tòn hìu trt (Mc 4.2.1), thay vớ mị ca s t c lng; lun vn khũng thc hnh ablation riỏng v nhy vì γ . V chin lc, lun vn xóy dng khng thờch ng theo loi drift, dúng kt qu phón loi t SE-CDT kòch hot còch cp nht phứ hp (Reset, Incremental, hoc Reuse) [13, 14]. V kin trũc, h thng c xut trin khai trổn nn tng Apache Kafka cho phỏp x lý lung phón tòn, tr thp vị

khả năng chu li.

Trong pipeline sản xuất, mô hình cần bao gồm mô hình nghiệp vụ như bộ phân loại chất lượng sản phẩm, dòng tiền, học bộ trợ dòng tiền. SE-CDT chuyên quan sát luồng dữ liệu vị sinh sản biến drift giảm thiểu, loại drift vị tồn tại hữu hạn. Adaptation Manager quản lý thành phần quyết định hình thức tiếp theo: bộ qua cảnh báo, yêu cầu xử lý, huấn luyện lại, cập nhật online học chuyển sang mô hình ổn định. Phân tách này giúp tránh hiểu nhầm rằng SE-CDT là mô hình dòng tiền chất lượng; SE-CDT là bộ monitoring vị ưu tiên phản ứng trước khi mô hình sản xuất suy giảm.

4.1.1 Tổng quan kiến trúc ba module

Trước khi đi vào chi tiết từng thành phần, Hình 4.1 minh họa tổng quan luồng xử lý của hệ thống. Ba module có kết nối liên tiếp, đầu ra của module trước là đầu vào của module sau.



Hình 4.1 Kiến trúc tổng quan: Hệ thống SE-CDT (gồm Detection Module chạy ShapeDD-IDW vị Classification Module phân tách hình dạng $\sigma(t)$) nhận luồng $\{X_t\}$ vị sản xuất nhận lỗi drift; Adaptation Module đứng nhận nhiệm vụ chọn chiến lược cập nhật mô hình phù hợp.

- **Detection Module** (Mc 4.2.1–4.2.1): ShapeDD-IDW liên tục theo dõi luồng $\{X_t\}$ qua các sự kiện, đồng thời tính toán MMD $\sigma(t)$, vị phát cảnh báo khi $\sigma(t)$ vượt ngưỡng. Đây là thành phần duy nhất tiếp xúc trực tiếp với dữ liệu đầu vào.
- **Classification Module — SE-CDT** (Mc 4.3): Nhận đồng thời Standard MMD $\sigma(t)$ từ bộ phát hiện vị phân tách hình dạng xử lý lỗi drift (TCD: sudden, blip, recurrent; hoặc PCD: gradual, incremental) mà không cần nhãn. Cập nhật toàn bộ, hai vai trò Detection vị Classification được triển khai trong cùng một lớp SE-CDT; phân tách thành hai tiến trình độc lập để triển khai Kafka (Mc 4.5).
- **Adaptation Module** (Mc 4.4): Dựa trên lỗi drift từ SE-CDT, chọn chiến lược cập nhật mô hình phù hợp (*Reset* cho sudden, *Incremental* cho gradual/incremental, hoặc *Reuse* cho recurrent).

Tổng hợp ba module được triển khai bằng mô phỏng, sau đó được triển khai trên Apache Kafka trong Mc 4.5, vì mỗi module chỉ nhận một tiến trình độc lập giao tiếp qua các topics riêng biệt. Hệ thống xuất ra gọi là **SE-CDT** (*ShapeDD-Enhanced Concept Drift Type identification*).

Tổn nịy nhn mnh vọ nng lc phón loi loi drift, vn lị úng gúp gc ca lun vn so vı còc phng phòp phòt hın thun tuỳ trc óy. Module phòt hın ca SE-CDT c t tổn riỏng lị **ShapeDD-IDW** vớ nú lị mt ci tin trc tip ca ShapeDD [7] bng IDW-MMD vı xp x Gamma; còch t tổn cú gch ni phn ònh quan h k tha vı phng phòp gc.

4.2 xut ci tin phng phòp phòt hın drift: IDW-MMD vı xp x Gamma

4.2.1 Inverse Density-Weighted MMD (IDW-MMD): Tı u húa hıu sut vı chỏnh xỏc

Vn ca c lng MMD truyn thng

Trong phng phòp gc, thng kỏ MMD c tỏnh toỏn da trỏn trng s u, coi vai trù ca mı im d liu trong ca s lı nh nhau. Nhc lı t Chng 2, cũng thc MMD cú dng:

$$\text{MMD}_{\text{uniform}}^2(X, Y) = \frac{1}{n^2} \sum_{i,j} k(x_i, x_j) + \frac{1}{m^2} \sum_{p,q} k(y_p, y_q) - \frac{2}{nm} \sum_{i,p} k(x_i, y_p) \quad (4.1)$$

trong ú còc tng chy qua tt c còc cp ch s, k c $i = j$. Vı kernel RBF, thnh phn t i sỏnh $k(x_i, x_i) = 1$, ngha lı mı im u úng gúp mt giò tr bng 1 vọ tng, lım giò tr MMD cao hn thc t mt chũt. Hn ch nıy s c khc phc trong cũng thc IDW-MMD trỏnh bị ngay di óy, bng còch loi còc cp im trỏng nhau khi phỏp tỏnh.

Vı ca s nh ($n, m < 200$), MMD d dao ng vı khú tỏch drift tht khi nhıu mu. Bc permutation test ca ShapeDD gc cng tn thi gian vớ phi lp lı phỏp tỏnh MMD nhıu ln c lng p-value. Mt nguyỏn nhón khỏc lı trng s u coi mı im trong ca s nh nhau, trong khi còch thay i t ngt thng xut hın rủ hn vớng biỏn phón phi.

Y tng ci tin bng còch đứg trng s thay i theo v trờ

Thay vớ gi trng s u, lun vn gòn trng s theo mt cc b: im vớng tha c nhn mnh hn, cùn im vớng trung tóm c gim bt nh hng. hỏnh thc húa, dng tng quỏt ca MMD cú trng s lı:

$$\text{MMD}_{\text{weighted}}^2(X, Y) = \sum_{i,j} w_i w_j k(x_i, x_j) + \sum_{p,q} v_p v_q k(y_p, y_q) - 2 \sum_{i,p} w_i v_p k(x_i, y_p) \quad (4.2)$$

trong ú w_i vı v_p lı trng s ca tng im (tha mỏn $\sum_i w_i = 1, \sum_p v_p = 1$). Cỏu hi t ra lı: tỏnh w_i nh th nọ phòt hın drift hıu qu?

Gii phòp xut: Trng s nghch bin mt (Inverse Density Weighting)

Lun vn xut phng phòp **IDW-MMD** (Inverse Density-Weighted MMD), mt còch gòn trng s n gin ly cm hng t ý tng weighted MMD trong Optimally-Weighted MMD ca Bharti et al. [21].


Phng phòp ca Bharti et al. c thit k cho bìi toàn suy lun thng kổ, xut trng s ti u phc tp vị khùng liồn quan n bìi toàn drift detection. Lun vn ch k tha ý tng “gòn trng s cho tng im d liu trong MMD” vị òp dng mt heuristic n gin hn (trng s nghch bin vị cn bc hai ca mt kernel) phứ hp vị bìi toàn drift detection.

Trng s w_i c tòngh đa trổn mt cc b, ch đứng còc cp im khòc nhau (off-diagonal) tròngh bias t tng quan:

$$w_i \propto \frac{1}{\sqrt{\sum_{j \neq i} k(x_i, x_j) + \epsilon}} \quad (\text{Inverse Density Weighting}) \quad (4.3)$$

trong ú ϵ lị mt hng s nh (vò d $\epsilon = 0.5$) m bo tòngh n nh s hc (numerical stability).

Khi mt im nm vúng trung tóm, tng mt $d(x_i)$ ln vị trng s ca im ú gim. Ngc li, im vúng biổn cú òt lớn cn hn nỏn nhn trng s cao hn (Hònh 4.2). Lun vn đứng $1/\sqrt{d_i}$ thay cho $1/d_i$ tròngh khuch i quò mnh còc im biổn n l, vn d b nhiu chỉ phi.



Hònh 4.2 C ch Trng s Nghch mt (IDW-MMD). Khòc vì MMD coi trng mi im nh nhau (A), IDW-MMD (B) t ng nỏn trng s ca vúng lủi (core) vị khuch i tòngh vúng biổn (boundary) — nì drift thng xy ra u tiổn.

Đa trổn phón tòch trổn, cũg thc IDW-MMD c xóy dng nh sau. t $d(x_i) = \sum_{j \neq i} k(x_i, x_j)$ lị mt cc b ca x_i , vị $\tilde{w}_i = 1/(\sqrt{d(x_i)} + \epsilon)$ lị trng s thũ. Ma trn trng s W_{ij}^{XX} ly tòch $\tilde{w}_i \tilde{w}_j$ cho còc cp $i \neq j$ ri chun hóa $\sum_{i \neq j} W_{ij}^{XX} = 1$ (ng chổo c loi tr theo U-statistic

style). Tng t cho W_{pq}^{YY} trón ca s Y . Cũng thc hoị chnh:

$$\text{MMD}_{\text{IDW}}^2(X, Y) = \underbrace{\sum_{i \neq j} W_{ij}^{XX} k(x_i, x_j)}_{\text{Weighted } XX} + \underbrace{\sum_{p \neq q} W_{pq}^{YY} k(y_p, y_q)}_{\text{Weighted } YY} - 2 \underbrace{\sum_{i=1}^n \sum_{p=1}^m \frac{1}{nm} k(x_i, y_p)}_{\text{Uniform } XY} \quad (4.4)$$

Thình phn so sòn chổ gia hai ca s gi trng s ng nht $1/(nm)$ vớ óy lị s hng o s chng chổ gia hai phón phi. Nu gòn trng s IDW cho cross-term, thng kổ cú th to khong còch gi ngay c khi hai ca s cú cũng phón phi, ch do cu trũc mt cc b khòc nhau. Cross-term vớ vy úng vai trũ trung lp, cùn Weighted XX vớ YY lịm rũ tòn hũu biổn.

H qu ca thit k nịy lị $\text{MMD}_{\text{IDW}}^2$ cú mt lch dng nh ngay c khi $P = Q$. lch nịy c x lý bc tòn p-value bng xp x Gamma (trnh bịy phn phón tồch phc tp bốn di), thay vớ t ngng th cũng trón giò tr MMD.

nh hng n tòn hũu phòt hìn

Khi dũng MMD gc, còc cp im vũng trung tóm thng chim phn ln tng thng kổ, lịm tòn hũu drift vũng biổn d b chơm. IDW-MMD gim nh hng ca vũng trung tóm vớ tng trng s cho còc im vũng biổn, nì sudden drift thng biu hìn sm hn.

Tuy nhiên, chònh c ch nịy lịm IDW-MMD ờt nhy hn vớ gradual drift — loi drift thay i dn t vũng trung tóm. Hn ch nịy c tho lun chỉ tit cui mc.

Thut toòn chỉ tit nh sau, trong ú mt cc b c tòn c lp trong tng ca s:

Gii thut 2 Inverse Density-Weighted MMD (IDW-MMD).

Require: Reference window $X = \{x_1, \dots, x_n\}$, test window $Y = \{y_1, \dots, y_m\}$, kernel $k(\cdot, \cdot)$, stability constant $\epsilon = 0.5$

Ensure: IDW-MMD statistic $\widehat{\text{MMD}}_{\text{IDW}}^2$

```

1: for  $i = 1$  to  $n$  do                                     ▷ inverse density weights for reference window  $X$ 
2:    $d(x_i) \leftarrow \sum_{j \neq i} k(x_i, x_j)$                      ▷ off-diagonal density; excludes self-kernel  $k(x_i, x_i)$ 
3:    $\tilde{w}_i \leftarrow 1 / (\sqrt{d(x_i)} + \epsilon)$ 
4: end for
5:  $\tilde{W}_{ij}^{XX} \leftarrow \tilde{w}_i \tilde{w}_j$  for  $i \neq j$ , else 0
6:  $\tilde{W}_{ij}^{XX} \leftarrow \tilde{W}_{ij}^{XX} / \sum_{i \neq j} \tilde{W}_{ij}^{XX}$                                      ▷ normalize so  $\sum_{i,j} \tilde{W}_{ij}^{XX} = 1$ 
7: for  $p = 1$  to  $m$  do                                       ▷ inverse density weights for test window  $Y$ 
8:    $d(y_p) \leftarrow \sum_{q \neq p} k(y_p, y_q)$ 
9:    $\tilde{v}_p \leftarrow 1 / (\sqrt{d(y_p)} + \epsilon)$ 
10: end for
11:  $\tilde{W}_{pq}^{YY} \leftarrow \tilde{v}_p \tilde{v}_q$  for  $p \neq q$ , else 0
12:  $\tilde{W}_{pq}^{YY} \leftarrow \tilde{W}_{pq}^{YY} / \sum_{p \neq q} \tilde{W}_{pq}^{YY}$ 
13:  $\widehat{\text{MMD}}_{\text{IDW}}^2 \leftarrow \sum_{i,j} \tilde{W}_{ij}^{XX} k(x_i, x_j) + \sum_{p,q} \tilde{W}_{pq}^{YY} k(y_p, y_q) - \frac{2}{nm} \sum_{i=1}^n \sum_{p=1}^m k(x_i, y_p)$  ▷ cross-term uses uniform
    weights  $1/(nm)$  as a geometric anchor; diagonal excluded from  $XX, YY$  terms (U-statistic style) return
 $\widehat{\text{MMD}}_{\text{IDW}}^2$ 

```

Phân tích phức tạp tính toán

phức tạp của IDW-MMD có phân tích trong Bng 4.1:

Bng 4.1 phức tạp tính toán của IDW-MMD và các phép phụ thuộc

Thí nghiệm	Thời gian	Bộ nhớ	Ghi chú
Kernel Matrix	$O(n^2)$	$O(n^2)$	n = window size
Density weights	$O(n)$	$O(n)$	Sum over rows
Weighted MMD	$O(n^2)$	$O(1)$	Scalar output
Xp x Gamma	$O(B \cdot n^2)$	$O(n^2)$	Hoàn v ch s, tài s dng K
IDW-MMD + xp x Gamma	$O(B \cdot n^2)$	$O(n^2)$	B vùng tính li kernel
ShapeDD gc (permutation)	$O(N_{\text{perm}} \cdot n^2)$	$O(n^2)$	Tính li kernel mi vùng

IDW-MMD có phức tạp $O(n^2)$, tương đương MMD. Permutation test để kiểm tra tính độc lập MMD² rất nhiều lần (với nhiều vùng) có log phân phối đa thức không drift, tốn $O(N_{\text{perm}} \cdot n^2)$. Thay vào đó, kiểm tra các hình ảnh xp x Gamma theo Gretton et al. [47]. Kỹ thuật *hoàn v ch s tài s dng kernel matrix* giúp giảm chi phí xuống $O(B \cdot n^2)$, vì B nhỏ hơn nhiều lần so với N_{perm} .

Theo Gretton et al. [17], phân phối giới hạn của thống kê MMD_u^2 phụ thuộc vào giả thuyết. Dưới giả thuyết có drift, MMD_u^2 tìm phân bố Gaussian xoay quanh giá trị MMD^2 thực. Nhưng dưới giả thuyết không có drift, MMD_u^2 *không* tìm phân bố Gaussian; nó tìm phân bố χ^2 . Với vậy, dùng Gaussian để xấp xỉ phân phối null có thể làm lệch mức ý nghĩa thực tế do vì α nhỏ.

Cách tiếp cận theo [47] là khớp một phân phối Gamma vào hai moment đầu (trung bình và phương sai) của phân phối đa thức không drift. Hai moment có thể tính bằng một số lần hoàn v ch s trở về cùng một mã trên kernel để tính số, nhờ đó kiểm tra không phân li kernel mà không cần permutation test. Cụ thể, sau khi tính kernel matrix K một lần cho hai dãy s :

1. Tính $\widehat{\text{MMD}}_{\text{IDW}}^2$ trở về cùng ban đầu của hai dãy s .
2. Hoàn v ngẫu nhiên các dãy s một số lần để tính li $\widehat{\text{MMD}}_{\text{IDW}}^2$ cho phân bố. Phân bố lý thuyết của null distribution; với K nhỏ, phân bố gần đúng $O(n^2)$ phức tạp hơn.
3. Khớp Gamma vào trung bình và phương sai của phân bố null và thu được, sau đó tính p-value (mức phi).
4. Nếu $p < \alpha$ (mức như $\alpha = 0.05$), kết luận có drift.

Trong thực nghiệm Chương 5, ShapeDD-IDW chạy nhanh hơn ShapeDD gc trong phổ biến ở cuối với không phi chạy permutation test để phân li ngẫu nhiên. Khi một số lần có nhiều hơn ngẫu nhiên, các p-value có thể vi phạm chính Bonferroni theo số lần kiểm tra trong cùng trace. Liệu chờ đợi của xp x Gamma là lý do cho việc xảy ra drift có thể thống kê rõ ràng hơn từ mức ý nghĩa $\alpha = 0.05$ (Mức 5.2.5), chỉ không chỉ lý thuyết mà thực tế.


Hình ảnh vị trí khi nổi bật

Mục đích IDW-MMD giúp bác sĩ khám bệnh nhận ra những thay đổi bất thường, biến đổi phân phối, tức là sự thay đổi bất thường do sudden drift, tức là sự thay đổi xảy ra tại một vị trí bất thường, phương pháp có hai giai đoạn chính: Với giám sát sự biến đổi trung tâm, IDW-MMD có thể kiểm tra sự thay đổi bất thường xảy ra chủ yếu trong vùng này. Các trọng số cũng không phù hợp phân loại lỗi drift, với nó có thể làm mất các trọng số hình dạng cần thiết cho gradual học incremental drift. Do đó, SE-CDT (Mục 4.3) phân tích hình dạng của tồn tại Standard MMD thay vì đứng trực tiếp tồn tại IDW-MMD.

Kiến trúc kết hợp của Detection Module

Trong trình bày cuối cùng, Detection Module ShapeDD-IDW không dùng IDW-MMD mà bác sĩ dùng kiến trúc kết hợp hai vai trò, tức là hình ảnh minh họa của Standard MMD và IDW-MMD:

1. Tồn tại $\sigma(t)$ của tồn tại Standard MMD (unbiased U-statistic, không trọng số). Tồn tại này giúp hình dạng tổng thể của drift, các vị trí gradual/incremental và thay đổi chủ yếu trong vùng trung tâm phân phối. Hình 4.3 minh họa cách hai các trường hợp tổng hợp dữ liệu tạo ra một hình ảnh tồn tại MMD.



Hình 4.3 Cách các trường hợp tồn tại MMD. Hình ảnh $\sigma(t)$ trở thành MMD (điểm) kết quả không có bất thường gia các tham chiếu W_{ref} và các kiểm tra W_{test} tổng hợp dữ liệu thử (trên).

2. Sau khi tóm tắt tồn tại Standard MMD, hình ảnh vẽ kiểm tra bằng IDW-MMD

vì p-value đã trộn lẫn χ^2 Gamma (xem Mc 4.2.1). IDW-MMD thay vì cố gắng thay thế bằng biến phân phối, cũng trộn lẫn χ^2 Gamma cùng với phân phối null cho các kiểm tra.

Bảng thống kê về logarit của logarit của bảng median heuristic trộn lẫn của lung, sau đó đứng nhất quán cho các ba ma trận kernel K_{XX}, K_{YY}, K_{XY} trong toàn bộ tồn tại. Cách này tránh được khi mà các thống kê logarit γ riêng.

Vì thế, kết quả tồn tại Standard MMD $\sigma(t)$ giá trị thống kê hình dạng cho các phân loại, trong khi IDW-MMD chỉ có đứng về xác nhận thống kê của module phát hiện ShapeDD-IDW. giao diện gia phát hiện vị phân loại, SE-CDT chỉ cần đưa ra các kết quả: các phát hiện drift, chuỗi tồn tại Standard MMD $\sigma(t)$, và danh sách p-value của các thống kê. Logic phân loại chỉ đứng $\sigma(t)$; nếu không thì IDW-MMD trực tiếp. Kết quả thực nghiệm của các phát hiện vị các hiệu chỉnh H_0 có thể bị bỏ qua Mc 5.2 và Mc 5.2.5.

Kiểm tra kết hợp trộn lẫn cho phép hình thức phát hiện drift vì chênh lệch cao và chỉ phù hợp toàn thể; tuy nhiên phát hiện chỉ là các, chỉ cần các thời gian phù hợp hình thức cùng các bit lỗi drift xảy ra. Phương pháp SE-CDT, tránh bị bỏ qua trong các kết quả, mà nhiệm vụ toàn phân loại drift không gồm sót.

4.3 Phương pháp phân loại drift SE-CDT

Sau khi bit lỗi drift xảy ra liên tiếp — hình thức cùng các bit drift thực tế lỗi, với mỗi lỗi drift thì chỉ cần các kết quả khác nhau. SE-CDT (ShapeDD-Enhanced Concept Drift Type) có thể kết quả quyết định toàn bộ.


Phương pháp tham khảo là CDT-MSW [8] vì không cần phát hiện vị phân loại drift trực tiếp, nhưng CDT-MSW cần nhận dữ liệu: nếu phân loại drift bằng cách so sánh chênh lệch phân loại giữa hai các (accuracy ratio $\tilde{P} = a_B/a_A$). Trong mỗi trường hợp không sót, không có nhận định toàn bộ chỉ số này.

SE-CDT dựa qua nhận định toàn bộ vị trực tiếp hình dạng của tồn tại MMD $\sigma(t)$ — tồn tại và có các thống kê phát hiện. Ý tưởng này là: mỗi lỗi drift là do hình dạng khác nhau trộn lẫn tồn tại MMD. Sudden toàn bộ nổi bật vị hợp. Gradual toàn bộ vị thời. Incremental toàn bộ hình dạng dần. Recurrent toàn bộ lặp lại liên tiếp. SE-CDT có những dữ liệu này ra quyết định phân loại.

4.3.1 Các lý thuyết

Theo phân loại của CDT-MSW, drift chia thành hai loại chính:


- **TCD (Transient Concept Drift):** Drift tạm thời vì thay đổi chuyển tiếp, gồm sudden, blip và recurrent (do toàn bộ lặp lại các kết quả thời gian).



Hình 4.4 Phóng to chi tiết MMD trong SE-CDT. Các công thức hình học như FWHM (quyết định Width Ratio) và Prominence (quyết định SNR) có thể xuất trực tiếp từ hình dạng của tín hiệu (baseline).

Ba công thức liên li mô tả xu hướng thời gian của tín hiệu:

1. **Linear Trend Strength (LTS):** Hệ số R^2 của hồi quy tuyến tính trên tín hiệu; Incremental của LTS cao.
2. **Step Detection Score (SDS):** Tỷ lệ các bước nhảy trong tín hiệu.
3. **Monotonicity Score (MS):** Tỷ lệ chiều hướng tăng (tăng hoặc giảm) trong tín hiệu.



Hình 4.5 Hình dạng tín hiệu MMD có các loại Drift. A) Sudden to nhám tam giác sắc nét; B) Gradual to nhám, dao động, xu hướng tuyến tính thấp; C) Incremental to nhám dốc tăng dần vì nhiễu cao; D) Blip to nhám nhọn cục bộ.

Hình 4.5 minh họa hình dạng tồn tại MMD ở trung ca trung loại drift, lý nên trung trung quan cho các trung núi trở.

Các trung hình học vị thí gian trở u ở trở xuất t *hình dạng* ca tồn tại MMD $\sigma(t)$. Tuy nhiên, thực nghiệm cho thấy hai loại drift chậm (Gradual và Incremental) cũng là hình dạng $\sigma(t)$ gần như giống hệt nhau (cứng lý một gù rỗng), khiến các trung LTS/MS/SDS không xác định được. Để khắc phục, luận văn bổ sung một trung tổng hợp tiếp trở *d liệu thử*, gọi là **Variance Ratio (VR)**, dựa trên **nh luật Tổng Phương Sai (Law of Total Variance)**.

Xét một ca s quan sát bị qua nhiễu drift. Giả sử C là biến chỉ thị khái niệm (concept) mà từ đó sinh ra. **nh luật Tổng Phương Sai** phân rõ phương sai trong ca s thành hai thành phần:

$$\underbrace{\text{Var}(X)}_{\text{tổng}} = \underbrace{\mathbb{E}[\text{Var}(X | C)]}_{\text{phương sai nội tại của trung khái niệm}} + \underbrace{\text{Var}(\mathbb{E}[X | C])}_{\text{phương sai giữa các trung bình khái niệm}}. \quad (4.5)$$

Hai loại PCD được phân loại (4.5) theo cách khác nhau:

- **Gradual drift** là một *hỗn hợp xác suất* (probabilistic mixture): trong giai đoạn chuyển tiếp, một số dữ liệu thuộc về khái niệm cũ và một số thuộc về khái niệm mới. Với ca s cha mẹ thì hai cụm phân phối tách biệt, thành phần *between-concept* $\text{Var}(\mathbb{E}[X | C])$ tăng vọt, làm tăng phương sai trong ca s **phương sai to** so với giai đoạn ổn định.
- **Incremental drift** là một *dịch chuyển trung bình liên tục* (continuous mean shift): từ từ thì hàm mật độ của phân phối duy nhất, trung bình của nó dịch chuyển dần dần. Trong một ca s như vậy, dữ liệu tập trung vào một phân phối mới với phương sai gần như **giảm xuống**; thành phần *between-concept* không đáng kể nên trung bình hỗn hợp.


Tóm tắt ngắn gọn, ta định nghĩa **Variance Ratio (VR)** là tỉ số giữa phương sai các quan sát ở trung ca s và trung ca s trước khi dịch chuyển l_2 vị phương sai cơ sở (baseline) ở trung ca s l_1 như sau:

$$\text{VR} = \frac{\max_i \sum_{d=1}^D \text{Var}\left(X_{[i, i+l_2)}^{(d)}\right)}{\sum_{d=1}^D \text{Var}\left(X_{[0, l_1)}^{(d)}\right)}, \quad (4.6)$$

trong đó $X^{(d)}$ là chuỗi dữ liệu d của dữ liệu (D chuỗi), ca s trước khi dịch chuyển vị bằng 5 mẫu giảm chi phí. Theo phân phối trở: $\text{VR} \ln (> \tau_{\text{VR}}^+)$ biểu hiện phương sai phương sai to do hỗn hợp $\Rightarrow$ **Gradual**; $\text{VR} \ln (< \tau_{\text{VR}}^-)$ biểu hiện phương sai nhỏ do dịch chuyển $\Rightarrow$ **Incremental**. Khi VR rơi vào vùng trung gian $[\tau_{\text{VR}}^-, \tau_{\text{VR}}^+]$ (thông thường vì dữ liệu nhiễu/phân phối), hệ thống lựa chọn quy tắc hình học LTS/MS/SDS không quyết định được.

Hình 4.6 minh họa trực quan về cách phân loại trở dữ liệu thử. Hình trở cho thấy: Gradual, do một số dữ liệu thuộc về hai khái niệm nên dữ liệu trải rộng trở c hai cụm trong ca s chuyển tiếp; còn Incremental, dữ liệu luôn nằm ở một cụm theo trung bình đang trở. Hình minh họa quan

sốt ú: phng sai ca s trt ca Gradual *nhũ lỏn rủ rt* so vi baseline, trong khi ca Incremental gn nh i ngang. Kt qu VR tng ng lị $VR_{\text{Gradual}} = 1.48$ v $VR_{\text{Incremental}} = 1.20$. Trng hp Gradual vt $\tau_{VR}^+ = 1.3$ nỏn c VR gòn trc tip lị Gradual. Trng hp Incremental li minh ho ỡng vũng khú: giò tr 1.20 nm trong vũng trung gian $[\tau_{VR}^-, \tau_{VR}^+] = [1.1, 1.3]$, tc VR *khũng* t kt lun c vị h thng phi lủi v b quy tc hnh hc LTS/MS/SDS. Vở d nịy cho thy VR tồch c chiu phng sai theo ỡng hng lý thuyt d oỏn, nhng biỏn tồch trỏn d liu mũ phng cùn hp — iu nịy gii thờch mt phn t l nhm ln Gradual/Incremental c phón tồch Mc 5.3.3.



Hình 4.6 Minh ho c ch Variance Ratio (VR) trỏn d liu thũ. (A, B) D liu thũ ca Gradual v Incremental drift: hn hp xỏc sut lịm d liu Gradual trỏn hai mc, cùn Incremental lị mt di hp trt dn. (C) Phng sai trỏn ca s trt: Gradual nhũ lỏn trỏn baseline (do thnh phn between-concept theo Eq. (4.5)), Incremental gĩ gn baseline. (D) Giỏ tr VR thu c vị vũng quy t nh: $VR > \tau_{VR}^+ \Rightarrow \text{Gradual}$; $VR < \tau_{VR}^- \Rightarrow \text{Incremental}$; vũng gia lủi v quy tc hnh hc.

Bng 4.2 tng hp toỏn b 10 c trng, giũp tra cu nhanh ý ngha vị iu kin phón loi ca tng c trng:

Bng 4.2 Tng hp còc c trng phón loi ca SE-CDT

c trng	Ký hiu	Cũng thc / Còch tòngh	Mìn giò tr	Ý ngha phón loi
<i>Nhóm 1: c trng hnh hc (Geometric Features)</i>				
Peak Width Ratio	WR	$\text{FWHM}/(2l_1)$	$[0, 1]$	Nh $\Rightarrow$ Sudden; Ln $\Rightarrow$ Gradual/Incremental
Peak Count	n_p	S nh vt ngng $\bar{\sigma}_s + 0.3\sigma_{\text{std}}$	$\mathbb{N}_0$	≤ 3 : Sudden; ≥ 4 : Recurrent
Periodicity CV	CV	$\text{std}(\Delta P)/\text{mean}(\Delta P)$	$[0, \infty)$	< 0.3 : Peaks u (Recurrent)
Signal-to-Noise	SNR	$\max(\sigma_s)/\text{median}(\sigma_s)$	$[1, \infty)$	> 2.0 : Peaks sc nốt (TCD)
Peak Proximity	PPR	Không còch gia hai peak c chn/ $ \sigma $	$[0, 1]$	Nh: hai peaks gn (Blip)
Dual-Peak Amp.	DPAR	$\min(h_1, h_2)/\max(h_1, h_2)$	$[0, 1]$	Trung bnh–cao: hai peaks cng ni bt (Blip)
<i>Nhóm 2: c trng thi gian (Temporal Features)</i>				
Linear Trend	LTS	R^2 ca hi quy tuyt tòngh trón σ_s	$[0, 1]$	> 0.5 : Xu hng tuyt tòngh (Incremental)
Step Detection	SDS	T l bc nhy $> 1.5\sigma$ trong σ_s	$[0, 1]$	> 0.12 : Nheu bc nhy (Incremental)
Monotonicity	MS	$ n^+ - n^- /(n^+ + n^-)$	$[0, 1]$	> 0.6 : n iu mnh (Incremental)
<i>Nhóm 3: c trng phng sai trón d liu thũ (Raw-data Variance Feature)</i>				
Variance Ratio	VR	$\max_i \text{Var}(X_{[i, i+l_2]})/\text{Var}(X_{[0, l_1]})$	$[0, \infty)$	> 1.3 : Hn hp (Gradual); < 1.1 : Dch chuyn n (Incremental)

4.3.3 Thut toàn phón loi

Bng 4.3 lit kỏ toịn b siỏ tham s ca thut toàn cng giò tr mc nh.

Bng 4.3 Siỏ tham s ca SE-CDT vị giò tr mc nh

Tham s	Giò tr mc nh	Vai trò
σ_g	4	Bng thũng b lc Gauss lịm mt tòngh hiu
α	0.3	H s nhón ngng tởm nh
τ_ℓ	1	Ngng dị tòngh PCD khi TCD
$\tau_{\text{WR}}^{\text{blip}}$	0.30	Chn trón WR cho Blip (nhòngh compact)
τ_{PPR}	0.20	Chn trón Peak Proximity Ratio cho Blip
τ_{DPAR}	0.60	Chn di Dual-Peak Amplitude Ratio cho Blip
τ_{LTS}	0.5	Ngng xu hng tuyt tòngh mnh
τ_{LTS}^-	0.3	Xu hng tuyt tòngh yu (iu kin kt hp)
τ_{MS}	0.6	Ngng n iu
τ_{SDS}	0.12	Ngng phòt hin bc nhy
τ_{VR}^+	1.3	Chn trón Variance Ratio (vt $\Rightarrow$ Gradual)
τ_{VR}^-	1.1	Chn di Variance Ratio (thp hn $\Rightarrow$ Incremental)
τ_n^{blip}	3	S nh ti a cho Blip
τ_n^{sud}	3	S nh ti a cho Sudden
τ_n^{rec}	4	S nh ti thiu cho Recurrent
τ_n^{inc}	7	S nh d phùng cho Incremental
τ_{WR}	$0.15^\dagger$	Ngng Peak Width Ratio cho Sudden
τ_{SNR}	$2.0^\dagger$	Ngng Signal-to-Noise cho TCD
τ_{CV}	$0.30^\dagger$	Ngng Periodicity CV cho Recurrent
τ_{match}	0.15	Ngng so khp Concept Memory (Mc 4.3.7)

† Ba ngng nịy lị giò tr tnh mc nh; khi bt t hiu chnh chũng cú th c ni lỏn theo phón v quan sỏt trón ca s khũng drift (Mc 4.3.6).

Gii thut 3 tróngh bịy toịn b quy tróngh phón loi theo tng bc:

Gii thut 3 SE-CDT — Unsupervised Drift Type Classification

Require: Drift magnitude signal $\sigma(t)$ (Standard MMD) from Detection Module

Require: Raw data window W (dùng cho Variance Ratio)

Require: Threshold parameter set Θ (see Table 4.3); τ_{WR} , τ_{SNR} , τ_{CV} self-calibrated (Section 4.3.6)

Ensure: Drift type: one of {TCD-Blip, TCD-Sudden, TCD-Recurrent, PCD-Gradual, PCD-Incremental}

```


1:  $\sigma_s \leftarrow \text{GaussianFilter}(\sigma, \sigma_g)$  ▷ smooth signal
2:  $P \leftarrow \text{FindPeaks}(\sigma_s, \bar{\sigma}_s + \alpha \sigma_{\text{std}})$ 
3: Compute geometric features:  $n_p \leftarrow |P|$ , WR, CV, SNR, PPR, DPAR
4: Compute temporal features: LTS, SDS, MS
5:  $VR \leftarrow \text{VarianceRatio}(W)$  ▷ Eq. (4.6), trỏ d liu thũ
6:  $\ell \leftarrow \text{EstimateDriftDuration}(\sigma_s)$  ▷ via peak FWHM
7: if  $n_p \leq \tau_n^{\text{blip}}$  and  $WR < \tau_{WR}^{\text{blip}}$  and  $\text{BlipProfile}(\text{PPR}, \text{DPAR}, \text{SNR}, \text{LTS})$  then return TCD-Blip
8: end if
9: if  $\ell > \tau_\ell$  then ▷ wide peak  $\Rightarrow$  PCD
10:   if  $\text{IsINCREMENTAL}(VR, \text{LTS}, \text{MS}, \text{SDS}, n_p)$  then return PCD-Incremental
11:   elsereturn PCD-Gradual
12: end if
13: end if
14: if  $n_p \leq \tau_n^{\text{sud}}$  and  $WR < \tau_{WR}$  and  $\text{SNR} > \tau_{\text{SNR}}$  then return TCD-Sudden
15: end if
16: if  $n_p \geq \tau_n^{\text{rec}}$  and  $CV < \tau_{CV}$  and  $\text{LTS} < \tau_{\text{LTS}}$  then return TCD-Recurrent
17: end if
18: if  $\text{IsINCREMENTAL}(VR, \text{LTS}, \text{MS}, \text{SDS}, n_p)$  then ▷ PCD fallback return PCD-Incremental
19: elsereturn PCD-Gradual ▷ default
20: end if

21: function  $\text{IsINCREMENTAL}(VR, \text{LTS}, \text{MS}, \text{SDS}, n_p)$ 
22:   if  $VR > \tau_{VR}^+$  then return false ▷ phng sai phng to  $\Rightarrow$  Gradual
23:   end if
24:   if  $VR < \tau_{VR}^-$  then return true ▷ phng sai n nh  $\Rightarrow$  Incremental
25:   end if
26:   // Vng trung gian: lũi v quy tc hnh hc
27:   if  $\text{LTS} > \tau_{\text{LTS}}$  then return true
28:   end if
29:   if  $\text{MS} > \tau_{\text{MS}}$  and  $\text{LTS} > \tau_{\text{LTS}}^-$  then return true
30:   end if
31:   if  $\text{SDS} > \tau_{\text{SDS}}$  and  $\text{LTS} > \tau_{\text{LTS}}^-$  then return true
32:   end ifreturn  $n_p \geq \tau_n^{\text{inc}}$ 
32: end function

```

Trong thut toàn, BlipProfile gm hai trng hp: cp peak gn nhau vì DPAR cao, hoc profile nhieu ngn hn cú WR nh, SNR trung bnh, DPAR mc va phi vị LTS thp. iu kin nỳ c kim tra trc nhnh PCD vớ nhieu blip cú FWHM hi rng do nhieu, nu xõit $\ell > 1$ trc s d b gòn nhm thnh Gradual.

Hnh 4.7 minh ha trc quan lung quy nh phón loi drift ca SE-CDT (tng ng vì Gii thut 3):



Hình 4.7 Lu quy trình phát hiện drift của SE-CDT (Ghi chú 3). Lưu ý: kiểm tra Blip để kiểm tra trực tiếp sự hiện diện của peak nhiễu ngẫu nhiên chuyển đổi vào mô hình PCD. Tồn tại cú nhúng ($\ell > \tau_\ell$) có thể phát hiện trực tiếp lỗi PCD; các trường hợp còn lại cần kiểm tra lần lượt Sudden, Recurrent, trước khi fallback về PCD theo cách thức gián tiếp (Bảng 4.2).

4.3.4 Ưu điểm và phức tạp

SE-CDT có một số ưu điểm mang lại sự khác biệt so với CDT-MSW:

- **Khả năng giám sát:** Hoạt động theo kiểu không giám sát, không cần nhãn dữ liệu, phù hợp với dữ liệu thực.
- **Tính hiệu quả:** Sử dụng tồn tại của Standard MMD $\sigma(t)$ để tổng hợp trong quá trình phát hiện nhiễu drift, không cần thêm bất kỳ thông tin riêng lẻ.

- **Thi gian thc:** Phón loi ngay sau khi phòt hin drift vì chi phờ $O(m)$ tuyn tòn — rt nh so vì bc phòt hin.
- **Phón tòch phòt hin vị phón loi:** Toịn b pipeline phòt hin — tòn tòn hui Standard MMD, tòm nh ng viỏn, vị kim nh bng IDW-MMD vì xp x Gamma — thuc module ShapeDD-IDW vị c xem nh mt bc phòt hin c lp. Module phón loi nhn li tòn hui Standard MMD $\sigma(t)$ t module phòt hin vị ch đứng $\sigma(t)$ nịy cho bc phón loi; logic phón loi ca SE-CDT khũng gi IDW-MMD trc tip.

V phc tp tòn toòn ca toịn b quy trnh:

- **Detection (ShapeDD-IDW):** $O(n^2 \cdot T/\text{step})$ vì n = kỏch thc ca s, T = ỉj stream, step = bc trt. óy lị bc chim chi phờ chỏnh.
- **Classification (SE-CDT),** chy sau khi bc phòt hin tr v $\sigma(t)$ vì m im:
 - Lịm mt tòn hui: $O(m)$
 - Tòm cc i cc b: $O(m)$
 - Trỏch c trng t cỏc peak: $O(n_p)$ vì n_p lị s peak
 - So sỏnh ngng phón loi: $O(1)$
- Tng chi phờ phón loi lị $O(m)$, tuyn tòn theo ỉj tòn hui.
- Tng chi phờ quy trnh vn ch yu nm bc phòt hin: $O(n^2 \cdot T/\text{step})$.

Vỏ vy, bc phón loi ch thỏm mt phn chi phờ nh so vì phỏp tòn MMD trong bc phòt hin.

4.3.5 Gii thờch la chn ngng

Cỏc ngng trong Gii thut 3 c xỏc nh trỏn synthetic datasets vì ca s chun $n, m \approx 200$, da trỏn cỏc quan sỏt sau: Blip c nhn ỉn bng hai hoc ba peak ngn hn, trong ú hai peak ni bt nht cú quan h ỉn v v trỏ hoc cú profile phứ hp vì mt xung ngn b nɦu. Sudden thng cú ỏt peak, nh hp vị SNR cao. Recurrent cú nɦu peak tng i u, cũn incremental vị gradual c tòch bng cỏc c trng thi gian nh LTS, SDS vị MS. Gradual lị trng hp mc nh khi tòn hui kỏo ỉj nhng khũng cú xu hng tuyn tòn rủ.

Toịn b ỉờ tr ngng c th nm trong Gii thut 3 vị c ti u cho ca s chun $n, m \approx 200$. Nu thay i kỏch thc ca s, cỏc ngng v ỉng nh, SNR, hay khong cỏch peak cũn c hui chnh lị; vì ỉ liu thc t, khuyn ỉnh tĩnh chnh trỏn mt tp ỉ liu nh c thứ cho tng mĩn ng ỉng.

Cỏc ngng trỏn lị heuristic thc ỉnhm, khũng phi kt qu suy ỉn lị thuyt. ỉim ph thuc vịỏ cỏc con s cũng, Mc 4.3.6 b sung c ch t iu chnh ngng theo mc nɦu nn quan sỏt c, vn khũng cũn nhỏn. Cỏc hn ch cũn lị c tho lun trong Chng 6.

4.3.6 T hieu chnh ngng phón loi (Online Self-Calibration)

Ngng cng cú mt vn thc t: ngng SNR “sc nốt” trở lung d liu sch cú th khũng th t c trở lung cú nhiu nn cao. Kt qu lị cứng mt nh sudden tht cú th b b qua ch vớ nn nhiu ca lung d liu mi cao hn lung hun luyn.

khc phc mị vn khũng đứng nhõn, lun vn b sung mũ-un **Rolling Feature Baseline**. Ý tng n gin: khi khũng cú drift, h thng quan sòt còc c trng SNR, WR, CV trũng nh th nịo vị lu li lịm chun. Khi cú drift mi cn phón loi, ngng phón loi c iu chnh theo chun nịy thay vớ đứng giò tr cng.

C th, mi khi mt ca s c kt lun lị *khũng cú drift*, ba c trng SNR, WR, CV c trỏch xut vị a vĩa mt b m vùng. H thng đứng phón v thc nghim t b m nịy iu chnh ngng: ly giò tr ln hn gia ngng tnh vị phón v quan sòt c.

C ch nịy tồc ng khòc nhau lỏn tng c trng:

- **Vi SNR:** Sudden cn SNR ln hn ngng. Kỏo ngng lỏn theo phón v th 90 ca baseline lịm iu kin khú t hn, giúp trỏnh nhm peak nhiu thịn Sudden khi nn nhiu cao.
- **Vi WR vị CV:** iu kin phón loi lị “phi nh hn ngng”. Kỏo ngng lỏn theo phón v th 25 ca baseline lịm iu kin d t hn, giúp còc peak Sudden trở stream nhiu (vn cú WR/CV cao hn bớnh thng) vn c bt ỹng.

C ch nịy ch iu chnh theo mt chiu gi nguyỏn hịn v vị trở còc lung d liu sch. Khi nhiu nn mc bớnh thng, ngng tnh tip tc c đứng; ch khi nn nhiu cao bt thng, ngng mi c iu chnh.

Baseline ch cp nht khi ca s va ri khũng phòt hìn drift vị tỏn hiu MMD dặ còc c trng cú ỳ ngha thng kỏ. B m cú ca s lịm núng (warm-up): trc khi tỏch lu mt s mu ti thiủ, h thng đứng ngng tnh trỏnh ngng thờch nghi chy theo nhiu giai on u stream. Ba u im chỏnh: (i) vn khũng cn nhõn khi vn hịn — baseline ch đứng tỏn hiu MMD, khũng cn y ; (ii) n nh trở d liu sch — trở còc lung ỏt nhiu, ngng gn nh gi nguyỏn so vị cu hớnh tnh; (iii) d ỏp dng gia còc mìn d liu — cứng mt SE-CDT cú th thờch nghi tt hn khi mc nhiu nn thay i.

4.3.7 B nh khòl nìm cho Recurrent Drift (Concept Memory)

Recurrent drift cú ngha lị phón phi ỏ tng xut hìn trc óy quay li. Nu khũng cú c ch ghi nh, lut phón loi theo ngng s khũng bit iu nịy vị phón loi nhm mị ln lp li lị mt s kin sudden riỏng l. Lun vn b sung mũ-un **Concept Memory** — mt b m vùng lu li còc phón phi ỏ gp — gii quy t vn nịy.

Bình chọn từ tập M mẫu mới, mỗi mẫu S_k có kích thước n_s tìm vị trí ngay sau khi một drift có thể hình thành như trên. Cũng vì mỗi S_k , hệ thống lưu trữ γ_k có bằng median heuristic thì tìm vị trí, đúng cho bộ ước lượng bandwidth trung bình khi số khớp sau này.

Khi SE-CDT phát hiện một drift mới, quy trình tra cứu diễn ra như sau:

1. Trích xuất mẫu sau drift S^{new} từ các tập dữ liệu.
2. Vì mỗi $S_k \in \text{Memory}$, ước lượng *Standard MMD* giữa S^{new} với S_k bằng RBF kernel với γ lấy trung bình $(\gamma_k + \gamma_{\text{new}})/2$.
3. Nếu tồn tại k^* sao cho $\text{MMD}(S^{\text{new}}, S_{k^*})$ nhỏ hơn ngưỡng số khớp τ_{match} , drift có thể gọi là **TCD-Recurrent**.
4. Nếu không tìm được mẫu phù hợp, S^{new} có thể thêm vào bình chọn vị trí mẫu mới thay thế.

Ngưỡng τ_{match} có thể cao hơn hoặc thấp hơn vì nhiều lần của MMD trở về phân phối Gaussian ngẫu nhiên, tránh bỏ sót hai concept khác nhau liên quan nhau. Giá trị của M , n_s , τ_{match} với nhiều lần tham chiếu có thể bổ sung tham số thực nghiệm (Chương 5).

Concept Memory dùng *Standard MMD* thay vì *IDW-MMD* với bất kỳ toàn bộ vị trí số khớp hai mẫu mới xem chúng có thể có một phân phối hay không. *IDW-MMD* chỉ phụ thuộc vào bộ xử lý thống kê trong module phát hiện ShapeDD-IDW; logic phân loại vị trí Concept Memory không gọi *IDW-MMD* trực tiếp. Lưu ý liên quan của Concept Memory là mẫu mới sau drift vị trí hiện tại *Standard MMD* $\sigma(t)$.

Concept Memory có thể gọi sau bộ phân loại theo ngưỡng ban đầu vị trí chỉ relabel thành Recurrent khi kết quả phân loại Blip. Lưu ý tránh trong hợp một nhiều lần quay lại phân loại có thể nhận thành recurrent drift.

Kết quả phân loại từ SE-CDT có thể được kết hợp để tránh bị lặp lại trong phân tích tiếp theo.

4.4 Khung chín lẻ thòch ng mẫu hình

Để tránh kết quả phân loại từ SE-CDT, hệ thống kết hợp chín lẻ có thể mẫu hình khác nhau cho từng loại drift. Có thể tìm thấy các công trình của Guo *et al.* [8], Gama *et al.* [13], Lu *et al.* [14], và Yuan *et al.* [5].

4.4.1 Ma trận quyết định chín lẻ

Thay vì tập dữ liệu một chín lẻ duy nhất (như huấn luyện liên tục) cho mỗi trường hợp, hệ thống xuất ra các thông tin về loại drift để đưa ra chỉ số vị trí hiệu suất. Bảng 4.4 mô tả định nghĩa loại drift vị trí chín lẻ thòch ng:

Bng 4.4 Chin lc thờch ng theo loi Drift

Loại Drift	Chín lc Thờch ng	C s lý lun
Sudden	Hun luy n li nhanh: Khi to li mũ hnh vị hun luy n trón ca s d liu mi nht sau drift.	D liu c khũng cùn giồ tr, cn loi b hoị n toị n trờn nhiu (negative transfer).
Incremental	Cp nht liỏn tc: Cp nht mũ hnh hin ti vị d liu mi.	S thay i mang tồnh tim tin, kin thc c vn cùn giồ tr mt phn.
Gradual	Ca s cú trng s: u tiỏn d liu mi nhng vn gi li mt phn d liu c.	Giai on chuy n tip cú s pha trn gia hai phón phi, cn b nh m.
Recurrent	Lu vị đứg li mũ hnh: Tỏm kim trong kho lu tr mũ hnh c phứ hp vị kờch hot li.	Tỏi s dng tri thc õ hc, tit kim chỉ phờ hun luy n li.
Blip	Khũng cp nht hoc cp nht rt nh: B qua hoc cp nht vị trng s rt thp.	Thay i ch lị nhiu tm thi, trờn vic mũ hnh “quỏn” kin thc n nh.

Vic chn chín lc trong Bng 4.4 cn tốt thm bn yu t vn hình. Th nht lị chỉ phờ false alarm: nu mi cnh bõo kõo theo retrain tn GPU hoc dng kim nh cht lng, h thng nõn dũng cooldown dị hñ vị ngng cht hñ. Th hai lị tr nhõn: khi nhõn cht lng n sau vị gi hoc vị ngìy, SE-CDT ch úng vai trũ cnh bõo sm vị Adaptation Manager cú th ch thõm xõc nhñ. Th ba lị loi drift: sudden thng cn reset nhanh, gradual cn recency weighting, incremental hp vị warm-start/online update, recurrent hp vị cache, cùn blip nõn b qua. Th t lị chỉ phờ b sút drift: trong mìn ri ro cao, false negative cú th lịm mũ hõnh suy gìm óm thm, nõn cn u tiõn recall vị thõm kim duy t ca chuyõn gia trc khi trin khai mũ hõnh mĩ.

4.4.2 nh hng ca bào ng sai vị b sút drift

False alarm không chỉ là một lỗi thống kê mà còn là lỗi về mặt hình thức. Một cảnh báo sai cú pháp hoặc hot retrain không cần thiết, làm mất hiệu quả thay vì kiểm soát (model churn), tăng chi phí và, tồi tệ hơn nữa là tính toán vị trí tiềm ẩn rủi ro khi mô hình mới chưa kịp cập nhật. Ngược lại, false negative làm trôi dạt thuật toán không thể xử lý; mô hình sẽ xuất hiện các lỗi trở nên phổ biến, dẫn đến model decay vì giảm độ tin cậy của dữ liệu chất lượng học bao quát.

Lưu ý rằng đối tượng mà chúng ta đang xem xét là một prototype: cooldown sau mỗi drift event không phải là một hằng số, mà thay đổi theo tình huống. Khi một trace có nhiều nhiễu loạn, tình huống thay đổi theo chi phí vận hành, vị trí không gian của mô hình khi drift có thể xảy ra. Vì vậy, điều quan trọng là phải có một cơ chế để quản lý sự thay đổi này. SE-CDT chỉ cung cấp một cơ chế để quản lý sự thay đổi này, không thể quyết định khi nào thay đổi mô hình.

4.4.3 Trìn khai còc chín lc

Chín lc cho Sudden Drift (Trng tóm nghiêng cu)

Trong phm vi lun vn, chín lc cho *Sudden Drift* c cị t vị ònh giò chi tit nht. Quy trnh c th nh sau:

1. **Kồch hot:** Khi SE-CDT phón loi drift lị “Sudden”.
2. **Thu thp d liu:** H thng ch vị thu thp mt lng d liu mi (N_{new}) ngay sau im drift.
3. **Hun luyt li:** Mt instance mũ hnh mi (vò d: Logistic Regression) c khi to vị trng s ngu nhĩn vị hun luyt trũn N_{new} .
4. **Thay th:** Mũ hnh c b loi b hoịt toịt, mũ hnh mi c a vĩa s dng.

Model Caching theo Concept Memory


Khi phón loi tr v Recurrent, h thng ti li mũ hnh ò c gn vị mu phón phi khp trong Concept Memory (Mc 4.3.7) vị tinh chnh nh trũn ca s d liu mi. Mi mu S_k trong b nh c lu kỏm tham chiu ti mũ hnh ò hun luyt trũn giai on n nh tng ng, trỏnh phi hun luyt li t u cho khòì nim ò gp.

4.5 Kin trũc xut cho h thng phòt hìn trũi đt vị cp nht mũ hnh thờch ng

hìn thc hĩa còc phng phòp trũn trong mũ trng d liu lung, lun vn xut mt kin trũc x lý phón tòn da trũn Apache Kafka [48, 49]. Kafka c chn vớ nú cung cp mt commit log phón tòn, bn vng vị cú th phón vũng, cho phỏp nhĩu thnh phn tiỏu th cũng mt lung d liu mt còch c lp [50, 51]; óy chỏnh lị tỏnh cht mị mt tng giòm sòt drift cn, vớ module phòt hìn, module phón loi vị b thờch ng phi c cũng lung c trng còc nhp khỏc nhau mị khũng chn nhau. Nn tng nịy cng ò c đũng quy mũ sn xut cho còc ng ng d liu thi gian thc [52, 53]. Kin trũc nịy c thit k theo hng tỏch bit thnh phn, d m rng vị d theo dũi. Tuy nhĩn, phn nịy trỏnh bịy thit k kin trũc vị mt nguỷn mu kim th trũn nn tng tng thờch Kafka (Redpanda), khũng phi h thng vn hnh hoịt chnh trong sn xut. Còc khờa cnh h tng phón tòn — tr di ti cao, thũng lng khi tng s phón vũng, vị thi gian phc hi khi cú li — nm ngoịi phm vi ònh giò ca lun vn vị c xp vĩa hng phòt trin tip theo (Chng 6). Còc ònh giò trong Chng 5 tp trung vĩa hũu nng thut toòn, khũng phi hũu nng h tng.

4.5.1 Tổng quan kiến trúc

Hệ thống được thiết kế theo mô hình **kiến trúc luồng s-kim** (Hình 4.8), gồm các thành phần hoạt động và vị trí giao tiếp qua các Kafka topics:



Hình 4.8 Sơ đồ kiến trúc hệ thống phát hiện vị thời lệch Drift

1. **Data Producer (Nguồn dữ liệu):** Mô phỏng học thu thập dữ liệu từ cảm biến/nguồn phát, gửi vào topic `sensor.stream`.
2. **SE-CDT Analysis Consumer (Bộ xử lý phân tích):** Nhận dữ liệu từ luồng, thực hiện phát hiện lệch bằng ShapeDD/MMD và phân loại lệch nếu có thay đổi. Kết quả gửi về vị trí lệch vào topic `drift.results`.
3. **Adaptation Manager (Bộ thích nghi):** Nhận thông tin từ `drift.results`, lựa chọn chiến lược cập nhật mô hình phù hợp để điều chỉnh lệch đã phân loại.

4. **Monitoring Dashboard:** Trc quan hóa d liu lung, trng thời h thng, vị lch s còc ln thờch ng.

4.5.2 Thit k chi tit còc thịnh phn

Producer vị Data Ingestion

Producer c thit k chu li vị m bo tòn h toin vn d liu:

- S dng c ch **retry with exponential backoff** x lý mt kt ni mng.
- D liu c úng gói di dng JSON gm thi im, vector c trng vị thũng tin mũ t.
- H tr iu chnh tc phòt tin mũ phng còc mc ti khòc nhau.

Consumer vị C ch Windowing

Thịnh phn Consumer úng vai trù quan trng nht, thc hin phòt hin drift:

- **Circular Buffer:** Duy tró mt b m tun hoìn (750 mu trong nguốn mu, xem Ph lc A.4) trong b nh phc v tòn h toìn ca s trt mị khũng cn truy xut li Kafka quò nhieu.
- **4-Phase Lifecycle:**
 1. *Pre-training:* Thu thp d liu ban u hun luy n mũ hnh gc.
 2. *Warm-up:* Giai on n nh, thit lp baseline hieu sut.
 3. *Monitoring:* Mũ hnh chy ch d oòn, liò n tc kim tra drift bng ShapeDD.
 4. *Adaptation:* Tm dng monitoring cp nht mũ hnh khi cú drift.

Qun lý Topic vị Giao tip

H thng s dng còc topic riò ng bit phón tòn h lung d liu vị lung iu khin:

Bng 4.5 Danh sòch Kafka Topics vị Chc nng

Topic Name	Ni dung	Mc ờch
sensor.stream	Raw data samples	Lung d liu u vọ cho h thng phón tòn h.
drift.results	Drift info & Type	Kt qu phón tòn h t SE-CDT (V trờ + Loi Drift).
model.updated	Model metadata	Thũng bõo mũ hnh mĩ õ sn sng (hot-reload).
model.accuracy	Performance metrics	D liu giòm sòt chònh xòc real-time.

4.6 C ch chu li vị m bo tin cy

Trong mũ trng phón tòn, còc s c lị khũng th trờn h khi. H thng xut tòn h hp còc c ch chu li (Fault Tolerance) nhieu cp :

4.6.1 X lý li mc ng dng

- **Suy gim cú kim soét:** Nu b thờch ng gp li (vở d: trịn b nh khi hun luyn), h thng tip tc đứng mũ hnh c vị ghi cnh bõo thay vớ dng toịn b lung x lý.
- **X lý ngoi l:** Quò trnh tồnh toòn ShapeDD c bc trong còc khi an toịn x lý còc ngoi l s hc mị khũng lịm dng Consumer.

4.6.2 X lý li mc h tng (Kafka)

- **Replication:** Còc topic quan trng c cu hnh `replication.factor=3` m bo khũng mt d liu ngay c khi 1-2 broker b li.
- **Offset Management:** Consumer ch commit offset sau khi õ x lý xong batch d liu, m bo ng ngha “at-least-once” (khũng b sút d liu).
- **Consumer Rebalancing:** Nu mt Consumer b li, Kafka s t ng phón phi li còc partition cho còc Consumer cùn li trong nhúm.

4.7 Kt lun chng

Chng nịy õ trnh bịy mũ hnh xut **SE-CDT**, bao gm ci tin thut toòn phòt hìn, phng phòp phón loi drift, khng thờch ng theo loi drift vị kin trũc h thng da trỏn Kafka. Ci tin thut toòn c ònh giò the ngħim trong Chng 5, cùn kin trũc Kafka c xem nh nguyổn mu cho còc bc trin khai the t sau nịy.

CHNG 5

THC NGHIM VỊ ÒNH GIÒ

5.1 Tng quan thc nghim

5.1.1 Mc tiêu vị cu trức chng

Chng này trnh bày kt qu thc nghim ònh giò h thng xut. ònh giò gm ba phn, tng ng vị ba phn ca h thng:

1. **ònh giò kh nng phòt hin drift:** So sònh ShapeDD vị bin th ci tin ShapeDD-IDW vị IDW-MMD cng vị còc phng phòp nn tng trón nhiu tp d liu, tp trung vịo vic ònh giò trón còc tp d liu sudden drift lị kch bn ShapeDD c thit k x lý.
2. **ònh giò kh nng phón loi drift ca SE-CDT:** kim tra chònh xòc khi nhn din loi drift (sudden, gradual, incremental, recurrent, blip) đa trón tòn hiu drift magnitude.
3. **ònh giò kh nng thờch ng:** o hiu qu ca còc chin lc cp nht mữ hnh t ng qua ch s Prequential Accuracy.

5.1.2 Mũi trng vị cu hnh

Còc tham s mũi trng vị thut toàn c mữ t gn vị tng kch bn (Detection, Classification, Adaptation) thay vớ trnh bày chung, d cú th ònh giò mt còch tng quòt vị cú th thc hin li.

5.1.3 Tp d liu thc nghim

H thng c ònh giò trón b **14 tp d liu**, gm còc tp tng hp (synthetic), mt tp gradual drift c thit k th cng, mt tp recurrent drift dng i xng (Gaussian Recurrent Stream) vị mt tp bòn thc t (Electricity semi-synthetic).

Mc nịy mữ t tng cng 15 tp, nhng benchmark phòt hin ch đứng 14. Trong ú, c th lị tp Stepping Drift c mữ t cứng nhúm Sudden cho lin mch nhng *ch* phc v ònh giò thờch ng (Mc 5.4), nỏn khũng nm trong 14 tp ca benchmark phòt hin. Trong 14 tp cùn li, tp Gaussian Stationary khũng cha drift nỏn c tòch riỏng o bòu ng gị vị khũng xut hin trong còc bng F1 theo dataset; vớ vỵ còc bng F1 (Bng 5.4–5.7) lịt kỏ 13 dừng dataset.

Còc tp tng hp c sinh bng b sinh chun ca th vin River [54], mt framework mỗ ngun m ph bin trong cng ng data stream mining. Lỳ do đứng d liu tng hp thay vớ d liu thc t thun lị vớ vị d liu thc, thi im xy ra concept drift (ground truth) hu nh khũng bit c, nỏn khũng th o F1-Score hay Detection Delay. B sinh chun cho phỏp kim soỏt v trờ, cng vị loi drift, giũp kt qu cú th tời lp.

Cu hỏnh ònh giò phòt hin. B ònh giò gm 14 tp d liu, mị tp chy 30 seed c lp. Hai tp c thỏm nh ngha drift mt còch cht ch (d liu recurrent dng i xng $A \rightarrow B \rightarrow A \rightarrow B \dots$, ửng nh ngha ca Lu et al. [14]) vị d liu chuyn tip tuyn tởnh trỏn mt khong xỏc nh trc. Mt tp d liu tnh úng vai trờ o bòu ng gị. S ln chy lị 30 ln chy kim nh Friedman/Nemenyi ti $\alpha = 0.05$ vị n nh cao hn cho còc ch s trung bớnh.

Còc tp d liu c phón loi da trỏn bn cht ca s thay i phón phi:

Nhúm 1: Sudden Drift (Thay i $P(X)$ t ng): óy lị trng tóm chờnh ca module phòt hin SE-CDT (ShapeDD-IDW). Còc dataset nịy cha s thay i t ng trong phón phi u vịo $P(X)$ (Covariate Shift), nị còc phng phỏp unsupervised cn phi phòt hin chờnh xỏc. Dng drift nịy phn ònh còc tởnh hung thc t nh: h thng IoT gp s c cm bin t ng, hoc mt dóy chuyn sn xut thay i nguyỏn liu u vịo.

- *Gaussian Shift (Moderate)*: D liu phón phi chun a chiu ($d = 10$) vị s dch chuyn trung bớnh (mean shift) t ng ($\Delta\mu = 1.5$). óy lị trng hp lỳ tng kim tra nhy ca kernel RBF, vớ phón phi Gaussian lị nn tng ca hu ht còc mữ hỏnh thng kỏ. Kch bn nịy c thit k da trỏn phng phỏp ònh giò tham s (parametric artificial datasets) trong bọ kho sỏt ca Hinder et al. [6], nị còc tòc gị s dng chũng so sỏnh cú h thng còc phng phỏp phòt hin drift unsupervised trỏn cứng mt nn tng thng nht.
- *Gaussian Concept Stream (GCS)*: Lung d liu 5 chiu vị phón phi Gaussian, trong ú mị concept c nh ngha bì mt vector trung bớnh khỏc nhau trỏn còc chiu c trng (concept 0: $\mu = +2.0$ trỏn x_0 ; concept 1: $\mu = -2.0$ trỏn x_0 ; concept 2: $\mu = +1.5$ trỏn x_1). Chui 3 concept to ra covariate shift $P(X)$ t ng, rủ rịng, phứ hp kim tra còc phng phỏp phòt hin khũng giòm sỏt. Cu trữc xoay vùng concept lỳ cm hng t STAGGER (Schlimmer & Granger, 1986) [9], nhng s dng c trng Gaussian liỏn tc thay cho c trng ri rc, cho phỏp còc kernel MMD quan sỏt $P(X)$ trc tip.

- *Random Uniform (Sensitivity Test)*: B 4 dataset (Random Mild, Random Moderate, Random Severe, Random Ultra Severe) c sinh ngu nhĩn vi cng thay i (intensity) tng dn t 0.125 n 2.0, s dng b sinh d liu c tham kho t survey ca Hinder et al. [6]. B nịy ụng vai trũ nh mt “nhit k” đũng ònh giò ngng phòt hìn (detection threshold) ca còc thut toòn: drift mc Random Mild ($\Delta\mu = 0.125$) gn nh khũng th phón bit vi nhieu t nhĩn, trong khi Random Ultra Severe ($\Delta\mu = 2.0$) to ra s thay i rũ rĩng mị bt k thut toòn nịo cng phi phòt hìn c.
- *Stepping Drift (Cumulative)*: Bin th c b sung kim tra kh nng thờch ng. Khòc vi Sudden Drift thũng thng (thng luón phiổn $A \rightarrow B \rightarrow A$), Stepping Drift dch chuyn phón phi tòch ly theo mt hng ($A \rightarrow B \rightarrow C \rightarrow D$). Kch bn nịy mĩ phng mĩ trng vn hình liổn tc tin húa mị khũng quay li trng thòi c (vò d trũi cm bin cũng nghip), nỏn mĩ hnh khũng th “hc vt” còc trng thòi c mị buc phi thờch ng vi d liu mị. *Kch bn nịy ch c đũng trong ònh giò thờch ng (Mc 5.4), khũng thuc phn ònh giò phòt hìn Mc 5.2.*

Nhúm 2: Blip Drift (Thay i ngn hn): Trong thc t vn hình, khũng phi mị s thay i u mang tòngh vnh vin. Mt t tn cũng mng ngn hn, mt s kin khuyn mĩ flash sale, hay mt li tm thi ca cm bin u to ra còc “xung nhieu” (blip) trong lung d liu ri nhanh chúng quay li trng thòi bnh thng. Kh nng phón bit blip vi drift thc s lị thờch thc ln i vi còc thut toòn phòt hìn.

- *RBF Blips*: D liu c sinh t b sinh Random RBF Generator [54] vi 50 trng tóm Gaussian. Mị on luón phiổn s dng mt cu hnh centroid khòc nhau kt hp vi bin i t l c trng ($\times 1.5 + 0.3$) còc on l, to ra s thay i $P(X)$ t ng t vị xen k trong khũng gian phi-Gaussian phc tp nhieu centroid. Tp d liu kim tra kh nng phòt hìn distribution shift trỏn phón phi phc tp hn Gaussian n gin.

Nhúm 3: Real Drift / Thay i ranh gii quy t nh (Control Group): Nhúm nịy ụng vai trũ **nhúm i chng** (negative control), gm còc dataset ch cú s thay i biổn quy t nh $P(Y|X)$ cùn phón phi u vịo $P(X)$ gi nguỷn (hoc thay i khũng òng k). óy lị dng *real drift* theo nh ngha ca Gama et al. [13], vn nm ngoị phm vi quan sòt ca còc phng phòp khũng giòm sòt ch da trỏn $P(X)$. Benchmark trỏn nhúm nịy giũp xòc nhn thut toòn khũng b “o giòc” (hallucination) trc còc thay i ch mang tòngh ng ngha nhõn.

- *Standard SEA*: B d liu benchmark do Street vị Kim xut ti hi ngh ACM SIGKDD 2001 [55]. SEA (Streaming Ensemble Algorithm) ban u c thit k ònh giò còc phng phòp ensemble learning cho lung d liu. B d liu gm 3 c trng ngu nhĩn, trong ú ch 2 c trng u lị liổn quan; drift c to bng còch thay i ngng phón lp $x_1 + x_2 > \theta$

(thng đứng còc ngng 8, 9, 7, 9.5). óy lị mt trong nhng benchmark c trỏch đn nhieu nht trong lnh vc concept drift.

- *Rotating Hyperplane*: B d liu do Hulten, Spencer v Domíngos gii thiu ti KDD 2001 [56] trong bi cnh nghiỏn cu khai phò lung d liu bin i theo thi gian (mining time-changing data streams). Mt siỏu phng d -chiu xoay đn trong khũng gian bng còch thay i trng s ca còc c trng, mủ phng gradual drift, đng drift mị ranh gii quy t nh đch chuyn t t tng t nh s thay i đn đn trong hnh vı ngi đứng hay iu kin th trng.
- *LED Abrupt*: Bụi toỏn phón lp ch s trỏn ỏn LED 7 thanh, c sinh bng b sinh chun ca River [54]. B d liu gm 7 thuc tởnh nh phón (còc thanh LED a–g), khũng thỏm thuc tởnh nhieu. Drift c to bng còch o ngc quy tc phón lp gia còc on: on chn phón loi ch s chn lị đng, on l o ngc lị, to ra s thay i t ng t trong $P(Y|X)$ mị khũng nh hng n phón phi c trng $P(X)$.

Nhúm 4: D liu bòn thc t (Semi-Synthetic) vı im drift kim soỏt: Nhúm nıy bc cu gia d liu tng hp vı d liu thc t thun tữ. Dataset lı c trng u vıo t d liu thc (phc tp, phi-Gaussian, cú tng quan gia còc chiu) cùn im drift thỏc inject nhón to cú ground truth rử rịng. Còch nıy cho phỏp kim tra hnh vı ca thut toỏn trỏn phón phi phc tp mị vn o c còc ch s ònh giò.

- *Electricity Semi-Synthetic*: Da trỏn b d liu Electricity gc ca Harries [57] t th trng in nng bang New South Wales, Australia (giai on 1996–1998, 45,312 quan sỏt). B d liu gc ghi nhn giò in dao ng theo thi gian thc vı còc c trng nh: nhu cu in nng, lng chuyn giao liỏn bang, vı chu k thi gian. óy lị mt trong nhng benchmark thc t c s đng ph bin nht trong nghiỏn cu concept drift, do bn cht d liu vn ỏ cha còc yu t bin ng t nhiỏn (mủa v, s kin th trng). Trong phiỏn bn semi-synthetic, 10 im drift c chỏn ti còc v trỏ c nh bng còch xỏo trn phón phi c trng, cho phỏp kim tra hnh vı ca thut toỏn trỏn d liu phón phi phi-Gaussian phc tp trong khi vn cú ground truth xỏc nh.

Nhúm 5: Recurrent, Gradual, vı Stationary: Ba dataset trong nhúm nıy c thỏm nh ngha Recurrent, Gradual vı Stationary mt còch cht ch v mt lý thuyt, ng b vı còc nh ngha drift trong kho sỏt ca Lu et al. [14].

- *Gaussian Recurrent Stream (GRS)*: Lung Gaussian 5 chiu vı 4 concept cú vector trung bớnh khỏc nhau, lp theo chu k $A \rightarrow B \rightarrow A \rightarrow B \dots$ ửng vı nh ngha Recurrent ca Lu et al. [14]. Mı concept c gı n nh mt khong thi gian trc khi quay v concept ỏ tng xut hin, cho phỏp Concept Memory (Mc 4.3.7) phỏt huy ửng vai trù.

- *Gaussian Gradual Synthetic*: D liệu Gaussian a chịu vì chuyển tiếp tuyn tồnh gia hai mean trổn mt không chuyển tiếp xóc nh trc (mc nh 400 mu). Khóc vì hyperplane (drift gradual ch $P(Y|X)$), dataset này cho drift gradual thc s $P(X)$, do ú o c kh nng phòt hin drift chm ca còc phng phòp khũng giòm sòt. óy cng lị im yu c hu ca IDW-MMD vị lị mt trng hp khú quan trng kim tra gii hn ca phng phòp.
- *Gaussian Stationary (No Drift)*: Lung Gaussian tnh (khũng cú s kin drift). Tp này úng vai trò o bào ng gì trổn d liệu tnh, b sung cho kim tra Type-I error Mc 5.2.5: nú cho bit liệu detector cú sinh bào ng gì khi lung d liệu hoịn toịn khũng i hay khũng.

5.1.4 Chín lc ònh giò

H thng SE-CDT c ònh giò theo cu trũc ca hai thnh phn bốn trong cũng vì khung thờch ng. **Thnh phn phòt hin (ShapeDD-IDW)** chu tròch nhim cho vic phòt hin thi im drift da trổn IDW-MMD vị Gamma-approximation p-value, u tiổn gim FP vị tr. **Thnh phn phón loi** ca SE-CDT phón loi loi drift (sudden, gradual, incremental, recurrent, blip) bng còch phón tồch hnh dng ca tòn hiu $\sigma(t)$ trổn ca s trt kòch thc W , hoịn toịn khũng giòm sòt. **Khung thờch ng** đũng nhõn loi drift do SE-CDT sn xut kòch hot chín lc cp nht phũ hp (Full Reset cho sudden, Incremental Update cho gradual/incremental, Concept Memory cho recurrent). Chín lc ònh giò còc mc sau bõm theo cu trũc ba giai on này.

Còc mc thc nghim đi óy tr li nhng cớu hi khòc nhau (chõnh xóc nh v, chõnh xóc phón loi, mc Type-I error, kh nng phc hi ca mũ hnh), nổn đũng còc cu hnh ca s, δ , cooldown vị ngha ca FP khòc nhau (Bng 5.1). Khi i chịu s liu gia còc mc cn lu ý rng cũng mt phng phòp cú th cho EDR/FP khòc nhau khũng phi do thay i thut toỏn mị do mc o ang tr li cớu hi khòc.

Bng 5.1 Quy c thit lp còc mc ònh giò. Cũng mt detector nhng c o đi nhng cu hnh ca s vị dung sai khòc nhau tũy cớu hi mị mc ú tr li; còc giò tr W , δ vị cooldown đũng trong chng c tng hp ti óy.

Mc ònh giò	Ca s	δ (mu)	Cooldown	Ngha ca FP	Metric chõnh
Detection (Mc 5.2)	$l_1=50, l_2=150$	75	150 ($= 2\delta$)	Bào trổn d liệu tnh / lch nh v	F1, EDR, FP
Classification (Mc 5.3)	$W=50, s=10$	250	—	Bào sai v trở ngoịi không chuyển tip	ACC_{cat} , ACC_{sub} , EDR
Hiu chnh H_0 (Mc 5.2.5)	$W=300$	—	—	Type-I error trổn d liệu tnh	Type-I error
Adaptation (Mc 5.4)	$l_1=50, l_2=150$	400	—	Bào d trong không phc hi	Prequential Accuracy
Nguyổn mu Kafka (Mc 5.5)	$W=250$	—	—	Khũng o	Phc hi chõnh xóc

5.2 ònh giò kh nng phòt hin ca SE-CDT

Mục nìy ònh giò kh nng phòt hin ca SE-CDT, t c ShapeDD-IDW, bng còch i chiu vì còc phng phòp phòt hin drift tiỏu biu thuc nhieu trng phòt: KS-Test (thng kổ c in), MMD (kernel-based), DAWIDD (window-based), D3 (Discriminative Drift Detector [45]), v ShapeDD g c [7]. Trng tóm phón tồch c t v iò kh nng nhn din. S thay i phón phi u v iò $P(X)$ (Distribution Shift / Covariate Shift). Vớ module phón loi ca SE-CDT ch chy sau khi module phòt hin bở drift, F1 phòt hin ca SE-CDT trng v ShapeDD-IDW; c hai dùng c gi li trong bng kt qu b c l rủ mi quan h nìy.

5.2.1 Thit lp thc nhim phòt hin drift (Detection Setup)

Còc tham s cho b i toàn phòt hin drift c thit lp nh sau:

- D liu bao gm 14 tp d liu (13 tng hp + 1 bòn thc t, chỉ tit Mc 5.1.2). Tp stationary (khũng cú drift) c tồch riỏng o false-positive. Kờch thc ca lung d liu 10,000 mu mi dataset vì 10 im drift c chỏn ti còc v trỏ c nh (mi 1,000 mu) to ground truth, tr tp stationary (0 drift).
- Quy trnh ònh giò c thc hin 30 ln chy c lp (30 runs) vì còc seed ngu nhỏn khỏc nhau m bở tỏnh n nh ca kt qu (xem Mc 5.1.2).
- tr chp nhn $\delta = 75$ v i cooldown = 150 ($= 2\delta$) nh Bng 5.1.

5.2.2 Kt qu so sỏnh hieu sut phòt hin

Bng 5.2 trnh b i kt qu tng hp ca còc phng phòp ShapeDD-IDW v SE-CDT v còc phng phòp c tham kho (MMD, KS-Test, D3, DAWIDD, ShapeDD). Còc phng phòp ShapeDD-IDW v SE-CDT đng chung thut toàn phòt hin nỏn cú F1 trng nhau; SE-CDT b sung bở phón loi c ònh giò Mc 5.3. Còc ch s F1 tỏnh đa trỏn kh nng phòt hin ử còc im drift ỏ bit (ground truth), tng hp t 30 ln chy c lp trỏn 14 tp d liu.

Bng 5.2 So sỏnh tng hp hieu sut còc phng phòp phòt hin drift. *Lưu ý:* ShapeDD-IDW l i module phòt hin ca SE-CDT; SE-CDT l i to i b h thng (bao gm c module phón loi). benchmark phòt hin nìy, hai dùng đng cng thut toàn nỏn F1, Precision, Recall, FP trng nhau theo thit k.

Method	Precision	Recall (EDR)	F1-Score	Delay	False Pos.
DAWIDD	<u>0.435</u>	0.734	0.532	38	10.3
IDW_MMD	0.432	0.737	<u>0.531</u>	36	<u>9.6</u>
SE_CDT	0.432	0.737	<u>0.531</u>	36	<u>9.6</u>
ShapeDD_IDW	0.432	0.737	<u>0.531</u>	36	<u>9.6</u>
MMD	0.429	0.734	0.527	35	10.5
ShapeDD	0.377	<u>0.749</u>	0.491	<u>34</u>	13.2
D3	0.558	0.472	0.489	16	0.6
KS	0.224	0.775	0.335	<u>34</u>	27.2


DAWIDD cú F1 cao nht v mt s hc (0.532), cùn ShapeDD-IDW (cúng cu hnh IDW-MMD ng riống lịm ablation) t $F_1 = 0.531$ vi Precision = 0.432, Recall/EDR = 0.737 vi 9.6 bõo ng gi trung bõnh mi run. Chõnh lch 0.001 lị khũng òng k; theo kim nh Nemenyi Mc 5.2.3, khõc bit th hng gia hai phng phòp khũng t mc ý ngha thng kỏ. úng gúp chõnh ca ShapeDD-IDW vớ vy khũng nm F1 mị chỉ phờ tồnh toà (nhanh hn ShapeDD gc khong $7\times$, Bng 5.9) vi kh nng phón loi loi drift c ònh giõ Mc 5.3.

So vi ShapeDD gc, ShapeDD-IDW gi F1 cao hn (0.531 so vi 0.491) vi gim FP t 13.2 xug 9.6. Cì tin nịy n t c ch trng s nghch bin mt (Gii thut 2) kt hp xp x Gamma thay cho permutation test. V thi gian chy, benchmark cho thy ShapeDD-IDW nhanh hn khong $7\times$ so vi ShapeDD gc (Bng 5.9). D3 cú Precision cao nht vi FP thp nht nhng Recall thp hn, cùn KS-Test cú Recall cao nhng to quò nhiu bõo ng gi phứ hp vi h thng giõm sòt t ng.

S $FP \sim 9.6/\text{run}$ ca module phòt hin SE-CDT (ShapeDD-IDW) vi cu hnh IDW-MMD ng riống cn c c cúng s lng ca s vị s ng viõn c kim nh. Trõn b ònh giõ nịy, mi seed cú nhiu ca s kim nh vị nhiu im drift tht. Bc lc hnh dng giúp gim s ng viõn trc khi kim nh bng IDW-MMD, vớ vy FP thc t thp hn trng hp kim nh mị ca s mt cõch c lp. Tham s khong trit bõo cooldown = 150 (xem mc thit lp) cng giúp trit tiõu phn ln bõo trúng trong vúng lớn cn ca mị im drift tht. Nu mun gim FP hn na, cn sít mc α hoc dúng hiu chnh a kim nh.

5.2.3 Phón tồch ý ngha thng kỏ

kim tra liu khõc bit hiu sut gia cõc phng phòp cú ý ngha thng kỏ hay khũng, Hnh 5.1 trõnh bịy biu Critical Difference (CD) dúng kim nh Friedman vi Nemenyi post-hoc theo quy trõnh ca Demar [58] cho vic so sõnh nhiu thut toà trõn nhiu tp d liu.



Hình 5.1 Biểu đồ Critical Difference (CD) với mức ý nghĩa $\alpha = 0.05$. DAWIDD có thứ hạng trung bình tốt nhất; ShapeDD-IDW và cụm hình IDW-MMD gần giống xếp ngay sau (cách DAWIDD 0.429, nhỏ hơn ngưỡng $CD = 2.806$) nên không khác biệt có ý nghĩa thống kê với DAWIDD. SE-CDT có cùng thứ hạng với đứng chung thứ toàn phần.

Bảng 5.3 Thứ hạng trung bình theo F1-score trong kiểm nghiệm Friedman/Nemenyi. ShapeDD-IDW và SE-CDT đứng chung thứ toàn phần nên có thứ hạng trung bình bằng nhau.

Method	Average Rank	Overall Rank
DAWIDD	3.464	1
IDW_MMD	3.893	2–4
SE_CDT	3.893	2–4
ShapeDD_IDW	3.893	2–4
MMD	4.607	5
D3	4.750	6
ShapeDD	5.179	7
KS	6.321	8
Critical Difference (CD) = 2.806		

Kết quả kiểm nghiệm Friedman/Nemenyi trong Bảng 5.3 cho thấy DAWIDD có thứ hạng trung bình tốt nhất (3.464); ShapeDD-IDW và cụm hình IDW-MMD gần giống có thứ hạng trung bình 3.893, sát ngay sau DAWIDD (SE-CDT có cùng thứ hạng với đứng chung thứ toàn phần). Vì ngưỡng $CD = 2.806$ ($\alpha = 0.05$), không cách gia ShapeDD-IDW và DAWIDD chỉ $0.429 < CD$, nên khác biệt thứ hạng F1 không có ý nghĩa thống kê. Tương tự, không cách so với MMD (0.714) cũng nhỏ hơn CD nên không thể kết luận khác biệt thống kê. Trong nhóm đa phần MMD, có bốn thí nghiệm có thứ hạng trung bình tốt hơn MMD (3.893 so với 4.607) nhưng cách biệt nằm ngoài ngưỡng Nemenyi, nên không khác biệt thống kê.

5.2.4 Hình ảnh chi tiết trên ảnh loại dữ liệu

Hiệu suất của các phương pháp thay thế dựa trên thực nghiệm cao (Bảng 5.4–5.7).

Bng 5.4 F1-Score theo dataset (Phn 1: D liu c bn vị Mild/Moderate Drift)

Method	Electricity	Gaussian Gradual Synthetic	Gaussian Shift	Random Mild
DAWIDD	0.250	0.472	<u>0.753</u>	0.594
IDW_MMD	0.383	<u>0.470</u>	0.736	0.511
SE_CDT	0.383	<u>0.470</u>	0.736	0.511
ShapeDD_IDW	0.383	<u>0.470</u>	0.736	0.511
MMD	<u>0.291</u>	0.462	0.740	<u>0.566</u>
ShapeDD	0.267	0.451	0.700	0.529
D3	0.213	0.029	0.998	0.012
KS	0.263	0.315	0.356	0.335

Bng 5.5 F1-Score theo dataset (Phn 2: Drift mnh vị thay i mt phng)

Method	Random Moderate	Random Severe	Random Ultra Severe	Hyperplane
DAWIDD	0.728	<u>0.739</u>	<u>0.738</u>	<u>0.136</u>
IDW_MMD	<u>0.688</u>	0.708	0.712	0.179
SE_CDT	<u>0.688</u>	0.708	0.712	0.179
ShapeDD_IDW	<u>0.688</u>	0.708	0.712	0.179
MMD	0.685	0.707	0.709	0.169
ShapeDD	0.619	0.636	0.638	0.197
D3	0.244	0.931	0.933	0.000
KS	0.407	0.434	0.434	0.240

Bng 5.6 F1-Score theo dataset (Phn 3: RBF Blips, GCS vị GRS)

Method	LED Abrupt	RBF Blips	GCS	GRS
DAWIDD	0.130	<u>0.749</u>	0.750	0.749
IDW_MMD	0.148	0.744	<u>0.755</u>	<u>0.753</u>
SE_CDT	0.148	0.744	<u>0.755</u>	<u>0.753</u>
ShapeDD_IDW	0.148	0.744	<u>0.755</u>	<u>0.753</u>
MMD	0.127	0.747	0.742	0.739
ShapeDD	0.163	0.670	0.681	0.679
D3	0.000	1.000	0.998	1.000
KS	<u>0.071</u>	0.371	0.459	0.458


Bng 5.7 F1-Score theo dataset (Phn 4: Standard SEA vị trung bnh)

Method	Standard Sea	Mean
DAWIDD	0.129	0.532
IDW_MMD	<u>0.118</u>	<u>0.531</u>
SE_CDT	<u>0.118</u>	<u>0.531</u>
ShapeDD_IDW	<u>0.118</u>	<u>0.531</u>
MMD	0.163	0.527
ShapeDD	0.151	0.491
D3	0.000	0.489
KS	0.206	0.335


1. Trón còc tp cú thay i phón phi rủ nh Random Moderate, Random Severe, Random Ultra Severe, GCS vị GRS (Gaussian Recurrent Stream), ShapeDD-IDW t F1 khong 0.69–0.76, n nh hn ShapeDD gc phn ln còc trng hp vị gi c tồn hieu Standard

MMD cn cho bc phón loi. Hnh 5.2 minh ha dng tồn hiu ShapeDD ti mt kch bn sudden drift.


2. i vi còc tp d liu drift nh vi drift dn dn, trón còc tp nh Random Mild, ba phng phòp xut t $F1 = 0.511$, thp hn MMD (0.566) nhng khùng b mt hoịn toịn tồn hiu. Vi Gaussian Gradual Synthetic, c ba phng phòp xut t $F1 = 0.470$, cao hn MMD (0.462) mt chũt (Hnh 5.3 minh ha tồn hiu trón kch bn gradual). Bc kim nh IDW-MMD vi p-value Gamma vn nh phòt hin drift dn dn khi ca s tham chiu vi ca s kim tra $\ln(l_1 = 50, l_2 = 150)$.
3. i vi còc tp d liu ch thay i v nhõn nh Hyperplane, LED Abrupt, vi Standard SEA, im $F1$ ca module phòt hin SE-CDT tng i thp (0.179, 0.148, vi 0.118). óy lị hnh vi phứ hp vi phm vi ca phng phòp khùng giòm sòt: h thng ch yu quan sòt $P(X)$, nỏn còc thay i nm $P(Y|X)$ khùng to tồn hiu rủ. Tuy nhiên, còc giò tr khòc 0 cng cho thy vn cùn mt mc bòa ng d tha do nhieu mu vi do còch ònh giò theo ca s.
4. i vi blip drift, trón tp RBF Blips, ba phng phòp xut t $F1 = 0.744$ bị toàn phòt hin, gn vi MMD (0.747), trong khi D3 t cao hn (1.000) nh classifier phón bit ca s trc vi sau blip. Còc thay i ngn hn vn cú th c phòt hin hiu qu; vic phón loi ỹng Blip vn cùn khú hn vi c phón tồch riỏng Mc 5.3.3.
5. Bòa ng gi trong detection: Bng 5.2 bòa còa FP trung bnh theo mi run trón toịn b b ònh giò: KS-Test cao nht (27.2 FP/run), trong khi ShapeDD-IDW (vi cu hnh IDW-MMD ng riỏng) mc ~ 9.6 FP/run, thp hn ShapeDD gc (13.2 FP/run) vi gn MMD (10.5 FP/run). Riỏng Hnh 5.4 hnh th tng s bòa ng gi trón tp d liu tnh; do ú con s trong hnh lị tng cng sau khi gp nhieu ln chy, khùng phi FP/run. Cú hai lý do giúp bc lc nịy phòt huy tòc dng: (i) c ch phòt hin hnh dng yỏu cu tồn hiu MMD phi khp dng tam giòc c trng; (ii) bng thũng kernel γ c c lng mt ln bng median heuristic vi dũng chung cho c ba kernel K_{XX}, K_{YY}, K_{XY} .



Hình 5.2 Minh họa tồn hiệu phù hợp hình trôi dạt Sudden Drift (kết hợp Mixed A). ShapeDD tạo ra hình dạng “tạm giữ có” ở trung tâm của trôi dạt, ứng với mô hình lý thuyết.



Hình 5.3 Minh họa tồn tại trôi dạt dữ liệu Gradual Drift. Tồn tại (mũi - Subplot 03) không thể nhận ra sự thay đổi của phân phối.



Hình 5.4 Tổng số báo động giả trên tập dữ liệu tĩnh (Stationary), đi qua các bộ lọc. Chỉ số này bổ sung cho FP/run Bảng 5.2: KS có ra nhiều báo động sai nhất, trong khi các phương pháp MMD-based thấp hơn rất nhiều.

5.2.5 Kim tra t l bào ng sai trồn d liu khũng cú drift

S False Positive quan sòt c trồn b ònh giò phòt hìn ch phn ònh mt phn hìn vi ca kim nh, vớ còc mc drift tht tng i tha vị bc lc theo hính dng nh ò loi bt ng viõn trc khi kim nh. ònh giò trc tip liu kim nh cú thc s gn mc $\alpha = 0.05$ hay khũng, lun vn tin hìn thõm mt thờ nghim ph trồn d liu **hoịn toịn khũng cú drift** vị o trc tip **Type-I error** (xòc sut bào ng sai khi gi thuyt H_0 ững) ca ba b phòt hìn chõnh:

- **MMD** vi p-value tòngh bng permutation test ($N_{\text{perm}} = 2,500$).
- **IDW-MMD** vi p-value tòngh theo xp x Gamma.
- **SE-CDT** (kt hp ShapeDD-IDW cho phòt hìn vị lut phón loi theo ngng).

Mi phng phòp chy trồn ba phón phi tnh bao quòt còc tòngh hung thng gp: (i) Gauss-iid $d = 5$, (ii) Gauss-iid $d = 10$ (kim tra nh hng s chiu), vị (iii) Gauss-AR(1) $d = 5$ vị $\rho = 0.6$ (kim tra d liu cú tng quan thi gian). Mi cu hính chy c lp 200 ln vi seed khòc nhau, dũng ca s tng kòch thc $W = 300$ mu. Standard MMD vị IDW-MMD chia W thịn hai na bng nhau (150 tham chiu vs 150 kim tra); SE-CDT (composite) òp dng giao thc ShapeDD vị $l_1 = 50$, $l_2 = 150$ trồn cũng ca s. Mc ý ngha danh ngha $\alpha = 0.05$.

Bng 5.8 T l Type-I error trồn d liu tnh (200 ln chy mi cell, $\alpha = 0.05$). S sau du $\pm$ lị na khong tin cy 95% theo Wilson.

Distribution	Standard MMD (perm)	IDW-MMD (Gamma null)	SE-CDT (composite)
Gauss-iid d=5	0.025 ± 0.022	0.040 ± 0.027	0.115 ± 0.044
Gauss-iid d=10	0.055 ± 0.032	0.050 ± 0.030	0.080 ± 0.038
Gauss-AR1 d=5	0.045 ± 0.029	0.075 ± 0.037	0.140 ± 0.048

Kt qu Bng 5.8 cho thy:

- MMD (permutation test, $N_{\text{perm}} = 2,500$) cú Type-I error nm trong khong 0.025–0.055, sòt vị mc danh ngha $\alpha = 0.05$. óy lị hính vi ững vi lý thuyt, cho thy MMD dũng lịm baseline trong lun vn khũng b thiõn lch.
- IDW-MMD vi xp x Gamma t Type-I error trong khong 0.040–0.075, gn vị mc danh ngha $\alpha = 0.05$. Kim nh do ú khũng quò bo th nh xp x Gaussian đi gi thuyt khũng drift.
- SE-CDT (kt hp bc lc hính dng vị IDW-MMD bc kim nh) t Type-I error 0.080–0.140, cao hn α rủ rt — anti-conservative trồn c hai phón phi $d = 5$ iid (0.115) vị AR(1) (0.140, $\approx 2.8 \times$ mc danh ngha). Mũ hính ò òp dng hiu chnh Bonferroni khi mt trace cú nhiu nh ng viõn, nhng Type-I error tng hp ca toịn pipeline vn chu

nh hng t bc chn nh vị tồnh cht ph thuc gia còc ca s trt. Vớ vy kt qu H0 c din gii thn trng nh mt kim tra calibration thc nghiêm, khũng phi bo m lý thuyt y cho toịn b pipeline.

Vic chn xp x Gamma theo Gretton et al. [47] thay cho xp x Gaussian xut phòt t mt nhn xỏt lý thuyt: di gi thuyt khũng drift, MMD_u^2 tim cn mt χ^2 cú trng ch khũng phi Gaussian. Nu òp dng Gaussian di gi thuyt khũng drift, kim nh cú xu hng quò bo th. Xp x Gamma khc phc im nịy tt hn vị cho kt qu gn mc $\alpha = 0.05$ hn trong thờ nghiêm trỏn d liu tnh.


5.2.6 ònh giò hieu sut tồnh tồnh

Bng 5.9 so sònh thi gian vị thũng lng.

Bng 5.9 So sònh hieu sut tồnh tồnh ca còc phng phòp

Method	Runtime (s/stream) [†]	Throughput (samples/s)	Speedup vs ShapeDD
KS	0.29	33,990	14.47×
D3	0.31	32,300	13.75×
ShapeDD-IDW	0.59	16,858	7.18×
IDW-MMD (standalone)	0.59	16,849	7.17×
SE-CDT	0.60	16,764	7.14×
ShapeDD (gc)	4.26	2,349	1.00×
MMD	4.31	2,322	0.99×
DAWIDD	5.66	1,767	0.75×

[†]Runtime o bng `time.process_time()` cho toịn b mt stream 10,000 mu, thc thi tun t loi b tranh chp tị nguồn CPU, ly trung bnh trỏn tt c dataset vị toịn b còc ln chy. Throughput = s mu/Runtime. Speedup c tồnh tng i vị ShapeDD gc.



Hình 5.5 Thi gian chy trung bnh ca còc phng phòp trỏn ònh giò phòt hin (10,000 mu, 30 ln chy).

ShapeDD-IDW nhanh hn rủ rt so vị ShapeDD gc trỏn lung 10,000 mu (Bng 5.9, Hnh 5.5), khong 7×, nh thay permutation test bng xp x Gamma; MMD vị DAWIDD

chm hn do khũng cú c ch kim nh gn ỹng. im quan trng hn lĩ bc kim nh da trũn xp x Gamma cú din gii thng kũ rũ hn so vi vic ch t ngng th cũng trũn tr MMD.

5.3 ònh giò module phũn loi ca SE-CDT

Phn nĩy ònh giò kh nng phũn loi ca SE-CDT: kh nng nhn din loi drift (Sudden, Gradual, Incremental, Recurrent, Blip) da trũn hũnh dng tũn hũu drift magnitude $\sigma(t)$ do module phũt hĩn ShapeDD-IDW (Mc 5.2) sn xut, hoĩn toĩn khũng giũm sũt.

5.3.1 Thĩt lp thc nghiĩm phũn loi drift

Thc nghiĩm phũn loi dũng song song hai ch o lng, ng vi hai cúu hĩ khũc nhau:

- **Oracle mode** (o CAT, SUB): SE-CDT c cho bit trc v trũ drift ground-truth vi ch thc hĩn bc phũn loi. Ch nĩy tũch bit nng lc phũn bit hũnh dng tũn hũu khi nng lc t phũt hĩn.
- **Real detection mode** (o EDR, MDR): SE-CDT t tũm im drift t tũn hũu MMD ri phũn loi, ònh giò pipeline u-cũi. EDR (Event Detection Rate) lĩ t lĩ s kin drift c nhn din; MDR (Miss Detection Rate = $1 - \text{EDR}$) lĩ t lĩ b sút.

Vũ CAT vi SUB c o oracle mode, hai cu hũnh SE-CDT (Std) vi SE-CDT (IDW) cho cũng kt qu CAT/SUB. Khũc bit gia hai cu hũnh ch xut hĩn EDR/MDR. ònh giò c chy vi 6 kch bn tng hp (30 seeds mi kch bn = 180 lung, mi lung cha 10 s kin drift = 1800 s kin phũn loi):

Bĩg 5.10 Sũu kch bn benchmark module phũn loi ca SE-CDT


Kch bn	Thĩnh phũn drift (xoay vũng)	ũĩi lung
Mixed A	Sudden $\rightarrow$ Gradual $\rightarrow$ Recurrent	$\sim 11,800$ mu
Mixed B	Blip $\rightarrow$ Incremental $\rightarrow$ Sudden	$\sim 13,800$ mu
Repeated Sudden	$10 \times$ Sudden	$\sim 9,600$ mu
Repeated Gradual	$10 \times$ Gradual	$\sim 11,800$ mu
Repeated Incremental	$10 \times$ Incremental	$\sim 13,800$ mu
Repeated Recurrent	$10 \times$ Recurrent (A $\rightarrow$ B $\rightarrow$ A)	$\sim 11,800$ mu

Trong ũ, mi s kin Sudden, Gradual vi Incremental dch chuyn mt tp c trũg khũc nhau theo c ch xoay vũng, mi concept mi lĩ c lp vi cũc concept ũ thĩ, ỹng theo nh nghĩa ca Lu vi cũg s [14]. Riũng Recurrent gi logic luũn phiũn $A \leftrightarrow B$ vũ ũĩy mi lĩ nh nghĩa c trũg ca loi drift nĩy.


- **Ca s ShapeDD:** $W = 50$, stride $s = 10$.

- **Tồn hui phón loi:** Standard MMD. Còc th ngi h so sòn h cho th y IDW-MMD khũng phứ h p lịm tồn hui phón loi vớ d lịm m còc drift chm nh Gradual/Incremental. Vớ v y h thng dũng mũ hnh kt hp: bc kim nh ng viổ dũng IDW-MMD, cùn bc phón loi dũng Standard MMD g i li thũng tin hnh dng toị cc.
- **Ngng phòt hìn:** hui chnh trổn m t p validation riổng (xem Bng A.1 v i A.2 Ph lc). Ngng mc nh ca th vin gc quỏ bo th trong iu kin streaming nỏn ỏ c ni xug cho phứ h p.

Trc khi c kt qu s, Hnh 5.6 v i Hnh 5.7 minh ha trc quan lý do Sudden drift d phón loi hn Incremental: SE-CDT da v i s khỏc bit hnh dng ca tồn hui $\sigma(t)$ phón bit còc loi drift.



Hnh 5.6 Tồn hui SE-CDT trổn kch bn Repeated Sudden: $\sigma(t)$ to nh nhn, i xng ti mi im drift — c trng d nhn đin bng height threshold.



Hình 5.7 Tồn hũ SE-CDT trở kch bn Repeated Incremental: $\sigma(t)$ tng dn theo dng ramp, khũng cú nh nhn. Hình dng nỳ khũ phn bit bng c trng MMD n thun; c trng Variance Ratio trở d liu thũ c đũng tồch Incremental khi Gradual, song hai loi drift chm nỳ vn chng ln òng k v phng sai ca s.

5.3.2 Kt qu phn loi tng hp ca SE-CDT

Bng 5.11 trng bỳ kt qu tng hp trở 1800 s kin phn loi trở. Hai cu hnh u đũng Standard MMD cho tồn hũ phn loi nũn CAT/SUB bng nhau, khòc bit ch nm tồn hũ detection. SE-CDT (Std) đũng Standard MMD, nhỹ vi c 5 loi drift (EDR $\approx 92.6\%$) nhng FP cao hn. SE-CDT (IDW) đũng IDW-MMD, cht hn v FP nhng b sút Gradual/Incremental. Trong ng cnh phn loi, u tiũn lĩ khũng b sút s kin, vớ vỹ **SE-CDT (Std)** c chn lĩm cu hnh chũnh.

Bng 5.11 Kt qu phn loi drift type ca SE-CDT (tng hp 1800 s kin, 6 kch bn $\times$ 30 seeds)

Method	CAT Acc	SUB Acc	EDR $\uparrow$	MDR $\downarrow$	FP	Supervised
SE-CDT (Std)	80.1%	55.3%	0.926	0.074	4846	No
SE-CDT (IDW)	80.1%	55.3%	0.567	0.433	657	No

Kt qu Bng 5.11 cho thỹ mt s chũnh lch giũ chũnh xòc phn nhũm mc ln (CAT Acc = 80.1%, phn bit giũ drift nhanh TCD vĩ drift chm PCD) vĩ chũnh xòc phn loi chỉ

tit tiêu lỗi (SUB Acc = 55.3% micro, 54.4% macro). c trung Variance Ratio (Eq. (4.6)) bổ sung thông tin phân sai d lưu trữ cho nhóm PCD bốn chế c trung hình học. Tuy vậy, chuẩn CAT-SUB vẫn còn, tập trung gần như hoàn toàn hai tiêu lỗi drift chậm, vì xuất phát từ một số lý do kỹ thuật cứng gán lý thuyết kết luận cả phân phù hợp tập cũn không giùm sòt:

- **Hai tiêu lỗi drift chậm lệ thuộc (Gradual 27.2%, Incremental 30.3%):** C Gradual và Incremental thuộc nhóm PCD lệ thuộc tồn tại MMD kéo dài, ờn nhận (Hình 5.7), nổi chứng minh lẫn nhau qua trục Variance Ratio. Về lý thuyết, chuyển tập hợp cả Gradual làm phân sai cả s phân to ($VR > \tau_{VR}^+$) cũn dịch chuyển n cả Incremental gì phân sai n nh ($VR < \tau_{VR}^-$); nhng trở c lũng mũ phân, phân b VR cả hai lỗi chế lẫn ờng k, dñ tỉ 47% s kin Incremental b c thịnh Gradual vì một phần Gradual b gòn ngược lại (Hình 5.8). Variance Ratio nóng kh nng tách tiêu lỗi PCD so vì ch đứng c trung hình học, song cha phân bit dữ liệu hai dạng drift chậm.
- **Drift chậm lệ thuộc vào nhóm Recurrent:** Trong chế kích bñ nhiều s kin Gradual/Incremental lẫn tập, chế dịch chuyển tách lưu dñ n khi $P(X)$ n nh; cả s sau drift khi ú trùng khớp vì một concept cũ lưu vị b Concept Memory gòn nhóm Recurrent. Cũ tỉ 57% s kin Gradual ri vị ờng hợp này, khñ Gradual ch t 27.2% trở toàn benchmark dữ vẫn nhận đñ c khi ng c lp. óy lệ h qu cả vic Concept Memory u tồn bñ chñ lp li cả phân phi hñ hình dạng chuyển tập danh nghĩa.
- **S ờn i nhiễm trùng v bào ng gi (FP):** Cu hình chếnh SE-CDT (Std) ghi nhận lũng bào ng gi cũ k lẫn (4846 FP trở toàn b cũ lẫn chñ th nghiệm). iu này lệ do Standard MMD rt nhy vì cũ bñ ng nhiều tñ s cao cả lũng d lưu. Khi chuyển sang cu hình SE-CDT (IDW) sít chñ FP xung cũn 657, b phòt hñ li b sút hu ht cũ s kin drift chậm (EDR gìm mñh t 92.6% xung cũn 56.7%). óy lệ mñ gñ hñ lñ: h thng học phi chñ nhận alert fatigue (quò nhiều bào ng gi) phân lỗi y cũ lp drift, học phi hy sinh kh nng nhận đñ cũn lỗi drift chậm gì h thng n nh.
- **Tồn heuristic cả cũ ngng quyt nh:** Vic phân lỗi hoñ toàn khñng giùm sòt đa trở mñ cóy quyt nh tñh vì cũ ngng cng ($WR < 0.15$, $SNR > 2.0$, v.v.). Cũ ngng này cả cũ c s toàn học chñ ch gñg nh bç phòt hñ (vñ c chñ hóa bñg p-value thñg qua xp x Gamma), dñ n mũ hình kỗm linh hoạt khi x lý cũ kích bñ d lưu lũng a dạng.

SE-CDT (Std) t CAT = 80.1% và SUB micro-average = 55.3% oracle mode. Bñg 5.12 cñg bào cũ macro-average per-class = 54.4% trờn vic kt qu b chỉ phi bi lp xuất hñ nhiều hñ trong benchmark. Nhóm TCD (Sudden, Blip, Recurrent) n nh hñ

hn nhóm PCD, phn ònh vic tồn hui chuy n tip chm khú tòch tiu loi hn khi ch đa vọ hnh dng tồn hui khũng giòm sòt.

Concept Memory giúp Recurrent t 71.5%, thp hn kt qu recurrent mị CDT-MSW cũng b trở n benchmark UCI khòc (83.9%) nhng vn cho thy c ch so khp khòì nim cú tòc dng. Tuy nhiên iu nịy cng lịm l ra s ònh i: m t phn Gradual vị Incremental b hũt vọ nhònh Blip/Recurrent khi tồn hui cú nhiu nh ph.


5.3.3 Phón tòch chi tit theo loi drift

Bng 5.12 vị Hnh 5.8, 5.9 phón tòch ngun gc li phón loi.


Bng 5.12 chònh xòc phón loi theo tng loi drift (oracle mode, SE-CDT Std)

Drift Type	Accuracy [%]
Sudden	82.4%
Blip	60.8%
Gradual	27.2%
Incremental	30.3%
Recurrent	71.5% [†]
Macro avg (per-class)	54.4%
Micro avg (over events)	55.3%

[†]Recurrent drift identified via Concept Memory (Standard MMD comparison with stored snapshots; $\tau_{\text{match}} = 0.15$). Macro avg averages the five per-class accuracies (each weighted equally); micro avg pools all events and counts correct predictions, so it is biased toward the most frequent class (here Sudden).



Hnh 5.8 Confusion Matrix cho 5 loi drift (oracle mode, cu hnh SE-CDT y vị Concept Memory vị Online Self-Calibration). Chi tit chònh xòc tng lp xem Bng 5.12.



Hình 5.9 Confusion Matrix mc nhóm (TCD vs PCD, oracle mode). chèn xóc nhóm t 80.1%; drift chm (Gradual, Incremental) tip tc chng ln tồn hieu nhieu hn drift nhanh (Sudden, Blip).

Sudden t 82.4%, vn lị nhóm n nh nht vớ tồn hieu MMD to nh nhn vị SNR cao. Blip t 60.8% sau khi lut phón loi cho phỗ hai hoc ba peak vị kim tra profile nhieu ngn hn; kt qu nịy tt hn phỉn bn cng trc ú nhng cha ngang mc supervised trong CDT-MSW. Recurrent t 71.5% nh Concept Memory, song vn cùn nhm vị Blip/Sudden khi mu sau drift gng mt concept ỗ lu.

Hai nhóm drift chm (PCD) lị ni tp trung phn ln lị phón loi. Incremental t 30.3% vị Gradual t 27.2% — thp hn rủ rt so vị còc tiu loi TCD. Confusion Matrix (Hnh 5.8) cho thy lị khũng phón tồn ngu nhĩn mị tp trung vộ hai c ch nhm ln cú h thng.

Th nht, Gradual vị Incremental nhm ln ln nhau qua trc Variance Ratio. V lị thuyt, chuyn tip hn hp ca Gradual lịm phng sai ca s phnht to cùn dch chuyn n iu ca Incremental gi phng sai gn nh khũng i (Eq. (4.6)); nhng trỏn d liu mữ phng, c hai c ch u to mt mc phnht phng sai trung gian trong ca s chuyn tip, lịm phón b VR ca hai loi chng ln. H qu lị 47% s kin Incremental b gòn thnh Gradual, vị mt phn Gradual b gòn ngc lị thnh Incremental. Th hai, vị chui nhieu s kin drift chm liỏn tip, còc dch chuyn trỏn nhng tp c trng b thay i tồch lu n khi $P(X)$ bỗo hợ; ca s sau drift khi ú trúng vị mt concept ỗ lu nỏn Concept Memory gòn nhõn Recurrent — chim ti 57% s s kin Gradual. Hai c ch nịy gii thờch vớ sao Gradual vị Incremental tuy vn nm ững nhóm PCD (gi CAT mc 80.1%) nhng chèn xóc mc tiu loi lị thp.

ý lý mt gii hn c hu ca vic phón loi tiu loi drift chm hoịn toịn khũng giòm sòt t hnh dng tòn hui: khi khũng cú nhõn y , ranh gii gia Gradual vị Incremental — cng nh gia mt chui drift chm lp li vi Recurrent — tr nỏn nhp nhng v mt thng kỏ. CDT-MSW, nh s dng tòn hui chõnh xỏc cú giòm sòt, tỏch cỏc lp nịy tt hn nhiiu (Gradual 96.9%, Incremental 74.0%; Bng 5.13). Vic thu hp khong cỏch nịy — chng hn bng mt b phón loi hc t d liu thay cho cỏy quy t nh ngng cng, hoc tỏch bc so khp Concept Memory khi bc phón loi hnh dng — c li nh mt hng phòt trin.

5.3.4 So sỏnh vi CDT-MSW

Bng 5.13 so sỏnh vi CDT-MSW [8], mt phng phỏp supervised s dng label vị d liu UCI thc t.

Bng 5.13 So sỏnh chõnh xỏc phón loi theo tng loi drift gia CDT-MSW (Guo et al. 2022) vị SE-CDT. ý lý i chiu tham kho, khũng phi so sỏnh ng iu kin: CDT-MSW chy cú giòm sòt trỏn 10 tp UCI thc t vị ACC_{subcat} tởnh cú iu kin trỏn cỏc drift c phòt hin vị phón nhúm ỡng; SE-CDT chy khũng giòm sòt trỏn 6 kch bn Gaussian 5-D (Mc 5.3.1) vị SUB tởnh trỏn toịn b ground truth. Cn lu ý thỏm rng “EDR” trong [8] vit tt cho *Error Detection Rate* (cng thp cng tt), khỏc hn vị “EDR” c dng trong lun vn (*Event Detection Rate*, tng ng Recall), nỏn hai ch s trỏng tỏn nịy khũng so sỏnh trc tip c vi nhau.

Drift Type	CDT-MSW (Paper) [%]	SE-CDT (Ours) [%]
Sudden	90.2%	82.4%
Blip	88.5%	60.8%
Gradual	96.9%	27.2%
Incremental	74.0%	30.3%
Recurrent	83.9%	71.5% [†]

[†]Recurrent drift identified via Concept Memory (Standard MMD comparison with stored snapshots; threshold $\tau_{match} = 0.15$).

Vớ hai ct vn hnh trỏn hai phón phi d liu vị hai ch giòm sòt khỏc nhau, bng ch cú ý ngha tham kho. SE-CDT chy khũng cn nhõn vị t recall cao hn trong thit lp nịy, nhng chõnh xỏc phón loi tiu loi vn thp hn CDT-MSW, c bit Gradual vị Incremental. Lun vn khũng khng nh SE-CDT vt CDT-MSW trỏn cng thit lp; so sỏnh trc tip cn trin khai SE-CDT trỏn cỏc tp UCI gc, c lit kỏ lị hng phòt trin Chng 6.

5.4 ờnh giò kh nng thờch ng mữ hnh

Sau khi SE-CDT phòt hin vị phón loi drift, khng thờch ng dng nhõn loi drift chn chin lc cp nht mữ hnh tng ng. Phn nịy ờnh giò hui qu ca chin lc thờch ng theo loi drift (Type-Specific Adaptation) bng ch s **Prequential Accuracy**.

5.4.1 Thit lp thc nghim thờch ng mữ hnh

- **Mữ trng:** Prequential Evaluation trỏn lung d liu mữ phng.

- **D liệu:** $T = 5,000$ mu, $N = 30$ ln chy c lp, mt drift cao (5 s kin/lung).
- **Kch bn:** ba loi: Stepping (drift tồch ly), Sudden, vị Mixed.
- **Bn chín lc thờch ng:**
 - *No Adaptation:* gi nguyên mẫu hình ban u (cn di).
 - *Periodic Retrain:* hun luy n li nh k mi 500 mu, khũng dũng tòn hieu detector.
 - *Simple Retrain:* hun luy n li trũn ca s gn nht mi khi SE-CDT bõo drift, bt k loi nũo.
 - *Type-Specific (xut):* chn mt trong nm nhõnh thờch ng tu theo nhõn drift do SE-CDT phõn loi (Full Reset cho Sudden, Incremental Fine-tune cho Incremental, Recency-weighted cho Gradual, Model Caching cho Recurrent, vị b qua thờch ng cho Blip; xem Mc 4.4).
- **Mũ hõnh d õõn:** pipeline gm chun hoõ c trng bng Standard Scaler vị phõn loi bng Logistic Regression, vị s vũng lp tỉ a t tỉ 1 000. óy lĩ mũ hõnh phõn loi c bo v trong thờ ngĩm thờch ng; SE-CDT ch lĩ tng giõm sõt drift, khũng phi mũ hõnh d õõn nhõn.
- **Tham s:** initial training = 500 mu, adaptation delay = 50 mu, periodic interval = 500 mu, mc ý ngha phõt hĩn $\alpha = 0.05$ (ngng p-value ca kim nh IDW-MMD), ShapeDD $l_1 = 50$, $l_2 = 150$.
- **Ch s:** Prequential Accuracy (chõnh xõc cun chiu) o kh nng phc hĩ sau drift; s False Positives (FP) o chỉ phõr cĩnh bõo d tha.

Lung d liũ mũ phng c to t hĩn hp d liũ Gaussian nm chiu vị nm im drift u nhau. Theo nh ngha ca Lu vị cĩng s [14], mi s kin Sudden, Gradual hoc Incremental phi đĩn n mt concept mi, cũn Recurrent lĩ s lp li cú chu k gia hai concept. ờp ng iũ nũy, b sinh dũng c ch xoay vũng c trng: mi s kin non-recurrent dch chuyn mt tp c trng khõc nhau, trõnh quay v phõn phi õ thũ. Riõĩng Recurrent gi pattern luõn phiõĩn $A \leftrightarrow B$ ỹĩng theo nh ngha. Kch bn Stepping b sung thõĩm thĩĩnh phĩn dch chuyn tồch ly theo cũĩng hĩng mũ phng mũĩ trĩng tĩn hoõ n iũ (võ d trũĩ cm bĩn cũĩng ngĩp).

5.4.2 Phĩm vị phõt hĩn trong thờch ng

Theo gi nh joint drift (Mc 2.1.2), cõc kch bn thờch ng đĩ óy tp trung vịõ kch bn cú thay i rũ rĩĩng $P(X)$, nĩ tòn hieu ca SE-CDT cú th c dũĩng kõch hot cp nht mũ hõnh.

5.4.3 Kt qu phc hi (Recovery)

Còc b to d liu Sudden Drift truyên thng thng luón phỉn gia hai concept $A \rightarrow B \rightarrow A$, dn n mữ hnh tnh cú chỏnh xỏc o $\approx 75\%$. khc phc gii hn nỳ, lun vn b sung kch bn **Stepping Drift**. óy lỳ dng trũi dt tỏch lỳ (Cumulative Sudden Drift), nỳ phón phi d liu liỏn tc dch chuyn ra xa trng thỏi ban u ($P_0 \rightarrow P_1 \rightarrow P_2 \dots$), buc mữ hnh phi hc li liỏn tc duy trỏ hiu sut.

Ngoi ra, h thng tỏch hp c ch **reset b m theo mu ADWIN** (Adaptive Windowing): sau mỳ ln thờch ng, b m c xúa vỳ ch gỳ li 200 mu gn nht lỳm tham chiu mỳ. C ch nỳ gim òng k hìn tng phỏt hìn li cúng mt drift event: Type-Specific vỹ Simple Retrain (c hai u đứng tòn hiu detector kỏch hot) cú FP trung bnh khong 1.5–2.2/run, trong khi Periodic Retrain vỹ No Adaptation (khũng thay i b m theo detector) cú FP trung bnh 13.0–17.0/run.

Bng 5.14 tng hp kt qu Prequential Accuracy trỏn $N = 30$ ln chy c lp, so sỏnh 4 chin lc: Type-Specific (xut), Simple Retrain, Periodic Retrain vỹ No Adaptation. S $N = 30$ kim nh Friedman cú lc thng kỏ cao vỹ m bo khong tin cy 95% cht vỹ lch chun quan sỏt c trỏn cỏc kch bn.

Bng 5.14 Kt qu Prequential Accuracy theo loi drift ($N = 30$ runs, $T = 5000$ mu). Ct FP: s ln bỏo ng sai trung bnh mỳ run, theo th t chin lc (Type-Specific / Simple Retrain / Periodic Retrain / No Adaptation).

Loi Drift	Type-Specific	Simple Retrain	Periodic Retrain	No Adaptation	FP
Stepping (Cumulative)	73.96% ± 2.42	62.72% ± 2.60	64.03% ± 2.74	54.80% ± 3.60	1.5/1.5/17.0/17.0
Sudden (Joint Drift)	73.34% ± 2.72	61.87% ± 2.25	63.65% ± 2.37	53.68% ± 3.46	1.5/1.5/17.0/17.0
Mixed (Combined)	86.36% ± 1.25	83.80% ± 0.96	86.09% ± 0.69	82.69% ± 0.94	2.2/2.2/13.0/13.0

Òp dng kim nh khũng tham s Friedman (paired theo seed) trỏn 4 chin lc $\times$ 30 runs cho mỳ kch bn:


- Stepping: $\chi^2 = 78.76$, $p = 5.66 \times 10^{-17}$
- Sudden: $\chi^2 = 85.48$, $p = 2.05 \times 10^{-18}$
- Mixed: $\chi^2 = 75.16$, $p = 3.35 \times 10^{-16}$

Trỏn c ba kch bn, $p \ll 0.05$ nỏn cú bng chng thng kỏ bỏc b gỳ thuyt H_0 “bn chin lc cho cúng phón phi chỏnh xỏc”. Kt qu nỳ xỏc nhn khỏc bit tng th gia cỏc chin lc; cỏc chỏnh lch theo tng cp bỏn dĩ c dĩn gii theo ln quan sỏt c, khũng thay cho mt kim nh hu nghiũm riỏng cho tng cp.

Trỏn Stepping, Type-Specific t 73.96%, hn No Adaptation +19.16pp, Simple Retrain +11.24pp vỹ Periodic Retrain +9.93pp. Trỏn Sudden, kt qu tng t: Type-Specific t 73.34%, hn No Adaptation +19.66pp, Simple Retrain +11.47pp vỹ Periodic Retrain


+9.69pp. Hai kịch bản này cho thấy lợi ích rõ ràng của việc chọn chiến lược phù hợp nhất theo loại drift thay vì chỉ huấn luyện lại theo một quy tắc cố định.

Trở lại Mixed, Type-Specific đạt 86.36%, vượt gần Periodic Retrain (86.09%) với sai số nhỏ hơn Simple Retrain/No Adaptation. Chênh lệch +0.27pp so với Periodic Retrain nhỏ hơn sai lệch chuẩn, nổi bật hơn hẳn so với chiến lược chọn theo từng cặp; im lặng chờ đợi hơn là FP của Periodic Retrain cao hơn rất nhiều (13.0 so với 2.2/run). Do vậy, lợi thế rõ ràng của Type-Specific trở nên Mixed lại càng rõ ràng hơn so với Periodic Retrain vì đã cân bằng được.




Hình 5.10 Prequential Accuracy trên Stepping Drift ($N = 30$). No Adaptation () đạt $\sim 55\%$ khi phát hiện chuyển đổi. Type-Specific (xanh) đạt khoảng 74% chọn đúng theo loại drift.

Trở lại Sudden (Hình 5.11), No Adaptation giảm xuống 53.68% do toàn bộ phát hiện thay đổi sau khi xảy ra. Type-Specific đạt 73.34%, kém hơn Simple Retrain +11.47pp với Periodic Retrain +9.69pp. Ở hai kịch bản Stepping (Hình 5.10) và Sudden cho thấy cần phải có chiến lược chọn theo loại drift.



Hình 5.11 Prequential Accuracy trốn Sudden Drift ($N = 30$). No Adaptation gim v $\sim 54\%$; Type-Specific duy trở không 74% nh chn Full Reset cho tng s kin Sudden m.

Trốn Mixed (Hình 5.12), bn chín lc u t kt qu cao hn hai kch bn trốn do lung d liu cha hn hp còc loi drift cú mc khú khòc nhau. Type-Specific t 86.36%, gn vi Periodic Retrain (86.09%) nhng vi FP thp hn (2.2 so vi 13.0/run). óy lị kt qu gn hòa v chònh xòc theo ngha thc nghim, nhng Type-Specific ờt kờch hot tha hn.



Hình 5.12 Prequential Accuracy trên Mixed Drift ($N = 30$). Type-Specific và Periodic Retrain giảm thiểu nhiễu trong artifact hình vẽ, nhưng Type-Specific có sự cân bằng thấp hơn.

5.5 Kim thử nghiệm mô phỏng kiến trúc tăng trưởng Kafka


Phạm vi của nguyên mẫu Kafka ở mức 4.5 (luồng và phạm vi triển khai); phần này chỉ thảo luận về quá trình kiểm thử khớp kờn giữa các thành phần Redpanda, SE-CDT Consumer và Adaptation Manager trên Docker.

5.5.1 Kế hoạch triển khai

- **Dữ liệu:** Lượng dữ liệu mẫu phân phối SEA dataset vì Sudden Drift tỉ lệ 1500.
- **Cuồng hình:** Các số phút hình $W = 250$ mẫu, thời gian $\Delta = 50$ mẫu (thu thập dữ liệu sau khi drift xảy ra khi cần).
- **Mục tiêu:** Xác nhận quy trình khớp kờn: Phát hiện Drift → thu thập dữ liệu mới → cập nhật mô hình → nạp lại mô hình → phục hồi chèn xóc.

5.5.2 Kết quả thực tế

Hình 5.13 trình bày dashboard giám sát drift trong môi trường thực nghiệm:



Hình 5.13 Dashboard giám sát nguồn nhiễu trong môi trường Kafka. (1) Dữ liệu nhiễu vì im drift tại mẫu 1500. (2) Chờn xóc giảm xung 0.59 tại im drift, sau đó phục hồi lên 0.93 sau khi mẫu nhiễu có sự thay đổi. (3) Thông tin SE-CDT phát hiện Sudden Drift. (4) Tài nguyên hệ thống (CPU/RAM) duy trì ổn định trong môi trường thực nghiệm.

- **tr phát hiện:** Drift của dữ liệu tại mẫu 1500 trong dữ liệu. ShapeDD xác định im drift tại mẫu 1476. Có lý do trở nên tam giác có đỉnh (triangle peak position) từ thông tin tích hợp ShapeDD, không phải chỉ dựa vào lý thuyết. Do các đặc điểm của vị trí lệch hình dạng, vì trở drift

bồ cồ cú th lch so vi nhõn danh ngha $\pm l_1$ (vi $l_1 = 50$ lị kờch thc na ca s reference), nm trong gii hn chp nhn ca ShapeDD.

- **Quy trnh khõp kờn:** Log h thng xõc nhn Consumer õ nhn tòn hiu cp nht t b thờch ng vị ti li mũ hõnh thnh cũng ti mu 2277.
- **Hiu qu phc hi:** chõnh xõc tng t mc 59% (gn ngu nhiõn) lõn 93% ngay sau khi mũ hõnh mi c ti, khp vi hnh vi mong i ca quy trnh thờch ng.

5.6 Kt lun chng

Cõc kt qu thc nghiõm cho thy ShapeDD-IDW t $F_1 = 0.531$ vi khong 9.6 FP/run trõn benchmark phõt hin, cao hn ShapeDD gc ($F_1 = 0.491$) vị khũng khõc bit thng kổ so vi DAWIDD di kim nh Nemenyi. V tc , benchmark cho thy ShapeDD-IDW nhanh hn $\approx 7.2\times$ so vi ShapeDD gc nh xp x Gamma thay th permutation test tn kỏm, trong khi kim nh IDW-MMD gi Type-I error n l gn mc $\alpha = 0.05$; pipeline SE-CDT composite vn cn c c thn trng vớ Type-I error cú th lõn n 0.140 trõn d liu AR(1).

bị toàn phõn loi, SE-CDT t CAT = 80.1%, SUB micro = 55.3% vị SUB macro = 54.4% oracle mode. Kt qu tt nht nm Sudden, Blip vị Recurrent; hai tiu loi drift chm Gradual vị Incremental lị khú nht do tòn hiu chuyn tip chng ln v phng sai vị mt phn b Concept Memory hũt sang nhõnh Recurrent. Trong ònh giò thờch ng, Type-Specific ci thn rủ trõn Stepping vị Sudden, cùn trõn Mixed thờ gn ngang Periodic Retrain v chõnh xõc nhng ờt FP hn. Nhõn chung, kin trũc xut kh thi, nhng cõc kt qu cng ch ra rủ nhng phn cn ci thn trc khi xem óy lị mt b phõn loi drift hoịn chnh.

Benchmark detection tp trung ch yu vớ sudden/abrupt drift vị blip, ỹng vị trng tóm thit k ca ShapeDD gc [7] lị phõt hin thay i phõn phi t ngt. Cõc loi drift chm hn (gradual, incremental) vị drift lp li (recurrent) c a vớ benchmark phõn loi nh m rng nng lc, khũng phi trng tóm ti u. Kt qu phõn loi theo tng loi drift (Bng 5.12) phn ònh ỹng khú vn cú vị m ra hng ci tin cho cõc cũng trnh tip theo.

CHNG 6

KT LUN VỊ HNG PHÒT TRIN

6.1 Tng kt còc ứng gúp chònh

Lun vn gii quyit bị toàn phòt hin, phón loi vị thờch ng vị concept drift trong mũi trng d liu lung. Bng 6.1 tóm tt còc s liu chònh; phn sau đin gii ý ngha vị gii hn ca còc kt qu nịy.

Bng 6.1 Tóm tt s liu chònh ca lun vn theo ba trc ứng gúp. Chi tit vị phón tòch thng kỏ trong Chng 5.

Trc	Kt qu chònh	i chng
Module phòt hin ca SE-CDT (Mc 5.2)	ShapeDD-IDW t $F_1 = 0.531$, khũng khòc bit thng kỏ vị DAWIDD; runtime nhanh hn ShapeDD gc khong $7\times$	ShapeDD gc đứng permutation; KS-Test cú Recall cao nhng FP nhieu
Module phón loi ca SE-CDT (Mc 5.3)	t CAT = 80.1%, SUB micro = 55.3%, SUB macro = 54.4%; nhúm TCD n nh, hai tiu loi drift chm Gradual/Incremental lị khú nht	CDT-MSW (Guo et al.) đứng nhõn y vị khũng cừng thit lp d liu
Thòch ng (Mc 5.4)	Type-Specific Adaptation cì thìn rủ trỏn Sudden/Stepping; trỏn Mixed gn Periodic Retrain v chònh xòc nhng ỏt FP hn	No Adaptation, Periodic Retrain, Simple Retrain

H thng SE-CDT gm hai module nị tip: module phòt hin ShapeDD-IDW thay permutation test y bng xp x Gamma cho IDW-MMD vị ỏp dng hiu chnh Bonferroni khi mt trace cú nhieu nh ng viỏn; module phón loi c hnh dng tòn hiu MMD do bc phòt hin sn xut xut nhõn loi drift mị khũng cn nhõn y . Kim tra trỏn d liu tnh cho thy IDW-MMD n l gn mc danh ngha $\alpha = 0.05$, dứ pipeline SE-CDT composite vn cú th cao hn trỏn mt s phón phi do bc chn nh vị ca s trt. Kt qu phón loi đứng cho mt s quyit nh thờch ng, nhng cha t mc n nh ca phng phòp cú giòm sòt.

Benchmark c m rng vị d liu recurrent i xng $A \rightarrow B \rightarrow A \rightarrow B$, gradual drift cú khong chuyn tip xòc nh, vị d liu stationary o bòo ng gi. Nh 30 ln chy c lp vị kim nh Friedman/Nemenyi, còc kt lun v th hng detection c c thn trng hn: mt s chỏnh lch s hc khũng kt lun khòc bit thng kỏ. phn h thng, nguỷn mu Kafka/Redpanda cho thy

còn module phát hiện, phân loại vị thời gian cụ thể tách rời vị phù hợp c trong mt pipeline streaming khớp kờn.

6.2 Hn ch vị Phm vi nghiên cu

Bốn cnh kt qu t c, nghiên cu vn cùn mt s hn ch:

6.2.1 Trade-off gia Recall vị False Positives

SE-CDT (Std) u tiỏn EDR cao vị chp nhn FP nhieu hn; SE-CDT (IDW) ngc li, FP thp hn nhng cng gim EDR (s liu c th Mc 5.2 vị Mc 5.3). Hai cu hnh phc v hai mc tiỏu s dng khỏc nhau: nu u tiỏn khũng b sút drift trong giỏm sỏt vn hnh thờ đứng SE-CDT (Std), cùn nu chỉ phờ phn ng cao vị cn gim bỏo ng gi thờ đứng SE-CDT (IDW) vị ngng cht hn. Mun gim FP thỏm cú th sit α hoc hieu chnh a kim nh theo s nh ng viỏn, i li recall cú th gim.

6.2.2 Subcategory Accuracy cùn hn ch

Category Accuracy (TCD vs PCD) t 80.1%, cùn Subcategory Accuracy t 55.3% theo micro-average vị 54.4% theo macro-average. Hai tiu loi drift chm lị khú nht: Gradual t 27.2% vị Incremental t 30.3%. c trng Variance Ratio (da trỏn nh lut Tng Phng Sai) b sung thũng tin phng sai d liu thũ tỏch hai loi nịy, nhng phón b VR ca chũng chng ln òng k nỏn gn mt na s kin Incremental b gỏn thnh Gradual; ng thi vị chui drift chm lp li, ca s sau drift bỏo hoị vị b Concept Memory gỏn sang Recurrent. C hai vn nm ửng nhúm PCD nỏn Category Accuracy khũng b nh hng. Recurrent t 71.5% nh Concept Memory nhng vn ph thuc vọo ngng so khp τ_{match} vị kờch thc snapshot n_s . Blip t 60.8% sau khi ni lut, song cn kim chng thỏm trỏn d liu thc t.

Nguyễn nhón gc lị CDT-MSW [8] đứng Growth process da trỏn chờnh xỏc cú nhón phón bit TCD vị PCD, trong khi SE-CDT ch quan sỏt tỏn hieu MMD ca $P(X)$. Vớ MMD c o trỏn ca s trt khỏ rng, quỏ trnh chuyn i cú th b nỏn thnh cỏc on tỏn hieu tng t nhau. Khi khũng cú nhón, kh nng phón bit tiu loi theo tc drift thp hn so vị phng phỏp cú giỏm sỏt lị iu cn chp nhn.

6.2.3 Ngng phón loi vn cùn yu t heuristic

Cỏc ngng cng trong lut phón loi SE-CDT (Gii thut 3) nh $WR < 0.15$, $SNR > 2.0$, $CV < 0.3$, $LTS > 0.5$, v.v. vn c chn da trỏn quan sỏt thc nghim ch cha suy ra t phón tỏch thng kỏ lý thuyt. So vi bc phỏt hin (đứng p-value da trỏn xp x Gamma cú c s

t [47]), bc phón loi cha cú cũng c lý thuyt tng ng mc tng c trng n l. Còc bin phòp ò òp dng gim ph thuc heuristic.

1. **T hieu chnh ngng SNR/WR/CV** (Mc 4.3.6): ni ngng cng theo phón v quan sòt trón ca s khũng drift, giúp SE-CDT chu c nn nhieu cao hn mị khũng cn tinh chnh th cũng cho tng dataset.
2. **Kim tra Type-I error** (Mc 5.2.5): kim chng IDW-MMD vì xp x Gamma cú Type-I error gn mc danh ngha trón ba phón phi tnh; ng thi ch ra SE-CDT composite cú th cao hn nh do kim nh nhieu nh ng vión.
3. **Loi b còc hng s tuyt i trong Blip vị Growth process** (Mc 4.3): iu kin Blip ch da trón còc c trng t l, khũng gn vì ngng khong còch peak c nh; tham s trong Growth process c biu din theo t l vì ca s tham chiu l_1 thay cho hng s dng phn ba rng FWHM.

Tuy nhiên, vn cùn tn ng nhng vn hn ch nh sau.

1. Self-calibration ch cú th ni ngng, cha thay c lut phón loi bng mt mũ hnh xóc sut, vớ vy vn khũng xut confidence/p-value cho mị nhón drift.
2. Ngng cho LTS, MS, SDS vn c nh, cha c t hieu chnh. Ba c trng nịy cú min giò tr nh vị nhy vì kòch thc ca s, nỏn vic rứt phón v t d liu nn khũng drift d to ra giò tr kỏm n nh.
3. Concept Memory vn cn ngng so khp $\tau_{\text{match}} = 0.15$ chn theo thc nghim (t mc khong $2 \times$ nhieu MMD nn). Khi snapshot tòch ly gn vì mt s kin Sudden mị, ngng nịy cú th dòn nhón nhm thịnh Recurrent. Hng cho ngng t thờch nghi theo phón phi c trnh bựy Mc 6.3.2.

Phn phón loi hin ti ò cú kh nng t ni mt s ngng theo d liu quan sòt khi vn hnh, nhng cha xut c tin cy cho mị nhón. bc phón loi t mc xóc sut y cn còc nghiỏn cu tip theo, c trnh bựy phn Hng phòt trin.

6.2.4 Gi nh joint drift trong phón loi

SE-CDT phón loi hnh dng thay i ca $P(X)$ di gi nh joint drift (Mc 2.1.2); còc tnh hung ch cú $P(Y|X)$ thay i hoc ch cú $P(X)$ thay i mị ranh gii quy t nh gi nguỷn u nm ngoị phm vì thit k. óy lị gii hn chung ca mị phng phòp unsupervised drift detection, nỏn trong trin khai thc t cn kt hp SE-CDT vì giòm sòt hieu sut mũ hnh khi nhón cú sn, dứ cú tr.

6.2.5 D liệu tổng hợp (Synthetic Data)

Đòn giò ch yu đa trồn còc tp d liệu tng hp. D liệu tng hp cho phốp kim soát chồnh xòc ground truth (thi im drift, loi drift) o F1-score vị tr, nhng cú th cha phn ònh ht phc tp, nhieu vị tòngh bt nh ca d liệu thc t trong còc h thng sn xut quy mĩ ln.

6.2.6 Phm vi ònh giò thờch ng

ònh giò thờch ng Chng 5 dng 4 phng òn so sòngh (Type-Specific, Simple Retrain, Periodic Retrain, No Adaptation) trồn 3 kch bn (Stepping, Sudden, Mixed) vị $N = 30$ ln chy, $T = 5000$ mu, initial training = 500, adaptation delay = 50, periodic interval = 500, vị mĩ hnh nn gm Standard Scaler kt hp Logistic Regression vị s vùng lp ti a 1 000. Hng m rng t nhĩn: (1) b sung kch bn Gradual vị Incremental drift, (2) o chi phờ tòngh toòn ca tng chin lc trong mĩ trng trin khai thc t, vị (3) ònh giò trồn d liệu thc t cú drift ground truth c kim chng.

6.2.7 Nguồn mu Kafka cha phi benchmark production

Nguồn mu Kafka/Redpanda trong lun vn chng minh c lung x lý khốp kòn gia producer, SE-CDT Consumer vị Adaptation Manager, nhng cha phi benchmark h tng sn xut. Còc ch s cn cú trc khi trin khai thc t gm tr u-cui đi ti cao, thũng lng khi tng s partition, thi gian phc hi khi broker/consumer li, n nh khi cú backpressure vị quy trnh shadow deployment cho mĩ hnh mi. Vớ vy kt qu nguồn mu ch chng minh tòngh kh thi kin trũc, khũng chng minh nng lc vn hnh production-grade.

6.3 Hng nghiỏn cu tng lai

Còc hng tip theo tp trung vọ phn phón loi, vớ óy lĩ mt xòch cùn yu nht trong pipeline hin ti.

6.3.1 M rng sang còc loi Drift khòc nhau

Gradual vị Incremental cn mt tòngh hũu tt hn ca s trt hin ti. Mt hng hp lý lĩ dng ca s tham chũu a thang o: gi mt ca s dị lĩm baseline n nh, ng thi vn dng ca s ngn bt thay i nhanh. Khi ú tòngh hũu MMD cú th duy trũ mc cao vị drift bn vng vị tr v baseline vị drift tm thi, giũp tòch Incremental khi Gradual rũ hn. Vi Incremental, cng nỏn th nghiĩm còc chin lc cp nht liỏn tc bng th vin River cón bng gia tc thờch ng vị n nh mĩ hnh.

Concept Memory có thể có m rng bng còch hc biu din snapshot thay vớ so sòngh trc tip ca s thũ bng Standard MMD. Ngng τ_{match} cng nỏn c hc t phón phi khong còch gia còc snapshot khũng drift, thay vớ t c nh. Nu liỏn kt c Concept Memory vi Model Caching, h thng cú th tời s dng c mũ hỏnh ỏ hc ch khũng ch nhn din rng mt concept c ỏ quay li.

6.3.2 Cỏ tin phón loi SE-CDT

Nh ỏ phón tỏch trong Mc 6.2.3, bc phón loi ca SE-CDT vn li phn cú c s lý thuyt yu nht trong chui x lý, dứ ỏ c cng c bng t hieu chnh ngng vị kim tra Type-I error. Còc hng cỏ tin tip theo: V bn thón SE-CDT, hng quan trng nht li thay lut ngng cng bng mũ hỏnh cú th c lng tin cy ca nhón phón loi. Còc c trng thi gian nh LTS, MS vị SDS cng cn c ch t hieu chnh riỏng, vớ hin vn dứng ngng c nh. Khi mìn ng dng cú mt lng nh nhón, cú th dứng chũng tnh chnh ngng hoc hun luyt mũ hỏnh nh trỏn chui MMD, thay vớ ph thuc hoịn toịn vớ c trng th cũng.

6.3.3 Hng dũi hn

V dũi hn, h thng cú th tin ti meta-learning trc tuyt t chn chin lc thờch ng vị tham s theo c im d liu quan sỏt. Mt benchmark chun húa vị d liu thc t c gòn nhón drift k lng cng rt cn thit, vớ d liu tng hp giũp kim soỏt ground truth nhng cha phn ỏnh y nhieu vị tỏnh bt nh ca mũi trng sn xut.

6.4 Kt lun

Lun vn xut h thng SE-CDT — mt pipeline khũng giỏm sỏt thờch hp phỏt hin vị phón loi drift, kt hp vị khung thờch ng theo loi drift. Module phỏt hin (ShapeDD-IDW) t F1 cnh tranh vị DAWIDD vị tt hn ShapeDD gc trong benchmark hin ti, dứ chỏnh lch th hng khũng kt lun khỏc bit thng kỏ vi DAWIDD. Module phón loi t kt qu chp nhn c mc TCD/PCD nhng cùn yu tiu loi, c bit vị Incremental. ỏy li giũ hn ln nht trong phm vị nghiỏn cu ca lun vn, ùi hi s nhón nhn khỏch quan lỳm tin cho còc hng tip cn tip theo.

Kt qu thờch ng cho thy thũng tin loi drift cú ỏch trỏn Stepping vị Sudden, ni Type-Specific vt rủ No Adaptation vị còc baseline retrain n gin. Trỏn Mixed, Type-Specific vị Periodic Retrain gn tng ng v chỏnh xỏc trong artifact hin ti, cùn li th rủ hn ca Type-Specific li gim cnh bỏo d. Vớ vy, úng gúp ca lun vn nm vic t nn cho mt h thng drift-aware cú th vn hnh khũng cn nhón tc thi; tin ti ỏp dng trong mũi trng vn hnh

thực tế, phần lớn lỗi của các công cụ phân tích dữ liệu là do sự sai lệch của dữ liệu đầu vào, do đó việc kiểm tra và xử lý dữ liệu đầu vào là một bước rất quan trọng trong quá trình phân tích dữ liệu. Việc kiểm tra và xử lý dữ liệu đầu vào có thể được thực hiện bằng cách sử dụng các công cụ phân tích dữ liệu để kiểm tra và xử lý dữ liệu đầu vào.

DANH MỤC CŨNG B KHOA HỌC

Thống tin v còc cũng b khoa hc ca tồc gi cú liỏn quan n ni dung lun vn:

Hì ngh quc t / Tp chồ:

Hc viỏn cha cú cũng b khoa hc.

TII LIU THAM KHO

- [1] T. Wuest, D. Weimer, C. Irgens, and K.-D. Thoben, “Machine learning in manufacturing: advantages, challenges, and applications,” *Production & Manufacturing Research*, vol. 4, no. 1, pp. 23–45, 2016.
- [2] N. Jourdan, L. Longard, T. Biegel, and J. Metternich, “Machine learning for intelligent maintenance and quality control: A review of existing datasets and corresponding use cases,” in *Proceedings of the Conference on Production Systems and Logistics (CPSL 2021)*. publish-Ing., 2021, pp. 473–483.
- [3] S. Tripathi, D. Muhr, M. Brunner, H. Jodlbauer, M. Dehmer, and F. Emmert-Streib, “Ensuring the robustness and reliability of data-driven knowledge discovery models in production and manufacturing,” *Frontiers in Artificial Intelligence*, vol. 4, p. 576892, 2021.
- [4] N. Jourdan, T. Bayer, T. Biegel, and J. Metternich, “Handling concept drift in deep learning applications for process monitoring,” *Procedia CIRP*, vol. 120, pp. 33–38, 2023.
- [5] L. Yuan, H. Li, B. Xia, C. Gao, M. Liu, W. Yuan, and X. You, “Recent advances in concept drift adaptation methods for deep learning,” in *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence (IJCAI-22)*. IJCAI, 2022, pp. 5654–5661.
- [6] F. Hinder, V. Vaquet, and B. Hammer, “One or two things we know about concept drift: a survey on monitoring in evolving environments. part a: detecting concept drift,” *Frontiers in Artificial Intelligence*, vol. 7, p. 1330257, 2024.
- [7] F. Hinder, J. Brinkrolf, V. Vaquet, and B. Hammer, “A shape-based method for concept drift detection and signal denoising,” in *2021 IEEE Symposium Series on Computational Intelligence (SSCI)*. IEEE, 2021, pp. 1–8.
- [8] H. Guo, H. Li, Q. Ren, and W. Wang, “Concept drift type identification based on multi-sliding windows,” *Information Sciences*, vol. 585, pp. 1–23, 2022.
- [9] J. C. Schlimmer and R. H. Granger, “Incremental learning from noisy data,” *Machine learning*, vol. 1, no. 3, pp. 317–354, 1986.

- [10] K. Ramakrishnan, D. Preuveneers, and Y. Berbers, “Enabling self-learning in dynamic and open iot environments,” *Procedia Computer Science*, vol. 32, pp. 207–214, 2014.
- [11] G. Hovakimyan and J. Bravo, “Evolving strategies in machine learning: A systematic review of concept drift detection,” *Information*, vol. 15, no. 12, p. 786, 2024.
- [12] J. G. Moreno-Torres, T. Raeder, R. Alaiz-Rodríguez, N. V. Chawla, and F. Herrera, “A unifying view on dataset shift in classification,” *Pattern recognition*, vol. 45, no. 1, pp. 521–530, 2012.
- [13] J. Gama, I. Iobait, A. Bifet, M. Pechenizkiy, and A. Bouchachia, “A survey on concept drift adaptation,” *ACM computing surveys*, vol. 46, no. 4, pp. 1–37, 2014.
- [14] J. Lu, A. Liu, F. Dong, F. Gu, J. Gama, and G. Zhang, “Learning under concept drift: A review,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 31, no. 12, pp. 2346–2363, 2019.
- [15] M. Basseville and I. V. Nikiforov, *Detection of abrupt changes: theory and application*. Prentice Hall Englewood Cliffs, 1993, vol. 104.
- [16] B. Celik and J. Vanschoren, “Adaptation strategies for automated machine learning on evolving data,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 9, pp. 3067–3078, 2021.
- [17] A. Gretton, K. M. Borgwardt, M. J. Rasch, B. Schölkopf, and A. Smola, “A kernel two-sample test,” *Journal of Machine Learning Research*, vol. 13, no. 25, pp. 723–773, 2012.
- [18] B. Schölkopf and A. J. Smola, *Learning with kernels: support vector machines, regularization, optimization, and beyond*. Cambridge, MA: MIT Press, 2002.
- [19] A. Bifet and R. Gavaldà, “Learning from time-changing data with adaptive windowing,” in *Proceedings of the 2007 SIAM International Conference on Data Mining (SDM)*. SIAM, 2007, pp. 443–448.
- [20] P. Good, *Permutation Tests: A Practical Guide to Resampling Methods for Testing Hypotheses*, 2nd ed. New York: Springer, 2000.
- [21] A. Bharti, M. Naslidnyk, O. Key, S. Kaski, and F.-X. Briol, “Optimally-weighted estimators of the maximum mean discrepancy for likelihood-free inference,” in *Proceedings of the 40th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 202. PMLR, 2023, pp. 2289–2312. [Online]. Available: <https://proceedings.mlr.press/v202/bharti23a.html>

- [22] E. S. Page, “Continuous inspection schemes,” *Biometrika*, vol. 41, no. 1/2, pp. 100–115, 1954.
- [23] D. V. Hinkley, “Inference about the change-point from cumulative sum tests,” *Biometrika*, vol. 58, no. 3, pp. 509–523, 1971.
- [24] C. Raab, M. Heusinger, and F.-M. Schleif, “Reactive soft prototype computing for concept drift streams,” *Neurocomputing*, vol. 416, pp. 340–351, 2020.
- [25] J. Gama, P. Medas, G. Castillo, and P. Rodrigues, “Learning with drift detection,” in *Advances in Artificial Intelligence – SBIA 2004*, ser. Lecture Notes in Computer Science, vol. 3171. Springer Berlin Heidelberg, 2004, pp. 286–295.
- [26] M. Baena-García, J. del Campo-Ávila, R. Fidalgo-Merino, A. Bifet, R. Gavaldà, and R. Morales-Bueno, “Early drift detection method,” in *Proceedings of the 4th ECML PKDD International Workshop on Knowledge Discovery from Data Streams (IWKDDs 2006)*, Berlin, Germany, 2006, pp. 77–86.
- [27] I. Frías-Blanco, J. del Campo-Ávila, G. Ramos-Jiménez, R. Morales-Bueno, A. Ortiz-Díaz, and Y. Caballero-Mota, “Online and non-parametric drift detection methods based on hoeffding’s bounds,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 27, no. 3, pp. 810–823, 2015.
- [28] A. Pesaranghader and H. L. Viktor, “Fast hoeffding drift detection method for evolving data streams,” in *Joint European Conference on Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*. Springer, Cham, 2016, pp. 96–111.
- [29] A. Pesaranghader, H. Viktor, and E. Paquet, “Mediarmid drift detection methods for evolving data streams,” in *2018 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2018, pp. 1–9.
- [30] R. S. Barros, D. R. Cabral, P. M. Gonçalves Junior, and S. G. Santos, “Rddm: Reactive drift detection method,” *Expert Systems with Applications*, vol. 90, pp. 344–355, 2017.
- [31] M. M. W. Yan, “Accurate detecting concept drift in evolving data streams,” *ICT Express*, vol. 6, no. 4, pp. 332–338, 2020.
- [32] O. A. Mahdi, E. Pardede, N. Ali, and J. Cao, “Diversity measure as a new drift detection method in data streaming,” *Knowledge-Based Systems*, vol. 191, p. 105227, 2020.
- [33] P. Wang, N. Jin, and G. Fehringer, “Concept drift detection with false positive rate for multi-label classification in IoT data stream,” in *2020 International Conference on UK-China Emerging Technologies (UCET)*. IEEE, 2020, pp. 1–4.

- [34] S. Bach and M. Maloof, “Paired learners for concept drift,” in *Proceedings - IEEE International Conference on Data Mining, ICDM*, 12 2008, pp. 23–32.
- [35] K. Nishida and K. Yamauchi, “Adaptive classifiers-ensemble system for tracking concept drift,” in *Sixth International Conference on Machine Learning and Cybernetics (ICMLC)*. IEEE, 2007, pp. 3607–3612.
- [36] R. Elwell and R. Polikar, “Incremental learning of concept drift in nonstationary environments,” *IEEE Transactions on Neural Networks*, vol. 22, no. 10, pp. 1517–1531, 2011.
- [37] Ö. Gözüaık and F. Can, “Concept learning using one-class classifiers for implicit drift detection in evolving data streams,” *Artificial Intelligence Review*, vol. 54, no. 5, pp. 3725–3747, 2021.
- [38] M. Pratama, C. Za’in, A. Ashfahani, Y. S. Ong, and W. Ding, “Automatic construction of multi-layer perceptron network from streaming examples,” in *Proceedings of the 28th ACM international conference on information and knowledge management*, 2019, pp. 1171–1180.
- [39] M. Jaworski, L. Rutkowski, and P. Angelov, “Concept drift detection using autoencoders in data streams processing,” in *Artificial Intelligence and Soft Computing (ICAISC 2020)*, ser. Lecture Notes in Computer Science, vol. 12415. Springer, Cham, 2020, pp. 124–133.
- [40] K. Hundman, V. Constantinou, C. Laporte, I. Colwell, and T. Soderstrom, “Detecting spacecraft anomalies using LSTMs and nonparametric dynamic thresholding,” in *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD)*. ACM, 2018, pp. 387–395.
- [41] G. Widmer and M. Kubat, “Learning in the presence of concept drift and hidden contexts,” *Machine Learning*, vol. 23, no. 1, pp. 69–101, 1996.
- [42] F. Hinder, A. Artelt, and B. Hammer, “Towards non-parametric drift detection via dynamic adapting window independence drift detection (dawidd),” in *Proceedings of the 37th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 4249–4259. [Online]. Available: <https://proceedings.mlr.press/v119/hinder20a.html>
- [43] A. Ashfahani and M. Pratama, “Autonomous deep learning: Continual learning approach for dynamic environments,” in *Proceedings of the 2019 SIAM International Conference on Data Mining (SDM)*. Society for Industrial and Applied Mathematics, 2019, pp. 666–674.
- [44] A. Ashfahani, M. Pratama, E. Lughofer, and Y.-S. Ong, “DEV DAN: Deep evolving denoising autoencoder,” *Neurocomputing*, vol. 390, pp. 297–314, 2020.

- [45] Ö. Gözüaık, A. Bykakir, H. Bonab, and F. Can, “Unsupervised concept drift detection with a discriminative classifier,” in *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*. ACM, 2019, pp. 2365–2368.
- [46] J. Yoon, E. Yang, J. Lee, and S. J. Hwang, “Lifelong learning with dynamically expandable networks,” in *International Conference on Learning Representations (ICLR)*, 2018. [Online]. Available: <https://openreview.net/forum?id=Sk7KsfW0->
- [47] A. Gretton, K. Fukumizu, Z. Harchaoui, and B. K. Sriperumbudur, “A fast, consistent kernel two-sample test,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 22, 2009, pp. 673–681.
- [48] J. Kreps, N. Narkhede, and J. Rao, “Kafka: a distributed messaging system for log processing,” in *Proceedings of the NetDB workshop*, 2011.
- [49] Apache Software Foundation, “Apache kafka documentation,” <https://kafka.apache.org/documentation/>, 2024.
- [50] G. Wang, J. Koshy, S. Subramanian, K. Paramasivam, M. Zadeh, N. Narkhede, J. Rao, J. Kreps, and J. Stein, “Building a replicated logging system with apache kafka,” *Proceedings of the VLDB Endowment*, vol. 8, no. 12, pp. 1654–1655, 2015.
- [51] M. Kleppmann and J. Kreps, “Kafka, samza and the unix philosophy of distributed data,” *Bulletin of the IEEE Computer Society Technical Committee on Data Engineering*, vol. 38, no. 4, pp. 4–14, 2015.
- [52] K. Goodhope, J. Koshy, J. Kreps, N. Narkhede, R. Park, J. Rao, and V. Y. Ye, “Building linkedin’s real-time activity data pipeline,” *Bulletin of the IEEE Computer Society Technical Committee on Data Engineering*, vol. 35, no. 2, pp. 33–45, 2012.
- [53] B. R. Hiraman, A. M. Viresh, S. A. Patil, and A. B. Kolekar, “A study of apache kafka in big data stream processing,” in *2018 International Conference on Information, Communication, Engineering and Technology (ICICET)*. IEEE, 2018, pp. 1–3.
- [54] J. Montiel, M. Halford, S. M. Mastelini, G. Bolmier, R. Sourty, R. Vaysse, A. Zouitine, H. M. Gomes, J. Read, T. Abdessalem, and A. Bifet, “River: machine learning for streaming data in python,” *Journal of Machine Learning Research*, vol. 22, no. 110, pp. 1–8, 2021. [Online]. Available: <https://jmlr.org/papers/v22/20-1380.html>
- [55] W. N. Street and Y. Kim, “A streaming ensemble algorithm (sea) for large-scale

- classification,” in *Proceedings of the seventh ACM SIGKDD international conference on Knowledge discovery and data mining*, 2001, pp. 377–382.
- [56] G. Hulten, L. Spencer, and P. Domingos, “Mining time-changing data streams,” in *Proceedings of the seventh ACM SIGKDD international conference on Knowledge discovery and data mining*, 2001, pp. 97–106.
- [57] M. Harries, “SPLICE-2 comparative evaluation: Electricity pricing,” School of Computer Science and Engineering, University of New South Wales, Technical Report, 1999.
- [58] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.

PH LC

A. Bng cu hnh tham s thc nghim

Bng di óy tng hp còc tham s chònh c s dng trong toin b thc nghim. Còc giò tr c ly t mỗ ngun trin khai vị gi c nh trong sut quò trnh ònh giò, tr khi c ghi chữ riống.

Bng A.1: Cu hnh tham s Detection Module (ShapeDD-IDW)

Tham s	Giò tr	Mũ t
l_1	50	Kòch thc ca s tham chiu (reference window)
l_2	150	Kòch thc ca s kim tra (test window)
α	0.05	Mc ý ngha thng kổ cho kim nh drift
N_{perm}	2 500	S vùng hoàn v cho ShapeDD gc (permutation test)
Stride (s)	10	Bc trt ca s
Kernel	RBF	Ht nhón Gaussian $k(x, y) = \exp(-\gamma\ x - y\ ^2)$
γ	median heuristic	c lng mt ln trón on u ca lung
ϵ	0.5	Hng s n nh s hc trong IDW weighting
Weighting scheme	Inverse density	Phng phòp tònhr trng s IDW-MMD da trón mt cc b
Gaussian filter σ_g	4	lch chun b lc Gauss lịm mt tòn hui
Peak threshold	$\bar{\sigma}_s + 0.3\sigma_{\text{std}}$	Ngng phòt hin nh ng viốn

Bng A.2: Cu hnh tham s Classification Module (SE-CDT)

Tham s	Giò tr	Mũ t
<i>Ngng phón loi (mc nh / trc self-calibration)</i>		
WR threshold (τ_{WR})	0.15	Ngng Peak Width Ratio cho Sudden
WR threshold (TCD/PCD)	0.12	Ngng WR trong EstimateDriftDuration: $\leq 0.12 \Rightarrow$ TCD, $> 0.12 \Rightarrow$ PCD
SNR threshold (τ_{SNR})	2.0	Ngng Signal-to-Noise cho TCD
CV threshold (τ_{CV})	0.3	Ngng Periodicity CV cho Recurrent
LTS threshold	0.5	Ngng Linear Trend Strength cho Incremental
MS threshold	0.6	Ngng Monotonicity Score (kt hp vi LTS)
SDS threshold	0.12	Ngng Step Detection Score (kt hp vi LTS)
PPR threshold	0.20	Ngng Peak Proximity Ratio cho Blip
DPAR threshold	0.60	Ngng Dual-Peak Amplitude Ratio cho Blip
<i>BlipProfile — bin th noisy (kt hp vi compact_pair)</i>		
WR (noisy blip)	< 0.17	Peak hp nhng rng hn compact
SNR (noisy blip)	(1.45, 2.60)	Tồn hiiu trung bnh, khng quỏ mnh
DPAR (noisy blip)	(0.45, 0.85)	Hai nh gn i xng
LTS (noisy blip)	< 0.12	Khng cú xu hng tuyen tnh
drift_length	> 1	FWHM vt ngng TCD/PCD do nhiiu
<i>Concept Memory</i>		
M	8	S lng snapshot ti a trong b nh vùng
n_s	150	S im d liu mi snapshot
τ_{match}	0.15	Ngng Standard-MMD so khp concept ($\approx 2 \times$ nhiiu nn)
<i>Self-Calibration</i>		
baseline_size	200	Khch thc b m vùng rolling baseline
baseline_min_history	20	S mu ti thiiu trc khi khch hot t hiiu chnh

Bng A.3: Cu hnh Benchmark ònh giò

Tham s	Giò tr	Mũ t
<i>Detection Benchmark</i>		
Stream size (T)	10 000	S mu mi lung
S drift events	10	t còch u mi 1 000 mu
N runs	30	S ln chy c lp (seed spacing: $42 + i \times 137$)
δ (tolerance)	75	tr chp nhn cho TP (ca s i xng)
Cooldown	150	Khong còch ti thiiu gia hai ln phòt hin
<i>Classification Benchmark</i>		
S kch bn	6	Mixed A, Mixed B, Repeated $\times 4$ loi
Seeds/kch bn	30	Tng cng 180 lung, 1 800 s kin
δ (tolerance)	250	Phứ hp vi drift kỏo dđi
δ_{early}	50	Cnh bởo sm
<i>Adaptation Benchmark</i>		
Stream size	5 000	Mu/lung
Drift events	5	S kin/lung
N runs	30	S ln chy
δ (tolerance)	400	ònh giò kh nng phc hi
Mũ hnh nn	Logistic Regression	Ti a 1 000 vùng lp
Prequential window	100	Ca s tnh Prequential Accuracy

Bng A.4: Cu hnh nguyõn mu Kafka

Tham s	Giò tr	Mũ t
Broker	localhost:19092	Redpanda (tng thờch Kafka API)
Topic (input)	sensor.stream	Lung d liú u vïo
Topic (results)	drift.results	Kt qu phòt hìn drift
Topic (accuracy)	model.accuracy	Ch s chõnh xóc real-time
Group ID	shapedd-detector	Consumer group
Buffer size	750	Kõch thc b m phòt hìn
Chunk size	150	Tn sut kim tra drift
Adaptation delay	50	Mu ch sau phòt hìn trc khi thờch ng
Adaptation window	800	Mu dứng cho hun luyñ li

PHÂN LÝ LỊCH TRÒCH NGANG

Họ và tên: Lê Phước Đức

Ngày, tháng, năm sinh: 29/09/2000

Nơi sinh: Thành phố Hồ Chí Minh

Địa chỉ hiện tại: 75/54 Nguyễn Tất Đạt, phường An Hòa, Quận 5, TP.HCM

Email: lephucduc2000@gmail.com



QUA TRÌNH HỌC TẬP (*Bắt đầu từ học tập hiện tại*)

- Tháng 8/2018 – Tháng 9/2022: Sinh viên, chuyên ngành Kỹ thuật Điện tử và Tin học, Trường Đại học Bách Khoa – HQG-HCM.
- Tháng 8/2023 – Nay: Học viên cao học, chuyên ngành Khoa học Máy tính, Trường Đại học Bách Khoa – HQG-HCM.

QUA TRÌNH CÔNG VIỆC (*Bắt đầu từ khi đi làm hiện tại*)

- Tháng 6/2022 – Tháng 6/2026: Embedded Software Engineer tại công ty Bosch Global Software Technology Vietnam.
- Tháng 6/2026 – Nay: Embedded Software Engineer tại công ty Hybrid Controls Vietnam Limited Company.